

Grado Universitario en Ingeniería Informática

2024-2025

Trabajo Fin de Grado

“Sistema Inteligente para Cumplimiento de Normativa de '0' Deforestación en Cacao”

Alba Vidales Casado

Tutor

Agapito Ismael Ledezma Espino

Leganés, 2025



Esta obra se encuentra sujeta a la licencia Creative Commons **Reconocimiento – No Comercial – Sin Obra Derivada**

RESUMEN

El siguiente proyecto se corresponde con el diseño y desarrollo de un asistente legal basado en inteligencia artificial. Este sistema inteligente está orientado a facilitar el cumplimiento y entendimiento de normativas de sostenibilidad y *Deforestación Cero* en el sector del cacao, de acuerdo con la Directiva sobre Diligencia Debida en Sostenibilidad Corporativa (CS3D) propuesta por la Unión Europea entre otras regulaciones. Por tanto, el objetivo principal es ayudar a las empresas de este sector con una herramienta que les facilite interpretar de manera rápida y fiable los diferentes puntos legales que afecten a su actividad, así como a resolver posibles dudas relacionadas con el cumplimiento normativo.

Para alcanzar dicho propósito, se ha diseñado un sistema basado en técnicas de procesamiento de lenguaje natural, recuperación aumentada por generación y modelos de lenguaje de gran tamaño (LLMs), de manera que se combina la búsqueda semántica de información legal con la generación de respuestas a las consultas realizadas por los usuarios. Además, se ha implementado una interfaz web que facilita la interacción con el asistente, garantizando su uso de manera sencilla e intuitiva en todo tipo de entornos.

Los resultados obtenidos reflejan un acceso más eficiente a la información legal, reduciendo los tiempos de búsqueda y facilitando la comprensión e interpretación de las diferentes normativas. Se concluye que los sistemas inteligentes basados en inteligencia artificial pueden resultar especialmente útiles en entornos donde no se cuenta con asesoramiento legal, permitiendo a empresas y usuarios adaptarse con mayor facilidad a este tipo de regulaciones.

Palabras clave: Procesamiento de lenguaje natural, asistentes legales, recuperación de información, gestión del conocimiento, IA generativa, modelos de lenguaje de gran tamaño, LegalTech, recuperación aumentada por generación (RAG).

ABSTRACT

The following project involves the design and development of an AI-based legal assistant. The main goal of this intelligent system is to facilitate compliance with, and a clear understanding of the requirements related to sustainability and Zero Deforestation in the cocoa sector, in line with the proposed European Union Corporate Sustainability Due Diligence Directive (CS3D), among other regulations. Therefore, the main objective is to support companies in this sector with a tool that helps them to quickly and reliably interpret the numerous legal aspects affecting their operations, and to support the resolution of legal and compliance-related questions.

To achieve this goal, the system has been designed using natural language processing techniques, retrieval-augmented generation (RAG), and large language models (LLMs), so that it combines semantic search of legal information with the generation of answers to user queries. In addition, a web-based interface has been implemented to facilitate interaction with the assistant, ensuring an intuitive and user-friendly experience across different usage contexts.

The results highlight a more efficient process for accessing legal information, reducing search times and facilitating the understanding and interpretation of various regulations. It is concluded that AI-based intelligent systems can be particularly useful in environments where professional legal support is limited or unavailable, making it easier for companies and users to adapt to such regulations.

Keywords: Natural Language Processing, Legal Assistants, Information Retrieval, Knowledge Management, Generative AI, Large Language Models, LegalTech, Retrieval-Augmented Generation.

*A mis padres, por su apoyo incondicional, su paciencia
y su confianza en cada paso que he dado.*

*A mis amigos de la universidad, por estar, por acompañarme
y por hacer de estos años mucho más que un simple camino académico.*

A mi tutor Agapito, por su guía, su tiempo y su ayuda en la realización de este trabajo.

*A quienes han estado, a quienes están y a quienes estarán, por dejar una parte de sí
mismos en la persona que soy y sigo construyendo.*

Gracias.

ÍNDICE DE CONTENIDOS

1. INTRODUCCIÓN.....	1
1.1. Motivación.....	2
1.2. Antecedentes.....	2
1.3. Objetivos.....	3
1.3.1. Objetivo general	3
1.3.2. Objetivos específicos	3
1.4. Estructura del documento	4
1.5. Glosario y abreviaturas	5
1.5.1. Glosario	5
1.5.2. Abreviaturas.....	6
2. ESTADO DEL ARTE	7
2.1. Cumplimiento normativo y sostenibilidad: evolución y tendencias.....	7
2.1.1. De la responsabilidad social a la diligencia debida obligatoria.....	7
2.1.2. Principales regulaciones recientes: CS3D y EUDR	8
2.2. Tecnologías legales (<i>LegalTech</i>) aplicadas al cumplimiento normativo.....	9
2.2.1. Asistentes legales inteligentes: situación actual	10
2.2.2. Limitaciones de las herramientas actuales en sectores agrícolas y sostenibles.....	11
2.3. Avances en procesamiento de lenguaje natural y LLMs	12
2.3.1. Aplicaciones del PLN en el ámbito jurídico.....	12
2.3.2. Potencial de los LLMs para el análisis legal automatizado.....	13
2.4. Recuperación aumentada por generación	13
2.4.1. Principios básicos de RAG	13
2.4.2. Aplicación de RAG para mejorar la precisión en sistemas legales	14
3. ANÁLISIS DEL PROBLEMA	16
3.1. Descripción del problema.....	16
3.2. Herramientas seleccionadas.....	17
3.2.1. Herramientas para el procesamiento de documentos	18
3.2.2. Herramientas para el acceso y descarga de los modelos	18
3.2.3. Herramientas modelo de <i>embeddings</i>	20
3.2.4. Herramientas almacenamiento vectorial	21
3.2.5. Herramientas modelo de lenguaje	22

3.2.6.	Herramientas interfaz de usuario	25
3.2.7.	Herramientas infraestructura cloud	25
3.2.8.	Versiones	27
3.3.	Especificación de requisitos	28
3.3.1.	Requisitos funcionales	30
3.3.2.	Requisitos no funcionales	31
3.4.	Casos de uso	32
3.4.1.	Especificación de casos de uso	33
3.4.2.	Matriz de trazabilidad	33
3.5.	Riesgos técnicos potenciales	34
4.	DISEÑO DEL SISTEMA BASADO EN RAG	36
4.1.	Arquitectura general del sistema	36
4.2.	Implementación técnica de RAG	37
4.2.1.	Ingesta y procesamiento de los documentos	38
4.2.2.	Vectorización con embeddings	39
4.2.3.	Almacenamiento en la base vectorial	41
4.2.4.	Recuperación de la información	41
4.2.5.	Construcción del prompt	42
4.3.	Validación del sistema RAG	44
4.3.1.	Tiempos de respuesta	44
4.3.2.	Evaluación de la recuperación de los fragmentos	45
4.3.3.	Evaluación manual de casos	47
5.	MODELO DE LENGUAJE	51
5.1.	Ajustes y configuración del modelo	51
5.1.1.	Carga del modelo	51
5.1.2.	Tokenización y generación	52
5.2.	<i>Fine-tuning</i> del modelo	53
5.2.1.	Preparación del modelo base	53
5.2.2.	Preparación del conjunto de datos	54
5.2.3.	Entrenamiento	55
5.2.4.	Fusión del modelo	57
6.	INTERFAZ DE USUARIO	58
6.1.	Enfoque de diseño	58
6.2.	Prototipo inicial	58

6.3.	Estructura y componentes de la aplicación.....	61
6.4.	Prueba de usabilidad.....	62
6.4.1.	Metodología.....	62
6.4.2.	Participantes	62
6.4.3.	Tareas planteadas.....	62
6.4.4.	Resultados.....	63
6.4.5.	Observaciones generales.....	63
7.	INFRAESTRUCTURA Y SERVICIOS CLOUD.....	64
7.1.	Configuración del <i>pod</i>	64
7.2.	Estructura del proyecto	65
7.3.	Ejecución y puesta en marcha	66
7.4.	Consideraciones de seguridad	67
8.	MARCO REGULADOR.....	68
8.1.	Protección de datos personales y derechos digitales	68
8.2.	Ética y regulación de la inteligencia artificial	69
8.2.1.	Directrices éticas para una IA fiable.....	69
8.2.2.	Reglamento Europeo de IA - <i>AI Act</i>	70
8.2.3.	Buenas prácticas aplicadas en este proyecto	71
8.3.	Licencias Software	72
9.	ENTORNO SOCIOECONÓMICO.....	73
9.1.	Impacto socioeconómico	73
9.2.	Planificación	75
9.3.	Presupuesto.....	76
10.	CONCLUSIONES.....	79
10.1.	Conclusiones generales.....	79
10.2.	Futuras líneas de trabajo	80
11.	BIBLIOGRAFÍA.....	82
	ANEXO	87
A.	Especificación de requisitos completa.....	87
B.	Especificación de casos de uso completa	96
C.	<i>Dataset</i> para <i>fine-tuning</i>	99
D.	Resultados <i>fine-tuning</i>	103
E.	Fragmentos recuperados en la evaluación	105
F.	Declaración de IA.....	107

ÍNDICE DE FIGURAS

Fig. 2.1. Arquitectura general del sistema RAG [14].....	14
Fig. 2.2. Arquitectura de indexación y recuperación dual de LightRAG [15]	15
Fig. 3.1. Tendencia de búsqueda de plataformas de modelos de IA en Google Trends [20]	19
Fig. 3.2. Tendencia de búsqueda en Google Trends de plataformas de almacenamiento vectorial [20].....	22
Fig. 3.3. Sliding Windows Attention en Mistral [31].....	23
Fig. 4.1. Arquitectura general y flujo de funcionamiento del sistema	37
Fig. 4.2. Plantilla del prompt generado	43
Fig. 6.1. Prototipo interfaz modo claro inicial	59
Fig. 6.2. Prototipo interfaz modo oscuro inicial.....	59
Fig. 6.3. Prototipo interfaz con chat modo claro	60
Fig. 6.4. Prototipo interfaz con chat modo oscuro	60
Fig. 7.1. Script de arranque start.sh.....	66
Fig. 9.1. Diagrama Gantt del proyecto	76

ÍNDICE DE TABLAS

TABLA 2.1. COMPARATIVA ENTRE LA DIRECTIVA CS3D Y EL REGLAMENTO EUDR	9
TABLA 2.2. COMPARATIVA HERRAMIENTAS LEGALTECH	11
TABLA 3.1. ALTERNATIVAS CONSIDERADAS PARA EL DISEÑO DEL SISTEMA	16
TABLA 3.2. VERSIONES DE LAS HERRAMIENTAS UTILIZADAS	27
TABLA 3.3. PLANTILLA ESPECIFICACIÓN DE REQUISITOS.....	29
TABLA 3.4. TABLA RESUMEN REQUISITOS FUNCIONALES	30
TABLA 3.5. TABLA RESUMEN REQUISITOS NO FUNCIONALES	31
TABLA 3.6. PLANTILLA CASOS DE USO	32
TABLA 3.7. TABLA RESUMEN CASOS DE USO.....	33
TABLA 3.8. MATRIZ DE TRAZABILIDAD	34
TABLA 3.9. RIESGOS TÉCNICOS	35
TABLA 4.1. SIMILITUD MEDIA ENTRE FRAGMENTOS CONSECUTIVOS POR MODELO	40
TABLA 4.2. TIEMPOS DE RESPUESTA DEL SISTEMA.....	44
TABLA 4.3. EVALUACIÓN DE LA RECUPERACIÓN DE FRAGMENTOS Y PRECISIÓN@3	45
TABLA 9.1. PLANIFICACIÓN.....	76
TABLA 9.2. COSTE DE LA PLANTILLA	77
TABLA 9.3. COSTE RECURSOS TECNOLÓGICOS	77
TABLA 9.4. COSTE TOTAL DEL PROYECTO.....	78
TABLA A.1. REQUISITO FUNCIONAL RF-01	87
TABLA A.2. REQUISITO FUNCIONAL RF-02	87
TABLA A.3. REQUISITO FUNCIONAL RF-03	87
TABLA A.4. REQUISITO FUNCIONAL RF-04	88
TABLA A.5. REQUISITO FUNCIONAL RF-05	88
TABLA A.6. REQUISITO FUNCIONAL RF-06	88
TABLA A.7. REQUISITO FUNCIONAL RF-07	89
TABLA A.8. REQUISITO FUNCIONAL RF-08	89
TABLA A.9. REQUISITO FUNCIONAL RF-09	89
TABLA A.10. REQUISITO FUNCIONAL RF-10	90

TABLA A.11. REQUISITO FUNCIONAL RF-11	90
TABLA A.12. REQUISITO FUNCIONAL RF-12	90
TABLA A.13. REQUISITO FUNCIONAL RF-13	91
TABLA A.14. REQUISITO FUNCIONAL RF-14	91
TABLA A.15. REQUISITO FUNCIONAL RF-15	91
TABLA A.16. REQUISITO FUNCIONAL RF-16	92
TABLA A.17. REQUISITO FUNCIONAL RF-17	92
TABLA A.18. REQUISITO NO FUNCIONAL RNF-01	92
TABLA A.19. REQUISITO NO FUNCIONAL RNF-02	93
TABLA A.20. REQUISITO NO FUNCIONAL RNF-03	93
TABLA A.21. REQUISITO NO FUNCIONAL RNF-04	93
TABLA A.22. REQUISITO NO FUNCIONAL RNF-05	94
TABLA A.23. REQUISITO NO FUNCIONAL RNF-06	94
TABLA A.24. REQUISITO NO FUNCIONAL RNF-07	94
TABLA A.25. REQUISITO NO FUNCIONAL RNF-08	95
TABLA A.26. REQUISITO NO FUNCIONAL RNF-09	95
TABLA A.27. REQUISITO NO FUNCIONAL RNF-10	95
TABLA B.28. CASO DE USO CU-03.....	96

1. INTRODUCCIÓN

En los últimos años, la preocupación global por la sostenibilidad en las cadenas de suministro ha llevado a un aumento significativo en la creación de regulaciones y normativas internacionales que buscan garantizar una serie de prácticas responsables por parte de las empresas. En este contexto, la Unión Europea ha desarrollado la “Directiva sobre Diligencia Debida en Sostenibilidad Corporativa” (CS3D), cuyo objetivo principal es obligar a las grandes compañías a identificar, prevenir, mitigar y rendir cuentas de los impactos negativos de sus actividades, tanto en materia de derechos humanos como de medioambiente [1].

En particular, la directiva anterior tiene un gran impacto en sectores como el agrícola, siendo el cacao uno de los productos con mayor influencia. Según datos de la Organización Internacional del Cacao (ICCO), durante la campaña 2022/23, la producción mundial de cacao alcanzó aproximadamente 5 millones de toneladas, de las cuales un 73,6% se concentró en África y un 21,3% en América [2]. Por lo tanto, la aplicación de esta normativa afectará de manera considerable a estos países, al exigir garantías de deforestación cero, respeto de los derechos laborales y responsabilidad ambiental en todas las fases de producción y comercialización. De igual manera, estas obligaciones se extienden a otros productos como pueden ser el café, el arroz, la soja, el aceite de palma o la madera, que también presentan un alto volumen de exportación y están igualmente asociados a riesgos medioambientales y sociales en sus cadenas de suministro.

Además, existen otras regulaciones que siguen la misma línea que la anterior, como es el caso del Reglamento Europeo contra la Deforestación o EUDR [3]. Este marco se centra especialmente en los aspectos medioambientales, tratando de controlar aspectos como que los productos comercializados en el mercado europeo no provengan de tierras deforestadas. Estas nuevas exigencias afectan a un gran número de sectores, por lo que disponer de sistemas inteligentes que asistan en la interpretación y aplicación de los requisitos legales resulta fundamental para apoyar a las empresas, motivando así el desarrollo del presente trabajo.

A partir de esta base, en las siguientes secciones se exponen la motivación y los antecedentes que justifican el trabajo, se definen los objetivos específicos perseguidos, se describe la estructura general del documento y se incorpora un glosario con los términos y abreviaturas utilizados a lo largo del mismo.

1.1. Motivación

Como ya se ha mencionado, el crecimiento de la legislación relacionada con la sostenibilidad y los derechos humanos ha llevado a la adopción de mecanismos de diligencia debida en las cadenas de valor en las empresas. Normativas recientes como CS3D y EUDR han reforzado esta tendencia, afectando de forma directa a sectores agrícolas como el cacao, donde la trazabilidad y el cumplimiento normativo son ya condiciones esenciales para poder acceder a mercados internacionales.

Sin embargo, la interpretación de estos marcos regulatorios puede resultar compleja, especialmente en pequeñas y medianas empresas, que a menudo carecen de los recursos técnicos y legales necesarios para adaptarse. Esta dificultad empeora en sectores de producción primaria, donde los procesos de certificación, verificación de origen y control de impacto ambiental requieren de una comprensión detallada y actualizada de los requisitos legales.

El avance de las tecnologías de procesamiento de lenguaje natural y los modelos de lenguaje de gran tamaño (LLMs) ofrecen una gran oportunidad en este ámbito, de manera que permiten desarrollar soluciones que faciliten el acceso y la interpretación de este tipo de normativas. En este contexto, se plantea el diseño de un asistente legal inteligente capaz de responder de manera rápida, comprensible y precisa a las consultas de las empresas y trabajadores de las mismas, apoyando su proceso de adaptación a los nuevos estándares regulatorios.

Aunque existen desarrollos en el ámbito de la tecnología legal (*LegalTech*), la mayoría de las soluciones actuales están orientadas a servicios jurídicos generales o a grandes organizaciones, sin abordar de forma específica las necesidades de cumplimiento en sectores agrícolas afectados por normativas como la CS3D o el EUDR. Esta carencia de herramientas accesibles y especializadas refuerza la motivación de diseñar un asistente legal que simplifique la comprensión de las nuevas normativas y proporcione soporte directo a empresas de sectores productivos.

1.2. Antecedentes

En los últimos años, han surgido diversas soluciones de tecnología legal basadas en *chatbots* y asistentes virtuales capaces de proporcionar soporte jurídico automatizado. Herramientas como *DoNotPay* [4] o *LawDroid* [5] han permitido automatizar tareas jurídicas básicas, como pueden ser la generación de documentos legales, la gestión de reclamaciones o la asistencia en consultas legales y administrativas. Sin embargo, estas soluciones suelen estar orientadas a servicios jurídicos generales o al apoyo a grandes despachos de abogados, sin abordar de forma específica el cumplimiento de normativas específicas relacionadas con la sostenibilidad o la producción agrícola. Esta falta de especialización evidencia la necesidad de desarrollar sistemas más enfocados y accesibles para otros sectores.

De esta manera, el rápido desarrollo de técnicas de procesamiento de lenguaje natural y la evolución de los LLMs han abierto nuevas posibilidades en el campo de la automatización del análisis documental. Estas tecnologías permiten interpretar textos legales de gran complejidad, identificar requisitos normativos y generar explicaciones comprensibles para usuarios que no sean expertos en el ámbito, democratizando así el acceso a la información jurídica.

Entre estas nuevas técnicas también cabe destacar la recuperación aumentada por generación (RAG), que ha ganado relevancia en tareas que requieren respuestas precisas y fundamentadas en documentos. Esta aproximación combina mecanismos de búsqueda semántica en bases de datos específicas con la capacidad generativa de los modelos de lenguaje, ofreciendo respuestas con mayor respaldo y reduciendo el riesgo de errores o invenciones frecuentes en sistemas generativos. En el ámbito del cumplimiento normativo, RAG es una estrategia adecuada para garantizar que las respuestas del asistente estén basadas en textos legales verificados e información relacionada.

1.3. Objetivos

1.3.1. Objetivo general

El objetivo general del proyecto consiste en diseñar y desarrollar un asistente legal inteligente capaz de interpretar, explicar y facilitar la comprensión y el cumplimiento de normativas de sostenibilidad y diligencia debida, con especial foco en el sector del cacao, empleando para ello técnicas de procesamiento de lenguaje natural y recuperación aumentada por generación, y siendo además accesible a través de una interfaz web intuitiva que permita su uso desde cualquier dispositivo, sin requerimientos técnicos específicos.

1.3.2. Objetivos específicos

- Analizar el marco normativo aplicable, especialmente las directivas europeas en materia de diligencia debida y Deforestación Cero.
- Investigar las tecnologías actuales en procesamiento de lenguaje natural (PLN), recuperación de información y generación automática de texto.
- Diseñar la arquitectura de un sistema inteligente basado en modelos de lenguaje de gran tamaño (LLMs) y técnicas de RAG.
- Desarrollar una interfaz web accesible e intuitiva, que permita la interacción fluida con el asistente legal y pueda ejecutarse desde cualquier dispositivo, sin depender de las especificaciones técnicas del equipo del usuario.

1.4. Estructura del documento

En este apartado se describe de forma breve la estructura seguida por el presente documento:

- **Introducción:** Presenta el contexto en el que surge el proyecto, su motivación y los objetivos que se pretenden alcanzar.
- **Estado del arte:** Revisa la evolución del cumplimiento normativo, las tecnologías legales y diferentes técnicas utilizadas en este ámbito, incluyendo ejemplos concretos de su aplicación en el ámbito jurídico y empresarial.
- **Análisis del problema:** Define el problema a resolver, justifica la selección de herramientas utilizadas, y lleva a cabo el proceso de diseño del sistema, incluyendo requisitos y casos de uso entre otros.
- **Modelo de lenguaje:** Detalla los ajustes y configuración utilizados en el LLM, además del proceso completo de fine-tuning.
- **Interfaz de usuario:** Describe el enfoque de diseño de la aplicación, su prototipo inicial y la estructura final, junto con todas sus funcionalidades.
- **Infraestructura y servicios cloud:** Explica el proceso de despliegue del sistema, la estructura de las carpetas del proyecto, y el arranque y ejecución del mismo en la nube.
- **Marco regulador:** Analiza los aspectos legales y éticos relacionados con la protección de datos, la inteligencia artificial y licencias de software.
- **Entorno socioeconómico:** Evalúa el impacto del proyecto, su planificación temporal y el presupuesto estimado para su desarrollo.
- **Conclusiones:** Resume los principales resultados obtenidos y propone futuras líneas de trabajo.
- **Bibliografía:** Recoge todas las referencias que han sido utilizadas a lo largo del documento.
- **Anexos:** Información complementaria, como el *dataset* utilizado en el entrenamiento, los resultados obtenidos después del fine-tuning o la declaración sobre el uso de inteligencia artificial durante el desarrollo del proyecto.

1.5. Glosario y abreviaturas

Esta sección tiene como objetivo principal facilitar la comprensión del documento mediante la inclusión de un glosario de términos técnicos y una serie de abreviaturas que han sido utilizadas a lo largo del trabajo.

1.5.1. Glosario

- Diligencia debida: Proceso por el cual una empresa identifica, previene y gestiona los posibles impactos negativos que puedan resultar de sus actividades sobre los derechos humanos y el medioambiente.
- LegalTech: Conjunto de tecnologías y herramientas digitales aplicadas a la mejora, automatización y optimización de servicios legales y procesos jurídicos.
- LLM (*Large Language Model*): Modelo de lenguaje de gran tamaño entrenado con grandes volúmenes de texto, capaz de generar, resumir o responder preguntas en lenguaje natural.
- RAG (*Retrieval-Augmented Generation*): Técnica que se basa en la combinación de modelos de lenguaje generativos con mecanismos de recuperación de documentos para generar respuestas fundamentadas en fuentes externas.
- Chatbot: Sistema basado en inteligencia artificial diseñado para simular conversaciones con personas usuarias mediante lenguaje natural.
- Transformer: Arquitectura de red neuronal introducida en 2017 que permite procesar secuencias de texto captando relaciones contextuales entre palabras. Es la base de los modelos de lenguaje de gran tamaño como GPT o BERT.
- Stakeholder: Persona o entidad que tiene interés o se ve afectada por el desarrollo o uso del sistema software. Puede incluir clientes, usuarios finales, desarrolladores, gestores, entidades reguladoras, entre otros.
- Embeddings: Vectores numéricos que representan información textual (palabras, frases o documentos) en un espacio semántico, permitiendo su procesamiento y comparación por modelos de inteligencia artificial.
- Framework: Conjunto de componentes reutilizables que facilitan el desarrollo de software, ofreciendo una estructura y herramientas predefinidas.
- Corpus: Conjunto de textos recopilados y organizados que se utilizan como base para entrenar, evaluar o analizar modelos de procesamiento de lenguaje natural.

- Dataset: Conjunto estructurado de datos utilizado en el entrenamiento o validación de modelos de inteligencia artificial.
- Prompt: Texto o instrucción que se proporciona a un modelo de lenguaje para indicarle qué tarea debe realizar o qué tipo de respuesta se espera. El contenido y la forma del texto influyen directamente en la salida generada por el modelo.
- Machine Learning: Rama de la inteligencia artificial que permite a los sistemas aprender y mejorar de forma automática a partir de datos, identificando patrones y sin ser programados. Esta técnica se utiliza para hacer predicciones o tomar decisiones.

1.5.2. Abreviaturas

- CS3D: Directiva sobre Diligencia Debida en Sostenibilidad Corporativa.
- EUDR: Reglamento Europeo contra la Deforestación.
- LLM: Large Language Model - Modelo de Lenguaje de Gran Tamaño.
- RAG: Retrieval-Augmented Generation - Recuperación Aumentada por Generación.
- PLN: Procesamiento del lenguaje natural.
- IA: Inteligencia artificial.
- ETL: Extract, Transform, Load – Extraer, Transformar, Cargar.
- API: Application Programming Interface – Interfaz de programación de aplicaciones.

2. ESTADO DEL ARTE

Esta sección contiene una revisión de los avances más importantes dentro del ámbito de las tecnologías aplicadas al cumplimiento normativo, prestando especial atención al contexto legal vinculado a la sostenibilidad. Por tanto, el objetivo de este capítulo es contextualizar el desarrollo del presente trabajo dentro del panorama actual, identificando las soluciones existentes, enfoques tecnológicos aplicables y limitaciones detectadas en el uso de inteligencia artificial en este dominio.

A continuación se analizan diversos sistemas de asistencia legal inteligentes, así como los avances recientes en procesamiento de lenguaje natural y en técnicas de recuperación aumentada, con el fin de determinar el punto de partida desde el que se plantea la propuesta desarrollada en este proyecto.

2.1. Cumplimiento normativo y sostenibilidad: evolución y tendencias

La creciente preocupación global por la sostenibilidad ha transformado la manera en que las empresas interactúan con su entorno tanto social como ambiental. Tradicionalmente, muchas de estas acciones se incluían dentro de la responsabilidad social corporativa (RSC) que se entendía como un compromiso voluntario hacia prácticas más responsables. Sin embargo en los últimos años, esta visión ha evolucionado hacia un enfoque más normativo, en el que los Estados y organismos europeos e internacionales imponen obligaciones legales concretas para garantizar la protección de los derechos humanos y del medioambiente en las cadenas de valor de las empresas [6].

Este cambio de paradigma ha dado lugar al desarrollo de una serie de directivas y reglamentos que exigen y regulan a las empresas, obligándolas no solo a actuar con responsabilidad, sino que también a demostrar de forma activa que han identificado y gestionado los riesgos relacionados con sus actividades. Dentro de este contexto, la diligencia debida se concibe como una herramienta que permite identificar y gestionar riesgos de manera sistemática. Tal como la define la Comisión Europea:

“En términos simples, la debida diligencia es la forma en que una empresa entiende, gestiona y comunica el riesgo. Esto incluye los riesgos que genera para otros, y los riesgos a los que se enfrenta a través de sus decisiones y acciones estratégicas y operativas [7].”

2.1.1. De la responsabilidad social a la diligencia debida obligatoria

Como se ha mencionado, durante décadas muchas empresas adoptaron iniciativas voluntarias en el ámbito de la sostenibilidad como parte de sus estrategias de reputación o diferenciación con respecto al resto del mercado. Estas acciones estaban vinculadas a estándares internacionales como es el caso del *Pacto Mundial de Naciones Unidas* o los *Principios Rectores sobre las Empresas y los Derechos Humanos*.

Sin embargo, la falta de mecanismos que prueben el cumplimiento de estas medidas y el limitado impacto real de muchas de estas iniciativas dieron lugar a un cambio de enfoque. Hoy en día, la sostenibilidad empresarial está dejando de ser una opción reputacional para convertirse en una obligación legal, especialmente en la Unión Europea [6].

El paso de un enfoque voluntario a uno más obligatorio y regulado, se refleja claramente en directivas como la CS3D que introduce exigencias jurídicas específicas en términos de derechos humanos y sostenibilidad ambiental [1], incluyendo reglamentos como la EUDR que prohíbe el acceso al mercado europeo a productos vinculados con la deforestación [3]. Ambos textos normativos incorporan principios de diligencia debida que exigen a las empresas a realizar una serie de controles sobre su cadena de valor.

2.1.2. Principales regulaciones recientes: CS3D y EUDR

En los últimos años, la Unión Europea ha puesto en marcha diversas normativas con el fin de reforzar el compromiso de las empresas con la sostenibilidad, los derechos humanos y la conservación del medioambiente. Entre estas regulaciones destacan la normativa **CS3D** y el reglamento **EUDR**, que comparten una base común en la exigencia de mecanismos de diligencia debida, aunque con enfoques y alcances distintos.

La CS3D, adoptada formalmente en mayo de 2024, establece un marco legal para que grandes empresas europeas identifiquen, prevengan, mitiguen y reparen los impactos negativos de sus actividades sobre los derechos humanos y el medioambiente. Los Estados miembros disponen de un plazo de dos años para transponer esta directiva a sus ordenamientos jurídicos nacionales [8].

Por su parte el EUDR, aprobado en 2023 y de aplicación obligatoria a partir del 30 de diciembre de 2025, busca garantizar que determinados productos comercializados en la UE no procedan de terrenos deforestados. Afecta a operadores e importadores de materias primas como cacao, café, soja, madera, caucho, aceite de palma y ganado bovino. Este reglamento implica un sistema de diligencia debida con geolocalización de las parcelas de origen, verificación de legalidad y ausencia de deforestación, y conservación de dichas pruebas durante cinco años [9].

Ambas normativas comparten el principio de diligencia debida, pero presentan diferencias relevantes que pueden observarse en la siguiente tabla:

TABLA 2.1. COMPARATIVA ENTRE LA DIRECTIVA CS3D Y EL REGLAMENTO EUDR

Aspecto	CS3D	EUDR
Tipo de norma	Directiva (transposición por los Estados) ¹ .	Reglamento (aplicación directa en toda la UE).
Entrada en vigor	Adoptada en mayo de 2024, transposición obligatoria en un plazo de 2 años.	Obligatoria desde el 30 de diciembre de 2025.
Ámbito de aplicación	Empresas grandes y medianas en sectores de riesgo.	Operadores, comerciantes e importadores de productos agrícolas específicos.
Cobertura temática	Derechos humanos y medioambiente (general).	Deforestación y degradación forestal (específico).
Objeto de regulación	Todas las actividades de la empresa.	7 materias primas clave (cacao, café, soja, etc.).
Requisitos clave	Integración de la diligencia debida en estrategia, supervisión.	Trazabilidad, geolocalización, documentación verificable.
Comunicación pública	Informes obligatorios sobre la aplicación de la diligencia debida.	Declaración por producto y sistema de control público.

A pesar de sus diferencias, ambas regulaciones son complementarias y reflejan una tendencia clara: exigir a las empresas una mayor responsabilidad sobre sus cadenas de suministro. Mientras que la CS3D aborda el cumplimiento desde una perspectiva global y estratégica, el EUDR introduce exigencias más operativas y específicas sobre productos agrícolas. En conjunto, configuran un escenario legal complejo que demanda soluciones técnicas avanzadas que ayuden a las empresas a cumplir con estos requisitos.

2.2. Tecnologías legales (*LegalTech*) aplicadas al cumplimiento normativo

El desarrollo de tecnologías de inteligencia artificial ha favorecido la aparición de múltiples herramientas en el ámbito del derecho, dando lugar al denominado sector *LegalTech*. En particular, los sistemas de asistencia legal basados en lenguaje natural y automatización han comenzado a desempeñar un papel relevante en tareas como la redacción de documentos jurídicos, la orientación legal básica o la resolución de consultas frecuentes.

¹ Las directivas requieren ser adaptadas a la legislación nacional por cada Estado miembro en un plazo determinado, mientras que los reglamentos tienen aplicación directa e inmediata en los países de la UE.

2.2.1. Asistentes legales inteligentes: situación actual

En los últimos años han surgido diversas soluciones de tecnología legal que aplican inteligencia artificial al ámbito jurídico. Estas herramientas permiten simplificar tareas como la redacción de documentos, la generación de reclamaciones, la atención a usuarios o la interpretación de consultas frecuentes. Algunos de los sistemas más conocidos a nivel generalista son:

- **DoNotPay** [4] es una plataforma que ofrece servicios legales automatizados mediante inteligencia artificial, diseñada para ayudar en ciertos trámites como recurrir multas, gestionar reclamaciones o cancelar suscripciones. Además funciona a través de una interfaz tipo *chatbot*, y solo cubre legislación de EE.UU. y Reino Unido. No está orientada a explicar ni interpretar normativas complejas.
- **LawDroid** [5], por su parte, proporciona asistentes jurídicos diseñados para despachos de abogados y profesionales dentro de este ámbito. Estas herramientas permiten automatizar respuestas, recopilar información jurídica y facilitar la relación con los clientes, mejorando la eficiencia en tareas repetitivas y la comunicación con clientes. Está enfocada en el contexto jurídico estadounidense. Aunque permite personalización, requiere de conocimientos para adaptarla a nuevos marcos legales.

Más recientemente, han surgido plataformas que aplican inteligencia artificial para facilitar el cumplimiento normativo, aunque no todas están diseñadas específicamente como asistentes legales ni orientadas a sectores como la sostenibilidad o la agricultura. Algunas incorporan capacidades que podrían adaptarse a marcos como la CS3D o el EUDR, aunque con enfoques y niveles de especialización distintos.

Una de ellas es **Prewave** [10], una plataforma que utiliza IA para analizar datos en tiempo real, detectar riesgos ambientales e identificar incumplimientos en la cadena de suministro. Este sistema automatizado facilita el cumplimiento de las normativas anteriores mediante la detección temprana de eventos críticos y la generación de informes. No obstante, el asesoramiento estratégico y la interpretación legal continúan a cargo de expertos humanos. Esto quiere decir que no interactúa con los usuarios ni interpreta estas normativas, y además su complejidad y coste pueden ser barreras para PYMEs agrícolas.

También destaca **Anytime AI** [11], una plataforma legal impulsada por inteligencia artificial centrada en la automatización de tareas jurídicas para despachos de abogados. Sus funciones incluyen la búsqueda jurídica automatizada, el análisis de documentos y la generación de respuestas legales personalizadas. Aunque no está específicamente orientada al cumplimiento de regulaciones como la CS3D o el EUDR, sus capacidades de procesamiento de lenguaje natural podrían adaptarse a estos marcos utilizando fuentes documentales y ajustes personalizados en su entrenamiento. Está pensada para asistir a profesionales jurídicos, no a usuarios no expertos o pymes del sector agrícola.

TABLA 2.2. COMPARATIVA HERRAMIENTAS *LEGALTECH*

Herramienta	Enfoque	CS3D/ EUDR	Usuario objetivo	Idioma	Limitaciones
DoNotPay	Reclamaciones para consumidores	No	Usuarios individuales	Inglés	Generalista, no orientada a marcos legales europeos
LawDroid	<i>Chatbots</i> jurídicos para abogados	No	Despachos jurídicos	Inglés	Más enfocada a la automatización de tareas que a la interpretación
Prewave	Monitoriza y detecta riesgos en cadenas de suministro	Sí	Empresas	Multi-lingüe	No interactúa con usuarios ni explica la normativa
Anytime AI	Automatización jurídica general para despachos	Parcial	Abogados y consultorías	Multi-lingüe	Requiere configuración manual, no está orientada a interpretar normativas, sino a búsqueda y análisis documental
Proyecto Asistente	Asistente legal inteligente RAG + LLM	Sí	PYMEs agrícolas	Español	Requiere infraestructura técnica mínima, pero accesible y explicado al usuario

2.2.2. Limitaciones de las herramientas actuales en sectores agrícolas y sostenibles.

A pesar del avance significativo de las herramientas de asistencia legal basadas en inteligencia artificial, la tabla anterior muestra como las soluciones actualmente disponibles presentan ciertas limitaciones cuando se analizan desde la perspectiva del cumplimiento normativo en sostenibilidad y cadenas de suministro agrícolas.

Por un lado, muchas plataformas están orientadas a servicios jurídicos generalistas o a contextos legales muy concretos, como la resolución de reclamaciones individuales o la automatización de trámites jurídicos comunes, sin abordar de forma específica las exigencias derivadas de marcos regulatorios como la CS3D o el EUDR, ni su interpretación y explicación posterior al usuario. Es decir, no ayudan a las organizaciones no expertas a comprender la normativa, cómo les afecta en la práctica ni qué deben hacer para cumplirla.

A todo lo anterior se suma que muchas de estas herramientas no están pensadas para ser utilizadas directamente por pequeñas y medianas empresas que pertenecen al sector primario y que a menudo carecen de los conocimientos legales y técnicos necesarios para interpretar marcos regulatorios complejos o configurar sistemas avanzados. Esto genera una barrera de acceso real a la tecnología, y limita su impacto en los sectores que más necesitan apoyo en el cumplimiento normativo.

Estas limitaciones evidencian la ausencia de soluciones comprensibles y adecuadas que permitan a este tipo de organizaciones interpretar y aplicar de forma sencilla los nuevos marcos regulatorios europeos. Esta carencia justifica la necesidad de desarrollar asistentes legales inteligentes que no solo automaticen tareas, sino que expliquen, contextualicen y faciliten el cumplimiento normativo en entornos no expertos.

En este contexto, se abre la oportunidad de aprovechar los recientes avances dentro del procesamiento de lenguaje natural y la recuperación aumentada por generación para construir herramientas realmente adaptadas a las necesidades del cumplimiento normativo en sostenibilidad, como la que se propone en este trabajo.

2.3. Avances en procesamiento de lenguaje natural y LLMs

El procesamiento de lenguaje natural es una rama de la IA que se centra en la interpretación y en la generación del lenguaje humano utilizando para ello algoritmos computacionales. Durante los últimos años, esta disciplina ha pasado de usar métodos simples basados en conteo de palabras o reglas predefinidas, a sistemas mucho más avanzados capaces de comprender el contexto y generar texto con coherencia.

En paralelo, los modelos de lenguaje de gran tamaño han mejorado sus capacidades de análisis y generación de texto. Gracias a su entrenamiento con grandes volúmenes de datos, pueden abordar tareas complejas como responder preguntas, resumir documentos o clasificar información, lo que los hace especialmente útiles en el ámbito legal.

2.3.1. Aplicaciones del PLN en el ámbito jurídico

El PLN ha sido aplicado con éxito en diversos contextos jurídicos, como la extracción de entidades legales relevantes (partes, fechas, jurisdicciones), la clasificación de documentos por tipo de procedimiento o la recuperación de jurisprudencia vinculada a casos concretos. También ha permitido desarrollar sistemas de apoyo a la decisión jurídica, como detectores de cláusulas abusivas o clasificadores de resoluciones judiciales según patrones previos [12].

Herramientas como **Legal NLP**, de *John Snow Labs*, proporcionan modelos preentrenados específicamente diseñados para este tipo de tareas, facilitando la automatización de procesos como la revisión de contratos o el análisis de documentos legales extensos [12].

2.3.2. Potencial de los LLMs para el análisis legal automatizado

Los modelos de lenguaje de gran tamaño representan uno de los avances más significativos en el campo del PLN. Gracias a su arquitectura de red neuronal conocida como *transformer*, diseñada para captar relaciones contextuales entre palabras en una secuencia, y a su entrenamiento sobre enormes volúmenes de texto, estos modelos han demostrado una gran capacidad para generar, comprender y reformular contenido en lenguaje natural con un alto grado de coherencia.

En el ámbito jurídico, los LLMs permiten abordar tareas complejas de forma más eficiente y automatizada. Su capacidad para interpretar textos normativos, responder consultas complejas, resumir documentos extensos o detectar inconsistencias legales los convierte en herramientas idóneas para tareas de análisis y asistencia automatizada. A diferencia de enfoques anteriores más limitados, estos modelos no requieren una programación explícita de reglas lingüísticas o lógicas para cada caso, sino que aprenden patrones a partir de grandes cantidades de ejemplos [13].

Además, los LLMs tienen el potencial de transformar la práctica jurídica al ofrecer asistencia a jueces en la toma de decisiones, facilitar el análisis de grandes volúmenes de jurisprudencia y generar automáticamente documentos legales. Este tipo de soporte puede reducir la carga de trabajo repetitiva y mejorar la eficiencia judicial. Por otro lado, estos modelos posibilitan una democratización del acceso al conocimiento jurídico, ya que pueden ser utilizados por ciudadanos para obtener orientación legal básica sin necesidad de recurrir a un profesional. De igual manera, su capacidad para realizar razonamientos lógicos a partir de la evidencia y presentar explicaciones de sus conclusiones contribuye a una mayor transparencia y trazabilidad en procesos judiciales [13].

2.4. Recuperación aumentada por generación

2.4.1. Principios básicos de RAG

La Recuperación Aumentada por Generación (RAG, por sus siglas en inglés) es una arquitectura híbrida que resulta de la combinación de modelos de lenguaje generativos con sistemas de recuperación de información. Esta integración permite que las respuestas generadas estén respaldadas por datos externos específicos y actualizados, mejorando así la precisión de las respuestas en tareas que requieren un alto nivel de conocimiento [14].

A diferencia de los modelos puramente paramétricos, que almacenan el conocimiento en sus pesos y no pueden ser fácilmente actualizados, RAG permite modificar su comportamiento simplemente cambiando su base de datos externa. Esto proporciona una ventaja clave en tareas donde el conocimiento cambia con el tiempo, como en el derecho o en la medicina. El funcionamiento de RAG se basa en dos componentes principales:

- **Recuperador (*Retriever*):** Utiliza técnicas de búsqueda semántica para localizar documentos relevantes en una base de datos externa, transformando la consulta del usuario en un vector y comparándolo con vectores de documentos indexados.
- **Generador (*Generator*):** Modelo de lenguaje que, tomando como entrada la consulta original y los documentos recuperados, genera una respuesta coherente y contextualizada.

Este proceso se puede visualizar a continuación:




Fig. 2.1. Arquitectura general del sistema RAG [14]

La **Figura 2.1** muestra como el sistema recibe una consulta (q) que es codificada y utilizada por un recuperador (p_n) para localizar los documentos más relevantes (z_1, z_2, z_3, z_4) en una base de datos. Estos documentos son procesados junto con la consulta por un generador (p_θ), que elabora la respuesta final (y).

2.4.2. Aplicación de RAG para mejorar la precisión en sistemas legales

En el ámbito jurídico, la precisión y la fundamentación de las respuestas es esencial. Los modelos generativos puros pueden ofrecer resultados coherentes pero inventados, lo cual supone un riesgo en contextos donde se requiere trazabilidad normativa. La integración de RAG permite mitigar este problema, ya que la generación de texto se limita al contexto obtenido a partir de documentos legales verificados y actualizados.

Esta técnica es especialmente útil en asistentes legales inteligentes, ya que facilita la interpretación automatizada de normativas complejas, como las relacionadas con sostenibilidad o diligencia debida, sin comprometer la fiabilidad de las respuestas. De este modo, RAG se convierte en una estrategia adecuada para sistemas orientados a empresas que requieren comprender y aplicar marcos legales con base documental explícita, como es el caso del asistente propuesto en este trabajo.

Además, han surgido propuestas recientes que exploran versiones más ligeras y eficientes de esta arquitectura. Un ejemplo destacado es **LightRAG** [15], un marco de código abierto que introduce innovaciones significativas en la implementación de sistemas RAG. LightRAG incorpora estructuras de grafos en los procesos de indexación y recuperación de texto, permitiendo una representación más rica de las interdependencias entre entidades.

Su arquitectura se basa en un sistema de recuperación de doble nivel:

- **Recuperación de bajo nivel:** se enfoca en información precisa sobre entidades individuales y sus relaciones directas. Esta capa permite identificar información muy específica y estructurada
- **Recuperación de alto nivel:** abarca temas y conceptos más amplios, facilitando una comprensión contextual más profunda. Permite entender el entorno o la narrativa donde se ubican las entidades recuperadas.

Esta dualidad mejora la capacidad del sistema para manejar consultas complejas que requieren tanto detalles más específicos como una visión general del contexto. Además, LightRAG integra representaciones vectoriales con estructuras de grafos, lo que facilita una recuperación eficiente de entidades relacionadas y sus relaciones, mejorando significativamente los tiempos de respuesta.

La arquitectura puede verse esquematizada en la siguiente figura, donde se representan las fases de deduplicación, extracción de entidades y relaciones, construcción del grafo de indexación y recuperación de contenido en dos niveles:

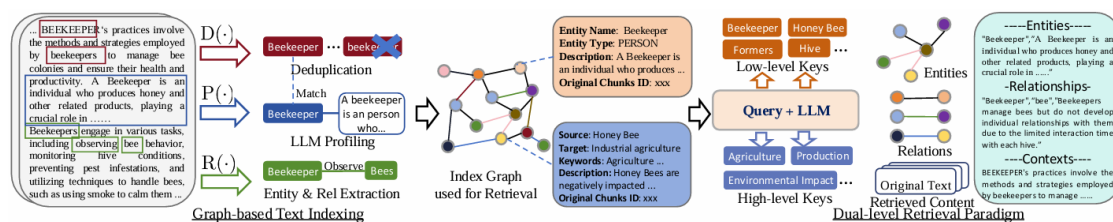


Fig. 2.2. Arquitectura de indexación y recuperación dual de LightRAG [15]

Por otro lado, su algoritmo de actualización incremental asegura la integración oportuna de nuevos datos, manteniendo la eficacia del sistema en entornos de datos en rápida evolución.

Aunque LightRAG no ha sido utilizado directamente en el desarrollo del presente sistema inteligente, representa una línea de investigación prometedora en la evolución de sistemas RAG, especialmente en contextos donde se requiere una comprensión profunda y contextualizada de la información.

3. ANÁLISIS DEL PROBLEMA

En el siguiente apartado se analiza el problema concreto que se pretende resolver con este asistente y que se centra en la dificultad que presentan muchas organizaciones para comprender y aplicar normativas europeas complejas como la CS3D o el EUDR. A partir de esta necesidad, se comparan distintas alternativas tecnológicas, valorando sus ventajas e inconvenientes en el contexto del cumplimiento normativo automatizado. Este análisis justifica la elección de un enfoque basado en modelos de lenguaje e inteligencia artificial, y permite definir tanto los principales escenarios de uso como los retos funcionales y técnicos, recogidos en la posterior especificación de requisitos.

3.1. Descripción del problema

A partir del análisis realizado en los capítulos anteriores, se concluye que actualmente no existen herramientas centradas específicamente en asistir en la comprensión y el cumplimiento de normativas como la CS3D o el EUDR, que combinen el uso exclusivo de técnicas de inteligencia artificial avanzada y una interfaz accesible para usuarios sin formación jurídica especializada.

Dado este contexto, al inicio del proyecto se evaluaron posibles aproximaciones para construir una solución que facilitase esta tarea:

TABLA 3.1. ALTERNATIVAS CONSIDERADAS PARA EL DISEÑO DEL SISTEMA

Alternativa	Sistema Experto	Chatbot basado en LLM + RAG
Descripción	Desarrollo de un sistema basado en reglas y listas de verificación para validar documentos según las normativas.	Asistente conversacional que responde a preguntas recuperando información relevante y explicando el contexto.
Ventajas	▪ Fácil de usar ▪ Implementación sencilla ▪ Interfaz simple ▪ Control total sobre las reglas	▪ Flexible y adaptativo ▪ Capaz de explicar y contextualizar ▪ Interfaz natural y dialogada ▪ Mayor interacción con el usuario
Inconvenientes	▪ Poco flexible ante cambios normativos ▪ Requiere mantenimiento manual ▪ Experiencia de usuario limitada ▪ No explica el porqué del resultado	▪ Puede requerir más interacción ▪ Dependencia del modelo para respuestas correctas
Decisión	Descartada por rigidez y falta de contexto	Seleccionada por su equilibrio entre precisión, accesibilidad y soporte al usuario

A la vista de la comparativa anterior, se opta por un asistente conversacional con arquitectura RAG, por su capacidad para ofrecer respuestas interpretadas, contextualizadas y accesibles en lenguaje natural. Esta decisión ha condicionado el diseño técnico del sistema, tanto a nivel de modelo como de interfaz, y ha guiado la selección de herramientas y requisitos que se abordan en los capítulos siguientes. Además, esta solución facilita la adaptación a nuevas normativas sin rehacer la lógica subyacente.

No obstante, esta elección introduce una serie de retos técnicos y conceptuales:

- **Fuentes legales estructuradas:** Disponer de datos fiables que alimenten la recuperación de información es esencial para garantizar respuestas pertinentes.
- **Selección y ajuste del modelo:** Es necesario contar con un modelo de lenguaje capaz de generar respuestas coherentes, jurídicas y adaptadas al contexto.
- **Diseño de la arquitectura RAG:** Se requiere una integración eficiente entre la recuperación semántica y la generación de texto, sin comprometer la precisión ni el rendimiento.
- **Interfaz accesible:** La solución debe integrarse en una interfaz sencilla e intuitiva, permitiendo a usuarios sin conocimientos jurídicos formular preguntas en lenguaje natural y recibir respuestas comprensibles.
- **Trazabilidad y transparencia:** Es crucial que las respuestas sean explicables y se pueda verificar su origen, dado el contexto legal en el que se utilizará la herramienta.

Por tanto, el problema a resolver consiste en desarrollar un asistente legal inteligente en forma de *chatbot*, capaz de ayudar a usuarios sin formación jurídica a comprender y consultar normativas complejas como la CS3D o el EUDR, mediante un sistema accesible, conversacional y basado en técnicas de inteligencia artificial como los modelos de lenguaje y la Recuperación Aumentada por Generación.

3.2. Herramientas seleccionadas

En la siguiente sección se encuentra la selección de herramientas utilizadas para integrar de forma eficiente los distintos componentes del sistema propuesto. Se detallan los principales recursos que se han utilizado, desde el procesamiento inicial de documentos hasta la infraestructura de despliegue, pasando por el modelo de lenguaje, la arquitectura RAG, el almacenamiento vectorial, los *embeddings* y la interfaz de usuario. Cada decisión técnica ha sido tomada en línea con los objetivos del proyecto y las necesidades que presentaban los usuarios finales.

3.2.1. Herramientas para el procesamiento de documentos

Antes de generar los embeddings o realizar búsquedas vectoriales, es necesario transformar los documentos legales en bruto a un formato estructurado y que el sistema pueda manejar. Para lo anterior, se ha diseñado un proceso de tipo ETL (*Extract, Transform, Load*), que permite extraer el texto del PDF, limpiarlo y dividirlo en fragmentos útiles para su posterior vectorización.

1. **Extracción (Extract):** El contenido se extrae utilizando la biblioteca *pdfplumber*, diseñada para extraer texto, tablas y metadatos de archivos PDF. De esta manera, permite acceder al texto de cada página conservando su estructura básica.
2. **Transformación (Transform):** El texto extraído se limpia mediante expresiones regulares utilizando el módulo estándar de Python *re*. De esta forma, se eliminan encabezados, saltos innecesarios y otros elementos irrelevantes. Posteriormente se divide en una serie de fragmentos o *chunks* utilizando la herramienta *RecursiveCharacterTextSplitter* ofrecida por *langchain*, una librería que facilita la construcción de aplicaciones con modelos de lenguaje. Esta división se realiza con control de tamaño y solapamiento. Se implementa también una lógica para fusionar fragmentos demasiado pequeños, garantizando así una mejor coherencia semántica.
3. **Carga (Load):** Finalmente los fragmentos procesados junto con los metadatos como el título del documento, país de aplicación y sección, se guardan en un archivo JSON.

3.2.2. Herramientas para el acceso y descarga de los modelos

Para el desarrollo del sistema ha sido necesario utilizar modelos preentrenados, tanto para obtener *embeddings* como para generar respuestas. Estos modelos se obtienen generalmente desde plataformas especializadas que permiten su descarga, integración y uso en proyectos.

Existen varias plataformas que centralizan modelos de inteligencia artificial y ofrecen APIs (*Application Programming Interface*) o herramientas de descarga para integrarlos en proyectos. Entre las más destacadas se encuentran:

- **Hugging Face [16]:** Plataforma líder en modelos de lenguaje y otras áreas de IA. Proporciona acceso a miles de modelos preentrenados, tanto públicos como privados, y cuenta con una comunidad muy activa. Está especialmente orientada al procesamiento del lenguaje natural y ofrece modelos listos para tareas como clasificación de texto, generación de lenguaje, traducción automática o análisis semántico. A diferencia de otras plataformas, Hugging Face se especializa en LLMs, como BERT, RoBERTa o GPT, ampliamente utilizados en asistentes inteligentes, buscadores semánticos y sistemas conversacionales.

- **TensorFlow Hub** [17]: Repositorio de modelos preentrenados desarrollados para funcionar principalmente con TensorFlow. Su catálogo está especialmente orientado a tareas de visión por computador, clasificación y reconocimiento de imágenes, aunque también incluye algunos modelos básicos de texto. Está pensado para integrarse fácilmente en proyectos con TensorFlow y permite aprovechar el uso de GPU o TPU en entornos compatibles. No está centrado en modelos de lenguaje de gran tamaño, por lo que su aplicación en sistemas como asistentes conversacionales es limitada.
- **PyTorch Hub** [18]: Plataforma mantenida por los desarrolladores de PyTorch, ofrece ejemplos de modelos para tareas como clasificación de texto o visión por computador. Está orientada principalmente a personas con experiencia técnica que trabajan directamente con el *framework* PyTorch. Aunque incluye algunos modelos de procesamiento de texto, no está especializada en lenguaje natural ni ofrece modelos de lenguaje de gran tamaño como Hugging Face.
- **ONNX Model Zoo** [19]: Repositorio de modelos preentrenados en formato ONNX, un estándar que permite utilizar modelos en distintos frameworks como PyTorch o TensorFlow, sin necesidad de reentrenarlos. Su principal ventaja es que los modelos pueden ejecutarse en diferentes entornos (como CPU, GPU o incluso dispositivos específicos), lo que lo hace útil para despliegues más técnicos. Sin embargo, requiere conocimientos más técnicos y no dispone de una API tan accesible como Hugging Face.

En la **Figura 3.1** se muestra el interés general por cada plataforma según Google Trends en los últimos 12 meses. Aunque términos como TensorFlow o PyTorch incluyen búsquedas más amplias, el gráfico permite observar que Hugging Face ha mantenido un crecimiento sostenido, posicionándose como una opción destacada en el ámbito de la IA.




Fig. 3.1. Tendencia de búsqueda de plataformas de modelos de IA en Google Trends [20]

A pesar de la popularidad de PyTorch, esta plataforma no está orientada específicamente al acceso y gestión de modelos de lenguaje natural, y su repositorio de modelos preentrenados es más limitado en este ámbito. Por ello, para este proyecto se ha decidido utilizar Hugging Face como plataforma principal de descarga de modelos, debido a su amplio catálogo especializado en lenguaje natural y a la facilidad que ofrece para integrarse en el código mediante la librería *huggingface_hub*.

3.2.3. Herramientas modelo de *embeddings*

Una vez se han procesado los documentos, el siguiente paso consiste en representar cada fragmento mediante un vector numérico que capture su significado semántico. Para ello se utilizaron diferentes modelos de generación de embeddings evaluando su rendimiento, con el objetivo de seleccionar el que ofreciera mayor coherencia entre fragmentos consecutivos y mejor desempeño en tareas de recuperación.

El proceso de generación y evaluación se apoyó en las siguientes herramientas:

- ***sentence-transformers*:** Biblioteca que ofrece modelos preentrenados optimizados para generar embeddings de oraciones y textos cortos. Se utilizó para cargar y ejecutar los siguientes modelos, destacados por su rendimiento y compatibilidad con textos multilingües:

paraphrase-multilingual-MiniLM-L12-v2 [21]: Modelo multilingüe ligero basado en la arquitectura Sentence-BERT, una extensión de BERT que utiliza redes siamesas para ajustar su arquitectura y poder generar un único vector representativo por frase. Ofrece un buen equilibrio entre precisión y velocidad, por lo que resulta adecuado para procesar grandes volúmenes de texto legal como el de la CS3D, manteniendo un tiempo de ejecución reducido [22].

distiluse-base-multilingual-cased [23]: Igual que el anterior, este modelo está basado en el modelo Sentence-BERT. Está optimizado para tareas de clasificación y recuperación, y es especialmente útil en contextos donde se requiere comparar fragmentos cortos de texto con un vocabulario técnico diverso. Ofrece buenos resultados incluso cuando se utiliza en equipos con poca capacidad de procesamiento [22].

- ***transformers* (de Hugging Face):** Además de los modelos anteriores, se utilizaron otros modelos a través de la librería *transformers*, que permite acceder a arquitecturas más flexibles y entrenadas sobre corpus específicos. Los modelos seleccionados fueron:

dccuchile/bert-base-spanish-wwm-uncased [24]: Modelo BERT entrenado exclusivamente en español, desarrollado por el centro de investigación DCC de la Universidad de Chile [25]. Se eligió por su enfoque monolingüe, lo que mejora la comprensión de estructuras gramaticales y vocabulario específico del idioma.

PlanTL-GOB-ES/roberta-large-bne [26]: Modelo basado en la arquitectura RoBERTa, una variante mejorada de BERT que elimina la predicción de la siguiente oración y emplea un entrenamiento más intensivo y robusto sobre corpus sin procesar. Este modelo forma parte del proyecto **MarIA**, desarrollado por el Plan de Impulso de las Tecnologías del Lenguaje del Gobierno de España, y ha sido entrenado con textos de la Biblioteca Nacional de España, lo que lo especializa en el lenguaje formal, institucional y jurídico. Su tamaño es equivalente a *RoBERTa large* (355 millones de parámetros) y está diseñado para tareas de comprensión y representación del lenguaje en español. Su especialización en lenguaje administrativo y jurídico lo hace especialmente adecuado para trabajar con el contenido de la directiva CS3D [27].

- **scikit-learn** [28]: Por último en esta parte también se utiliza esta librería de Python, comúnmente utilizada en el desarrollo de tareas de aprendizaje automático clásico y que incluye una serie de herramientas para clasificación, regresión, reducción de dimensionalidad y métricas. Específicamente, en esta parte se utiliza la función *pairwise.cosine_similarity*, que permite calcular la similitud entre vectores numéricos. Esta métrica se aplicó para comparar los *embeddings* generados por los distintos modelos, midiendo la similitud semántica entre fragmentos consecutivos del texto. Una mayor similitud entre fragmentos relacionados indica una representación más coherente, lo que ayuda a evaluar el rendimiento de cada modelo de forma cuantitativa.

3.2.4. Herramientas almacenamiento vectorial

Para almacenar y consultar los embeddings generados por los distintos fragmentos de texto, se ha utilizado **Pinecone**, una plataforma especializada en bases de datos vectoriales que permite indexar vectores numéricos y realizar búsquedas eficientes por similitud, lo que resulta clave cuando se trabaja con representaciones vectoriales generadas por modelos de lenguaje [29].

Se optó por Pinecone por su facilidad de uso, su API bien documentada y su integración directa con entornos de desarrollo en Python. Permite almacenar y consultar vectores de forma eficiente sin necesidad de configurar herramientas adicionales, lo que agiliza el desarrollo y simplifica el mantenimiento durante el proyecto.

A pesar de que existen otras soluciones como FAISS, Weaviate o Qdrant, se descartaron por diversos motivos. FAISS requiere configuración y ejecución local, lo que complica el despliegue rápido. Weaviate y Qdrant, aunque ofrecen funcionalidades avanzadas, implican una mayor complejidad de instalación o integración, lo que añadía una complejidad innecesaria para los objetivos y el alcance del proyecto.

Para mostrar la popularidad actual de estas herramientas, en la **Figura 3.2** se compara el interés general en cada una de ellas según datos de Google Trends. Como se puede observar, Pinecone destaca claramente sobre el resto, reflejando una mayor presencia en la comunidad y mayor facilidad de acceso a recursos, documentación y soporte.



Fig. 3.2. Tendencia de búsqueda en Google Trends de plataformas de almacenamiento vectorial [20]

3.2.5. Herramientas modelo de lenguaje

Para la generación de respuestas se ha utilizado el modelo **mistralai/Mistral-7B-Instruct-v0.3** [30], un modelo de lenguaje de código abierto, optimizado para tareas de instrucción disponible en la plataforma Hugging Face. Se basa en la arquitectura Mistral, y se ha seleccionado por su capacidad para generar texto coherente y controlado a partir de un *prompt* estructurado.

Mistral 7B es un modelo con 7,3 mil millones de parámetros basado en la arquitectura *Transformer*, una estructura de red neuronal diseñada específicamente para procesar secuencias de texto de forma eficiente. Esta arquitectura se basa en el mecanismo de autoatención, que permite al modelo ponderar la relevancia de cada palabra del texto con respecto a las demás, independientemente de su posición, logrando una comprensión textual muy precisa.

La autoatención se implementa mediante múltiples cabezas de atención, cada una de las cuales aprende a detectar distintos tipos de relaciones entre palabras. Estas cabezas transforman cada palabra en tres vectores: consulta (*query*), clave (*key*) y valor (*value*). La consulta de una palabra se compara con las claves de todas las demás para calcular su nivel de relevancia respecto a ellas. A partir de estas comparaciones se generan unos pesos de atención, que indican la importancia relativa de cada palabra dentro del contexto.

El diseño de Mistral 7B se centra en ofrecer un alto rendimiento con eficiencia computacional, introduciendo para ello dos mecanismos claves de atención:

- **Grouped-Query Attention (GQA):** En los *Transformers* clásicos, cada cabeza de atención genera sus propios vectores de consulta, clave y valor, lo que supone un alto coste computacional y de memoria. GQA optimiza este proceso haciendo que varias cabezas compartan los vectores de clave y valor, mientras cada una conserva su propio vector de consulta. Esto permite reducir los recursos necesarios sin perder capacidad para captar relaciones distintas entre palabras, ya que cada cabeza sigue enfocándose en aspectos contextuales diferentes usando la misma información base [31].
- **Sliding Windows Attention (SWA):** Este mecanismo permite que cada *token* atienda solo a un número limitado de tokens anteriores dentro de una ventana fija. Esto reduce significativamente el coste cuadrático de la atención tradicional, haciendo el modelo más eficiente al procesar secuencias largas. Como se muestra en la figura, en cada capa solo se permite atención dentro de una pequeña ventana. Sin embargo, al acumular información a lo largo de las capas, el modelo puede construir un contexto más amplio de forma progresiva [31].




Fig. 3.3. Sliding Windows Attention en Mistral [31]

Dada la necesidad de ofrecer respuestas claras, contextualizadas y ajustadas a normativa legal, se ha seleccionado Mistral-7B-Instruct-v0.3 por su equilibrio entre eficiencia y capacidad de generación. Su arquitectura permite manejar entradas legales extensas con menor coste computacional, manteniendo un alto nivel de coherencia en las respuestas. Además, su *fine-tuning* orientado a instrucciones le permite generar respuestas claras y alineadas con lo que solicita el usuario, algo especialmente importante en un contexto legal donde la precisión es fundamental.

Además del modelo, en este proyecto se han utilizado diversas herramientas que permiten ajustar y ejecutar Mistral-7B-Instruct-v0.3 de forma eficiente en entornos locales con recursos limitados:

- ***BitsAndBytesConfig*** ha sido utilizado para cuantizar el modelo a 4 bits, lo que reduce significativamente el uso de memoria VRAM sin comprometer gravemente el rendimiento. Esta técnica representa los pesos del modelo con menor precisión numérica, lo que puede afectar levemente la calidad de las respuestas en tareas especialmente sensibles. Sin embargo, en la práctica mantiene un rendimiento adecuado para tareas conversacionales como las abordadas en este proyecto. No obstante, en una futura extensión del proyecto, se podría considerar eliminar esta cuantización y emplear computación en la nube para aprovechar el modelo con una mayor precisión y rendimiento.
- ***Trainer*** y ***TrainingArguments***, de la librería *transformers*, han sido empleados para definir y controlar el proceso de *fine-tuning* sobre un conjunto de datos adaptado al dominio legal. Estas herramientas facilitan la gestión de entrenamiento, seguimiento, evaluación y guardado de *checkpoints* (puntos de control).
- Para realizar un fine-tuning eficiente, se ha incorporado el uso de la librería ***PEFT (Parameter-Efficient Fine-Tuning)***. En particular, se ha aplicado ***LoRA***, lo que permite ajustar solo un subconjunto pequeño de parámetros del modelo original para el entrenamiento, manteniendo el resto intacto. Esta técnica reduce el coste computacional y la cantidad de datos necesarios para ajustar el modelo a tareas específicas como la generación de respuestas legales en el contexto del proyecto. Igual que con la cuantización, esto se puede ir adaptando para mejorar el entrenamiento según los recursos de los que se dispongan.
- También dentro del fine-tuning se ha utilizado el optimizador ***AdamW***, que se encarga de actualizar los pesos del modelo durante el entrenamiento. Se caracteriza por ajustar de forma adaptativa la magnitud de estos cambios para cada hiperparámetro, y es ampliamente utilizado en modelos de lenguaje por su eficacia y estabilidad. Además, corrige el manejo del término *weight_decay*, evitando que los pesos crezcan de forma descontrolada, lo cual evita el sobreajuste y ayuda a que el modelo sea capaz de generalizar mejor ante datos desconocidos.

3.2.6. Herramientas interfaz de usuario

Para la construcción de la interfaz del asistente legal se ha utilizado **Streamlit** [32], un *framework* de Python que facilita el desarrollo de aplicaciones web, y que está especialmente orientado a proyectos de ciencia de datos y prototipos interactivos. Permite crear interfaces con una estructura clara y con pocas líneas de código, facilitando así el mantenimiento del proyecto y su despliegue. Esta simplicidad no implica descuidar la experiencia del usuario; al contrario, ha permitido centrar los esfuerzos en el desarrollo del asistente sin dejar de ofrecer una interfaz cuidada, funcional y adaptada al contexto.

Además, se ha incorporado **HTML** y **CSS** embebido para personalizar ciertos aspectos del diseño del chat, logrando una experiencia visual más cercana a las interfaces conversacionales de la actualidad. Con ello se han definido estilos adaptativos, burbujas de conversación diferenciadas entre usuario y asistente, y animaciones. Esta personalización mejora la usabilidad y facilita la interacción con el asistente legal de forma intuitiva y estructurada.

Aunque existen otras opciones como Gradio o Flask, Streamlit ha sido seleccionado por su curva de aprendizaje más suave, su integración nativa con Python y su compatibilidad con procesos en tiempo real sin necesidad de configurar rutas ni servidores de forma manual. Gradio, si bien está orientado también a interfaces para modelos de lenguaje, ofrece menos flexibilidad en el diseño visual y en la personalización avanzada. Flask permite un control total sobre la lógica web, pero requiere conocimientos adicionales de desarrollo *frontend* y gestión de servidores.

En este contexto, Streamlit ofrecía el equilibrio adecuado entre simplicidad, personalización y funcionalidad, permitiendo centrar el esfuerzo en la lógica del asistente sin añadir complejidad innecesaria al desarrollo de la interfaz.

Antes de llevar a cabo la implementación, se utilizó la herramienta **Figma** [33] para el diseño de un prototipo interactivo de la interfaz. Esta fase previa permitió definir visualmente la estructura general del asistente, planificar la disposición de los elementos conversacionales y evaluar posibles interacciones con el usuario. A pesar de que Streamlit impone ciertas limitaciones en cuanto a personalización visual, al estar orientado a componentes estándar, contar con un diseño previo ayudó a trasladar las ideas clave a un entorno funcional.

3.2.7. Herramientas infraestructura cloud

Para la ejecución del modelo y el funcionamiento completo del asistente legal, se ha utilizado la plataforma **RunPod** [34], un servicio de computación en la nube especializado en ofrecer acceso bajo demanda a entornos con GPU. Su uso ha permitido solventar las limitaciones del hardware local, especialmente en lo que respecta a memoria y procesamiento para la inferencia de modelos de gran tamaño, como los LLMs.

Además de proporcionar acceso a recursos computacionales avanzados, RunPod permite desplegar aplicaciones accesibles desde cualquier dispositivo a través de un enlace público, lo cual ha sido clave para facilitar la usabilidad del sistema desde distintos equipos sin necesidad de instalar software adicional.

Aunque existen otras alternativas como Google Colab o AWS (SageMaker), se ha descartado su uso por distintas razones:

- **Google Colab** es una plataforma que permite ejecutar código en la nube con soporte para GPU, pero presenta ciertas limitaciones. Entre ellas, destacan la restricción de tiempo de sesión, que puede desconectar el entorno tras periodos de inactividad o tras unas horas de uso, así como la asignación dinámica de recursos, que hace que no siempre se garantice el acceso a GPUs adecuadas. Además, el control sobre la configuración del entorno es limitado, y su uso sostenido requiere suscripción de pago (Colab Pro), sin garantizar el rendimiento necesario para modelos de gran tamaño con carga constante.
- **AWS SageMaker** es una solución profesional y altamente escalable para entrenar, desplegar y alojar modelos de *machine learning* en la nube. Sin embargo, su uso implica una configuración inicial compleja y requiere conocimientos avanzados de servicios cloud y redes virtuales, además de un coste elevado para proyectos académicos o prototipos que no requieren una infraestructura de producción a gran escala. Aunque es ideal para entornos empresariales, no era la opción más adecuada para este proyecto.

Frente a las alternativas anteriores, RunPod ha ofrecido el equilibrio adecuado entre rendimiento, coste, facilidad de uso y capacidad de despliegue, permitiendo no solo ejecutar el modelo con fluidez, sino también ofrecer el asistente como servicio accesible desde cualquier navegador mediante una URL.

3.2.8. Versiones

En la tabla que se muestra a continuación, se exponen las diferentes versiones de las principales herramientas utilizadas en el proyecto:

TABLA 3.2. VERSIONES DE LAS HERRAMIENTAS UTILIZADAS

Herramienta	Versión	Uso principal
Python	3.10.12	Lenguaje base del proyecto
pdfplumber	0.11.6	Lectura y análisis de contenido en PDF
huggingface-hub	0.30.2	Autenticación y descarga de modelos desde Hugging Face
sentence-transformers	4.1.0	Generación de embeddings semánticos
pinecone	5.4.2	Almacenamiento y recuperación de vectores
transformers	4.51.3	Carga y ejecución del modelo Mistral-7B
peft	0.15.2	Fine-tuning con LoRA
bitsandbytes	0.45.5	Cuantización a 4 bits del modelo
streamlit	1.44.1	Desarrollo de la interfaz

3.3. Especificación de requisitos

La especificación de los requisitos de software es un documento fundamental en el desarrollo de cualquier sistema, ya que establece de forma clara, precisa y verificable lo que debe hacer el software que se va a desarrollar. Según la práctica recomendada por el estándar IEEE 830-1998 [35], este documento actúa como un contrato entre *stakeholders* y desarrolladores, definiendo el comportamiento del sistema sin adentrarse en detalles de diseño o implementación.

Según este estándar, una buena especificación debe cumplir con las siguientes características principales [35]:

- **Corrección:** Una especificación se considera correcta si todos los requisitos que contiene responden a necesidades justificadas del sistema, asegurando que el producto desarrollado coincida con lo que realmente se espera de él.
- **No ambigua:** Cada uno de los requisitos debe tener una única interpretación.
- **Completa:** Todos los requisitos significativos deben estar recogidos en la especificación.
- **Consistente:** Los requisitos no deben contradecirse entre sí, la inconsistencia no es implementable.
- **Clasificada por importancia y/o estabilidad:** Cada requisito debe tener asignada una prioridad o reflejar el grado de probabilidad de que sufra cambios.
- **Verificable:** Debe ser posible comprobar si un requisito se ha cumplido mediante una prueba, revisión o análisis.
- **Modificable:** La estructura del documento debe permitir cambios simples y consistentes.
- **Trazabilidad:** Cada requisito debe tener una identificación única y poder ser referenciado a lo largo de todo el ciclo de vida del software.

Dentro del conjunto de requisitos, se diferencian dos grandes grupos:

- **Requisitos funcionales:** Definen las funciones, comportamientos y servicios que el sistema debe ofrecer, es decir, cómo debe actuar ante determinadas entradas o situaciones.
- **Requisitos no funcionales:** Establecen restricciones, condiciones o características de calidad que debe cumplir el sistema, como el rendimiento, la seguridad o la usabilidad.

Antes de presentar la especificación de requisitos del proyecto, se describe a continuación la estructura utilizada para documentarlos. Cada campo cumple una función específica:

- **Identificador:** Código único que permite referenciar al requisito de forma inequívoca. Se clasifica como RF (requisito funcional) o RNF (requisito no funcional).
- **Nombre:** Título breve y representativo del contenido del requisito.
- **Fuente:** Indica el origen del requisito definido, pudiendo ser el cliente, el analista o un experto en IA.
- **Prioridad:** Establece la importancia relativa del requisito dentro del sistema (Alta, Media o Baja).
- **Estabilidad:** Estima la probabilidad de que el requisito se mantenga sin cambios a lo largo del tiempo (Alta, Media o Baja).
- **Necesidad:** Evalúa la dependencia del éxito del sistema respecto al cumplimiento del requisito (Alta, Media o Baja).
- **Verificabilidad:** Determina si es posible comprobar de forma objetiva si el requisito se ha satisfecho (Alta, Media o Baja).
- **Descripción:** Se trata de una explicación detallada y completa del requisito.

La **Tabla 3.3** mostrada a continuación representa la plantilla que se ha utilizado para la especificación de los requisitos funcionales y no funcionales del sistema. En ella se define una estructura estandarizada que facilita su identificación, análisis y posterior validación durante el desarrollo del proyecto.

TABLA 3.3. PLANTILLA ESPECIFICACIÓN DE REQUISITOS

Identificador			
Nombre			
Fuente			
Prioridad		Estabilidad	
Necesidad		Verificabilidad	
Descripción			

3.3.1. Requisitos funcionales

A continuación se recoge un resumen de los requisitos funcionales del sistema, que son aquellos que describen las funciones que debe ofrecer la aplicación para satisfacer las necesidades del usuario y cumplir con todos los objetivos del proyecto.

TABLA 3.4. TABLA RESUMEN REQUISITOS FUNCIONALES

Identificador	Nombre	Prioridad
RF-01	Resolución de consultas sobre Deforestación Cero	Alta
RF-02	Recuperación contexto legal mediante RAG	Alta
RF-03	Registro historial conversacional	Media
RF-04	Construcción del prompt	Alta
RF-05	Generación de respuesta legal con modelo LLM	Alta
RF-06	Disponibilidad de base documental legal	Alta
RF-07	Entrada de consultas desde la interfaz web	Alta
RF-08	Visualización inmediata de respuestas	Media
RF-09	Feedback sobre utilidad de respuestas	Media
RF-10	Registro de interacciones en archivo CSV	Alta
RF-11	Retroalimentación visual durante el procesamiento	Media
RF-12	Botones de consulta rápida	Baja
RF-13	Reinicio del historial de chat	Baja
RF-14	Inclusión de documentación legal CS3D	Alta
RF-15	Autenticación mediante claves de entorno	Media
RF-16	Extracción de contenido desde PDF	Alta
RF-17	División del texto en fragmentos	Alta

Para consultar la especificación completa de los requisitos funcionales que incluye la plantilla anterior descrita al inicio del apartado (con la descripción detallada, fuente, estabilidad, necesidad y verificabilidad), se remite al apartado correspondiente en el **Anexo A**.

3.3.2. Requisitos no funcionales

En esta sección se recoge una tabla con un resumen de los requisitos no funcionales, que definen las restricciones, condiciones de calidad y características generales que debe cumplir el sistema para garantizar su eficacia, usabilidad y rendimiento.

TABLA 3.5. TABLA RESUMEN REQUISITOS NO FUNCIONALES

Identificador	Nombre	Prioridad
RNF-01	Tiempo de respuesta	Media
RNF-02	Tiempo de carga del sistema	Media
RNF-03	Interfaz con formato de chat	Alta
RNF-04	Sistema accesible desde cualquier dispositivo	Alta
RNF-05	Facilidad de uso	Alta
RNF-06	Persistencia del registro de interacciones	Alta
RNF-07	Rendimiento mínimo del modelo	Alta
RNF-08	Arquitectura desacoplada	Media
RNF-09	Compatibilidad con navegadores modernos	Media
RNF-10	Soporte modo claro y oscuro	Baja

Para consultar la especificación completa de los requisitos no funcionales que complementa la plantilla anterior (incluyendo la descripción detallada, fuente, estabilidad, necesidad y verificabilidad), se remite al apartado correspondiente en el **Anexo A**.

3.4. Casos de uso

Los casos de uso permiten representar cómo interactúan los diferentes usuarios con el sistema para alcanzar sus objetivos, describiendo el comportamiento del sistema desde la perspectiva del usuario final. Cada caso de uso representa una interacción aislada entre un actor y el sistema.

Su desarrollo se ha realizado a partir de los requisitos funcionales definidos anteriormente y se ha utilizado además una plantilla que permite detallar los siguientes elementos para cada uno de los casos:

- **Identificador:** Clave única que permite referenciar al caso de uso de forma precisa y sin ambigüedades. Sigue un formato del tipo CU-01, CU-02, etc.
- **Nombre:** Título breve y descriptivo que resume la funcionalidad representada por dicho caso de uso.
- **Actor:** Elemento o entidad que interactúa con el sistema a través de la acción descrita por el caso de uso (Usuario y Sistema).
- **Fuente:** Requisitos relacionados con el caso de uso. Este campo permite identificar qué requisitos se están abordando y comprobar que quedan cubiertos por el comportamiento del sistema.
- **Precondiciones:** Requisitos que deben cumplirse antes de que el caso de uso tenga lugar, garantizando así que el sistema está en un estado válido para comenzar.
- **Postcondiciones:** Resultado o estado esperado del sistema una vez se haya completado el caso de uso.
- **Descripción:** Explicación más extensa y detallada de la interacción de los actores y el sistema.

En la siguiente tabla se puede ver la plantilla mencionada, que se ha utilizado como base para documentar todos los casos de uso desarrollados.

TABLA 3.6. PLANTILLA CASOS DE USO

Identificador		Nombre	
Actor		Fuente	
Precondiciones			
Postcondiciones			
Descripción			

3.4.1. Especificación de casos de uso

Se presenta a continuación un resumen de los casos de uso identificados dentro de este sistema y que describen las interacciones principales entre los actores (usuarios o componentes del sistema) y la aplicación, con el fin de cumplir los requisitos funcionales definidos y alcanzar los objetivos del proyecto.

TABLA 3.7. TABLA RESUMEN CASOS DE USO

Identificador	Nombre	Actor
CU-01	Realizar una consulta	Usuario
CU-02	Recuperar contexto legal	Sistema
CU-03	Generar respuesta con LLM	Sistema
CU-04	Mostrar la respuesta	Sistema
CU-05	Valorar respuesta	Usuario / Sistema
CU-06	Consultar mediante sugerencias	Usuario
CU-07	Reiniciar chat	Usuario
CU-08	Carga del sistema	Sistema
CU-09	Carga de documentos	Administrador / Sistema

Para consultar la especificación completa de los casos de uso que complementa la plantilla anterior (incluyendo actor, fuentes de requisitos, precondiciones, postcondiciones y descripción detallada), se remite al apartado correspondiente en el **Anexo B**.

3.4.2. Matriz de trazabilidad

Por último se muestra la matriz de trazabilidad, que permite establecer una correspondencia entre los requisitos funcionales y los casos de uso, para asegurar que todas las funcionalidades que se esperan del sistema (requisitos) están cubiertas por las interacciones descritas en el apartado anterior.

La trazabilidad de los requisitos asegura un seguimiento bidireccional, facilitando tanto la verificación de que cada requisito definido ha sido correctamente implementado, como la identificación de los requisitos que justifican cada componente del sistema desarrollado.

TABLA 3.8. MATRIZ DE TRAZABILIDAD

	CU-01	CU-02	CU-03	CU-04	CU-05	CU-06	CU-07	CU-08	CU-09
RF-01	X								
RF-02		X							
RF-03			X						
RF-04		X	X						
RF-05			X						
RF-06		X							X
RF-07	X							X	
RF-08				X					
RF-09					X				
RF-10					X				
RF-11	X			X					
RF-12						X			
RF-13							X		
RF-14		X							X
RF-15								X	
RF-16									X
RF-17									X

3.5. Riesgos técnicos potenciales

En todo desarrollo software, especialmente cuando dicho proceso involucra tecnologías emergentes como en este caso pueden ser los modelos de lenguaje de gran tamaño o la arquitectura RAG, es fundamental anticiparse a posibles riesgos técnicos que puedan comprometer el rendimiento, la precisión o la viabilidad del sistema.

En este contexto surge el **análisis de riesgos técnicos**, una técnica que permite identificar, evaluar y gestionar posibles problemas que podrían surgir durante el desarrollo y afectar negativamente al funcionamiento o mantenimiento de un sistema software. Su principal objetivo es, por tanto, anticipar escenarios problemáticos y establecer medidas de mitigación para reducir su impacto.

Para cada riesgo identificado dentro del proyecto se han considerado los siguientes campos:

- **Riesgo técnico:** Contiene una descripción breve del problema detectado.
- **Descripción:** Explicación del riesgo, especificando en qué consiste y por qué podría afectar al sistema.
- **Probabilidad:** Estimación de la posibilidad de que ocurra (Alta, Media o Baja).
- **Impacto:** Gravedad de las consecuencias si el riesgo ocurriese (Alto, Medio o Bajo).
- **Mitigación:** Acciones planificadas para evitar o reducir el efecto del riesgo.

La siguiente tabla resume los principales riesgos técnicos identificados durante el diseño y desarrollo del asistente legal.

TABLA 3.9. RIESGOS TÉCNICOS

Riesgo técnico	Descripción	Probabilidad	Impacto	Mitigación
Baja precisión de respuestas	El modelo podría generar respuestas erróneas o inútiles.	Alta	Alto	Uso de RAG y sistema de feedback del usuario.
Latencia elevada de las consultas	El tiempo de respuesta podría ser demasiado alto.	Media	Alto	Fragmentar en <i>chunks</i> más pequeños y homogéneos, normalizando su longitud.
Cambios en las bibliotecas o APIs de los modelos	Posibles modificaciones que podrían romper la compatibilidad.	Media	Medio	Fijar las versiones utilizadas en un entorno virtual o contenedor.
Limitaciones del dispositivo del usuario	Limitaciones si el sistema dependiera del hardware del usuario.	Alta	Alto	Despliegue del sistema en infraestructura cloud con soporte para GPU.
Costes inesperados de uso en la nube	El despliegue cloud puede generar gastos superiores a los esperados.	Baja	Medio	Monitorización activa del uso del sistema.

4. DISEÑO DEL SISTEMA BASADO EN RAG

En los siguientes capítulos se detalla la metodología seguida en el desarrollo de cada uno de los componentes del sistema. En concreto, en este capítulo se analizan las fases iniciales del asistente legal, que comprenden el preprocesamiento, ingesta y vectorización de los documentos, su posterior almacenamiento y la implementación del sistema basado en RAG.

4.1. Arquitectura general del sistema

Como ya se ha mencionado previamente, el sistema se basa en la arquitectura denominada Recuperación Aumentada por generación, o RAG por sus siglas. Este tipo de arquitectura combina técnicas de recuperación semántica con generación de lenguaje natural, con el fin de responder a las preguntas realizadas por el usuario en relación con las normativas de Deforestación Cero.

A grandes rasgos, el sistema se estructura en una serie de componentes que permiten procesar documentos legales, almacenarlos en una base vectorial y utilizarlos posteriormente como contexto durante la generación de respuestas.

La arquitectura del sistema RAG, por tanto, se puede dividir en los siguientes cinco bloques funcionales descritos a continuación:

1. **Ingesta y procesamiento de los datos:** limpieza, fragmentación y preparación de los documentos legales en formato PDF.
2. **Vectorización con embeddings:** generación de representaciones numéricas de cada fragmento.
3. **Almacenamiento:** indexación y almacenamiento de los vectores en Pinecone para una recuperación posterior eficiente.
4. **Recuperación del contexto:** búsqueda semántica de los fragmentos más importantes en la base de Pinecone considerando la consulta realizada por el usuario.
5. **Construcción del prompt:** integración de todos los elementos necesarios para la construcción de la instrucción que procesa el LLM.

En la **Figura 4.1** se representa de forma de esquema el flujo seguido por el asistente, así como la integración y coordinación de los diferentes módulos que componen el sistema.




Fig. 4.1. Arquitectura general y flujo de funcionamiento del sistema

4.2. Implementación técnica de RAG

Para la implementación del sistema RAG, se ha partido de la estructura base de este tipo de arquitectura. Es fácil recordar sus componentes a partir de sus siglas:

- **R → Retrieval (Recuperación)**

El sistema recupera los fragmentos más importantes a partir de una base de datos de vectores externa, en este caso Pinecone [29], utilizando búsquedas semánticas basadas en *embeddings* con el fin de encontrar aquellos segmentos que sean más cercanos a la consulta realizada por el usuario.

- **A → Augmented (Aumentada)**

La fase de generación de la respuesta con el modelo LLM está “aumentada” con el contenido que se haya recuperado del almacén de vectores. Por esto, no se basa únicamente en el propio conocimiento preentrenado del modelo, sino que incorpora evidencias sacadas directamente de las normativas.

- **G → Generation (Generación)**

El modelo de lenguaje genera texto natural, utilizando el contexto que se ha recuperado e integrado en el prompt, lo que mejora la precisión y fundamentación de las respuestas generadas.

A continuación se describen en detalle cada una de las fases que componen esta arquitectura RAG, enfocada en el asistente legal desarrollado.

4.2.1. Ingesta y procesamiento de los documentos

El primer paso dentro de la implementación del sistema consiste en el preprocesamiento y la preparación de los diferentes documentos legales que van a formar parte de la base de conocimientos del asistente legal y que posteriormente serán utilizados para la generación de los embeddings. Para este proceso, se ha diseñado un *script* que automatiza cada una de las funcionalidades necesarias y que abarca los siguientes pasos:

- **Carga de los documentos en bruto:** Inicialmente los documentos legales se encuentran en formato PDF. Este formato no es procesable directamente, y por ello es necesario extraer su contenido textual para poder trabajar con dichos datos en etapas posteriores.

Por tanto, se utilizan las herramientas especificadas anteriormente para extraer el texto, y convertir el contenido de los documentos PDF en cadenas de texto (*str*).

- **Limpieza del contenido textual:** Una vez el texto se encuentra en un formato procesable, se procede a la limpieza del mismo. En este contexto, se eliminan elementos que resultan innecesarios como saltos de línea excesivos o espacios dobles. También se han utilizado expresiones regulares para eliminar encabezados y pies de página que se repiten en todo el documento y que no aportan información semántica relevante.
- **Fragmentación del texto o *chunking*:** Con la cadena de texto libre de elementos innecesarios, el contenido se divide en fragmentos de una longitud específica, con el objetivo de facilitar su posterior vectorización y recuperación. En concreto, en este sistema se ha utilizado una configuración con los siguientes parámetros:

En primer lugar se ha establecido un tamaño de los fragmentos de 750 caracteres. Este valor se ha elegido como punto de equilibrio entre dos factores, por un lado asegurar que los fragmentos tienen suficiente información, de manera que resulten útiles en la fase de recuperación, y por otro lado evitar que puedan ser demasiado largos y dificulten la construcción del prompt. En pruebas preliminares, se observó que valores superiores a 1000 caracteres generaban prompts demasiado largos, produciendo respuestas demasiado largas por parte del modelo de lenguaje, y que valores inferiores a 500 no aportaban suficiente contexto.

También se ha establecido un solapamiento de 50 caracteres entre fragmentos consecutivos, para así tratar de conservar el contexto y evitar rupturas bruscas de significado. Parece un valor idóneo ya que se ha comprobado que valores mayores aumentaban innecesariamente el tamaño del corpus sin producir mejoras.

A parte de lo anterior, se ha definido una jerarquía de separadores para realizar la división del texto de una forma más natural. Dichos separadores serán los saltos de línea o signos de puntuación, en ese orden. No obstante, durante este proceso se pudo detectar que algunos fragmentos resultantes eran demasiado cortos, probablemente debido a la conversión realizada desde el formato PDF. Para evitar que estos fragmentos perjudiquen la coherencia semántica, se ha implementado una lógica que permite unirlos con el fragmento anterior.

- **Inclusión de metadatos:** Se sigue este proceso asignando a cada fragmento una serie de metadatos como a qué documento pertenecen o a qué sección dentro de este. Esto mejora la trazabilidad de cada fragmento recuperado, y puede ser útil en posteriores actualizaciones para poder filtrar los resultados en función de criterios específicos, o simplemente mostrar al usuario la fuente exacta de la información proporcionada.
- **Almacenamiento de los fragmentos:** Para finalizar, se almacenan los fragmentos anteriores y sus datos en un archivo con el formato JSON. Este archivo permite organizar el corpus de forma estructurada antes de su vectorización.

4.2.2. Vectorización con embeddings

Una vez generados los fragmentos, el siguiente paso consiste en transformar cada uno de ellos en una representación numérica conocida como *embeddings*. El objetivo de esta transformación es poder realizar comparaciones con otras entradas, como la consulta del usuario en este caso.

En esencia, un *embedding* es una representación numérica de un texto en forma de vector. Esta representación no se basa únicamente en las palabras que pertenecen al fragmento, sino que también tiene en cuenta su significado. De esta manera, gracias a los embeddings frases formadas por diferentes palabras pero con el mismo sentido pueden estar muy próximas en el espacio vectorial, permitiendo que el sistema pueda comparar el contenido de la consulta con los fragmentos recuperados del documento legal, aunque no coincidan exactamente en el lenguaje utilizado.

Para llevar a cabo la vectorización de los fragmentos, se ha utilizado el modelo *PlanTL-GOB-ES/roberta-large-bne* [26]. Este modelo, ha sido entrenado para trabajar con textos en español y optimizado para tareas semánticas, es decir, orientado a comprender el significado de los textos. Esto lo hace especialmente adecuado para un dominio como el legal, en el que se necesita realizar una interpretación adecuada del lenguaje

Antes de adoptar este modelo, se evaluaron otras alternativas. Para determinar la calidad semántica de los diferentes modelos de embeddings, se realizaron pruebas basadas en la similitud entre fragmentos consecutivos dentro del mismo documento. Esto tiene sentido, pues en textos legales, los fragmentos adyacentes deberían compartir un alto grado de coherencia semántica.

En concreto, se compararon varios modelos calculando la similitud coseno entre los embeddings generados para fragmento consecutivos. Posteriormente, se calculó la media de estas similitudes para cada modelo y se seleccionó aquel que presentaba una mayor cohesión local. Se muestran los resultados obtenidos en la **Tabla 4.1**.

TABLA 4.1. SIMILITUD MEDIA ENTRE FRAGMENTOS CONSECUTIVOS POR MODELO

Modelo	Similitud media
RoBERTa_BNE	0.9818
BERT (dccuchile)	0.8101
SBERT	0.6592
DistillUSE	0.3987

Se puede observar como el modelo RoBERTa_BNE obtuvo la mayor similitud media, superando con diferencia al resto de modelos evaluados, reforzando así su idoneidad para representar fragmentos legales en español de forma coherente y contextualizada.

Del mismo modo, es importante recalcar que la consulta introducida por el usuario a través de la interfaz, también se vectoriza con este mismo modelo. Esto permite compararla directamente con los fragmentos almacenados. Será a partir de esta comparación cuando se seleccionen los fragmentos más relevantes para incluirlos en el prompt con el que se generará la respuesta.

4.2.3. Almacenamiento en la base vectorial

Una vez se han obtenido los embeddings para cada fragmento, estos se deben almacenar en una base de datos vectorial como Pinecone [29], que luego permita realizar búsquedas por similitud.

Para lo anterior se ha creado un índice vectorial, una estructura de datos que permite almacenar y buscar fragmentos de texto en forma de vectores. Para esta búsqueda se va a basar en su similitud semántica, a diferencia de una base de datos tradicional donde las búsquedas son exactas por claves, un índice vectorial permite recuperar los elementos con mayor similitud en un espacio multidimensional.

En este sistema se ha definido un índice denominado *legal-compliance-index* que actúa como contenedor principal para los embeddings generados. Este índice se ha creado con una dimensión de 1024, coincidiendo así con el tamaño de los vectores generados por el modelo mencionado en el apartado anterior. Además se ha especificado un *namespace*, que en el contexto de Pinecone funciona como una partición lógica dentro de un mismo índice, permitiendo agrupar vectores relacionados de forma separada. Así se facilita la organización del contenido y permite escalar el sistema en el futuro, por ejemplo al añadir nuevos documentos legales o separar por idiomas.

Una vez el sistema se ha conectado con Pinecone y ha creado la estructura del índice, se insertan todos los vectores generados. A partir de este momento, el índice queda preparado para realizar búsquedas por similitud.

4.2.4. Recuperación de la información

Una vez la base vectorial se ha creado y contiene los embeddings, el sistema ya está preparado para recibir preguntas de los usuarios y recuperar los fragmentos que formarán parte del contexto legal del prompt. Este proceso comienza transformando la consulta introducida por el usuario en un vector, tal como se ha explicado en apartados anteriores.

A continuación, el vector de la consulta se compara con todos los vectores almacenados en el índice. Esta comparación se lleva a cabo con la similitud coseno.

En tareas de recuperación semántica como la que se implementa en este sistema, la similitud coseno es la métrica más adecuada, ya que compara la orientación de los vectores sin verse afectada por su magnitud, lo cual quiere decir que va a comparar vectores que apunten hacia direcciones similares sin importar la longitud que estos tengan. Esto permite medir con mayor precisión la cercanía semántica entre fragmentos y consultas, incluso si su longitud o estructura superficial son muy diferentes. Existen otras métricas como la distancia euclídea o el producto escalar, pero suelen requerir vectores normalizados o ajustados a tareas específicas.

De esta manera, se devuelven los k fragmentos más cercanos a la consulta, ordenados por su grado de similitud. En el caso de este asistente, el valor de k se ha configurado como 4, de modo que se recuperan los 4 fragmentos más relevantes del índice. Una vez recuperados, se incorporarán en el prompt como parte del contexto legal que el modelo generativo recibirá para elaborar la respuesta.

4.2.5. Construcción del prompt

El siguiente paso en la arquitectura RAG consiste en construir el mensaje de entrada que será enviado al modelo generador. En este contexto, toma relevancia lo que se conoce como *prompt engineering* o ingeniería de prompts, una práctica clave en el uso de modelos de lenguaje generativos como el utilizado en este sistema. Esta técnica consiste en diseñar la estructura, el contenido y las instrucciones del prompt con el fin de guiar el comportamiento del LLM y obtener respuestas más precisas, relevantes y controladas.

En esencia, un *prompt* es el mensaje de entrada que se le proporciona al modelo de lenguaje para la generación de la respuesta. Este no consiste únicamente en la pregunta del usuario, sino en un bloque de texto en el que se puede incluir información adicional como contexto sobre un tema, instrucciones o el formato deseado en la respuesta. A continuación se desarrolla la estructura elegida en este caso:

- **Instrucciones:** Al inicio del mensaje, se incluyen una serie de indicaciones diseñadas para guiar el comportamiento del modelo. Estas instrucciones abordan ciertos aspectos como evitar divagaciones, el uso del contexto legal cuando sea necesario y el tipo de lenguaje utilizado en las respuestas entre otros. Su objetivo es reducir ambigüedades y asegurar que las respuestas sean coherentes, relevantes y comprensibles.
- **Historial de la conversación:** A continuación se incorporan las tres últimas interacciones entre usuario y asistente, con el objetivo principal de mantener coherencia conversacional y tener en cuenta el flujo del diálogo. Esto puede resultar útil cuando la consulta actual dependa de mensajes anteriores.
- **Contexto legal recuperado:** En esta parte se incluyen los fragmentos recuperados mediante la búsqueda semántica del índice.
- **Consulta del usuario:** Por último, se introduce la pregunta del usuario a la que debe responder el modelo.

Cabe destacar que el prompt utiliza una estructura delimitada por los tokens especiales < s >, [INST] y [/INST], que son interpretados por el LLM seleccionado como inicio y fin de la instrucción. Estos permiten separar la parte de la entrada (instrucción, historial, contexto y pregunta) del espacio donde el modelo debe generar su respuesta. De esta manera, el token < s > indica el comienzo de una nueva conversación, mientras que la etiqueta [INST] señala el inicio de la instrucción que el modelo debe procesar. Al cerrar con [/INST] se delimita el final del prompt y todo lo que venga después se entiende como la salida esperada del modelo.

En la siguiente figura se puede ver la estructura completa del prompt.

```
""<s>[INST]
  Eres un asistente legal especializado en la Ley CS3D (Directiva de
  Diligencia Debida en Materia de Sostenibilidad Empresarial) y
  derechos humanos/laborales.

### Instrucciones importantes:
  Responde únicamente a lo que el usuario ha pedido. No añadas
  información extra que no haya solicitado explícitamente.
  - Sigue siempre la intención del usuario. Si pide
  aclaraciones, ejemplos o más detalle, responde a eso de forma
  precisa, SIN repetir toda la respuesta anterior.
  - Usa el CONTEXTO solo si la consulta trata sobre la ley CS3D,
  otras normativas o conceptos jurídicos. Si no, ignora el contexto
  totalmente.-
  - Si la consulta es un saludo o despedida ("hola", "buenos días",
  "gracias", "ok", "vale"...), RESPONDE de forma amable y BREVE, sin
  añadir más información.
  - Usa lenguaje claro y accesible. Evita tecnicismos
  innecesarios y explicaciones complicadas.
  - Usa el historial de conversación para mantener una respuesta
  coherente y natural.

HISTORIAL DE CONVERSACIÓN:
{chat_history_text}

CONTEXTO:
{context}

Usuario: {user_question}
Asistente:
[/INST]""
```

Fig. 4.2. Plantilla del *prompt* generado

4.3. Validación del sistema RAG

Una vez se han implementado todas las fases dentro de este tipo de arquitectura, se ha llevado a cabo un proceso de validación para evaluar su rendimiento y utilidad. Esta validación se centra en el sistema al completo, desde la consulta del usuario hasta la generación de la respuesta final, e incluye tanto métricas automáticas como observaciones manuales.

4.3.1. Tiempos de respuesta

El sistema ha sido desplegado en una infraestructura cloud con soporte para GPU a través de la plataforma RunPod, lo que permite ofrecer el servicio desde cualquier navegador y dispositivo sin necesidad de conocimientos técnicos ni recursos avanzados de hardware. Para más detalles sobre la arquitectura y configuración del entorno de ejecución puede consultarse el **Capítulo 7: Infraestructura y servicios cloud**.

Se han registrado varios tiempos de respuesta desde que el usuario introduce una consulta en la interfaz hasta que recibe la respuesta, lo que incluye la vectorización, recuperación de documentos y generación por parte del modelo de lenguaje. Para esto se han seleccionado cuatro preguntas representativas sobre estas directivas, relacionadas con su definición, ámbito de aplicación, obligaciones y procedimientos.

De esta manera, cada pregunta se ha lanzado 3 veces de manera consecutiva al sistema, y se ha medido el tiempo desde la introducción de la consulta en el sistema hasta la recepción de la respuesta a través de la interfaz. Se han obtenido los siguientes resultados:

TABLA 4.2. TIEMPOS DE RESPUESTA DEL SISTEMA

Pregunta	Tiempo 1 (s)	Tiempo 2 (s)	Tiempo 3 (s)
¿Qué es la directiva CS3D?	9.17	9.25	8.87
¿A qué empresas se aplica la CS3D?	9.39	8.92	9.23
¿Qué debe incluir un plan de acción conforme a la CS3D?	10.68	11.24	11.06
¿Qué obligaciones de diligencia debida establece la CS3D en materia de derechos humanos?	12.81	11.45	11.68

El tiempo medio total del sistema considerando las 12 ejecuciones realizadas ha sido aproximadamente 10.3 segundos.

Estos resultados permiten confirmar que se cumple con el **requisito no funcional RNF-01 (Tiempo de respuesta)** establecido por el analista, que exige un tiempo máximo de 11 segundos desde el envío de la consulta por parte del usuario.

4.3.2. Evaluación de la recuperación de los fragmentos

Para continuar en la línea de evaluar la calidad del asistente desarrollado, se ha realizado un análisis manual de la capacidad de recuperación de los fragmentos más relevantes por parte del sistema.

Dentro de este contexto se ha utilizado la métrica **precisión@k** (*precision at k*), utilizando para ello un valor de $k = 3$ como medida sencilla de la calidad de la recuperación. Esta métrica es ampliamente utilizada para evaluar sistemas de recuperación de información y de recomendación, e indica la proporción de resultados relevantes que aparecen entre los k primeros elementos recuperados por el sistema.

En este caso concreto, **precisión@3** mide la proporción de fragmentos relevantes presentes entre los tres segmentos que ha recuperado el sistema por cada consulta realizada. Matemáticamente se define como:

$$\text{precisión@3} = \frac{\text{número total de fragmentos relevantes en el top - 3}}{3 \times \text{número de consultas evaluadas}}$$

De esta manera se realiza una pequeña evaluación del sistema de recuperación de forma aislada, valorando la capacidad de aportar información útil en la fase posterior de generación. Una baja precisión en la recuperación podría limitar la calidad de las respuestas producidas, independientemente de la capacidad del modelo de lenguaje para generar las respuestas.

Para este proceso se han utilizado las mismas cuatro consultas descritas en el apartado anterior, obteniendo los siguientes resultados observados en la tabla.

TABLA 4.3. EVALUACIÓN DE LA RECUPERACIÓN DE FRAGMENTOS Y PRECISIÓN@3

Consulta	Fragmentos relevantes	Respuesta adecuada	Comentario
¿Qué es la directiva CS3D?	1	Sí	La respuesta es adecuada pese a la baja relevancia de los fragmentos recuperados.
¿A qué empresas se aplica la CS3D?	0	Sí	La respuesta es adecuada pese a que no se recuperaron fragmentos relevantes. El modelo ha compensado correctamente.
¿Qué debe incluir un plan de acción conforme a la CS3D?	2	Sí	La respuesta es adecuada y corresponde bien con los fragmentos relevantes recuperados.
¿Qué obligaciones de diligencia debida establece la CS3D en materia de derechos humanos?	3	Sí	Respuesta completa y adecuada, alineada con los fragmentos recuperados.

Los resultados obtenidos muestran que la capacidad de recuperación del sistema RAG varía notablemente en función de la formulación de la consulta. Es por ello que la primera pregunta al ser tan general no permite al sistema recuperar fragmentos relevantes que definan de forma directa qué es la directiva. Los fragmentos obtenidos se centran en aspectos parciales o en detalles específicos de la normativa, lo que limita el valor de la precisión@3 en este caso. No obstante, el modelo de lenguaje generativo ha sido capaz de desarrollar una respuesta adecuada gracias a un equilibrio entre el conocimiento adquirido durante el entrenamiento, su capacidad de generalización y la configuración de los parámetros de generación, que permiten mantener un nivel controlado de creatividad en las respuestas.

Por otro lado, en consultas más concretas y orientadas a aspectos específicos de la directiva como es el caso de la cuarta pregunta, el sistema es capaz de recuperar fragmentos muy relevantes, lo que se traduce en un valor de precisión@3 elevado.

Estos resultados demuestran que existe una correlación entre la calidad de la recuperación de los fragmentos y la calidad de las respuestas generadas, cuanto más relevantes son los fragmentos recuperados, más precisa y completa tiende a ser la respuesta del sistema.

Para cuantificar la capacidad de recuperación se sustituyen los resultados en la fórmula anterior:

$$precisión@3 = \frac{6}{3 \times 4} = 0.50$$

Este valor indica aproximadamente la mitad de los fragmentos recuperados por el sistema han sido relevantes para las consultas evaluadas. Este resultado es coherente con la naturaleza de las consultas y con el dominio legal abordado, caracterizado por documentos extensos y fragmentos de contexto que pueden resultar muy específicos. Además, confirma la **importancia de seguir optimizando la fase de recuperación**, ya que una mayor precisión en esta etapa contribuye de manera directa a una mejora en la calidad de las respuestas generadas por el modelo de lenguaje.

4.3.3. Evaluación manual de casos

Para esta evaluación se han seleccionado las preguntas utilizadas en los apartados anteriores para determinar el tiempo medio de respuesta del sistema y la precisión de la recuperación. Con las respuestas del modelo a dichas consultas se ha realizado una evaluación manual de la calidad de las mismas. Se han tenido en cuenta los criterios:

- **Corrección:** Exactitud del contenido de la respuesta con respecto a la normativa.
- **Compleitud:** Cobertura de los aspectos relevantes de la pregunta realizada.
- **Claridad:** Facilidad de comprensión del resultado.
- **Errores:** Ausencia de información incorrecta.

El análisis ha mostrado que las respuestas generadas son correctas y claras. Aunque en algunas preguntas más complejas la completitud podría mejorarse, aspecto coherente con el diseño conversacional del asistente, no se han encontrado errores demasiado graves. Se muestran a continuación los diferentes casos:

Caso 1: ¿Qué es la directiva CS3D?

Respuesta generada:

“La Directiva CS3D (CS3D = Corporate Sustainability Due Diligence) es una normativa europea que regula la diligencia debida en materia de sostenibilidad empresarial. Esta directiva está diseñada para obligar a las empresas a evaluar y mitigar los impactos negativos que puedan tener sus actividades en áreas como el medioambiente, los derechos humanos y los derechos laborales. Esto incluye conocer quiénes son sus proveedores, cómo trabajan y cuál es su impacto en la cadena de suministro. El objetivo final es ayudar a crear condiciones favorables para que todas las empresas operen de manera sustentable y ética.”

Análisis:

- **Corrección:** La respuesta generada por el asistente legal es correcta. Describe de forma adecuada en qué consiste la directiva y menciona sus aspectos clave, como el medioambiente y los derechos humanos y laborales.
- **Compleitud:** La respuesta cubre los aspectos principales de la consulta. A pesar de que no menciona todos los detalles, como que la directiva impone obligaciones específicas a empresas de determinados tamaños o sectores, es suficiente información para una pregunta tan general.
- **Claridad:** Respuesta clara, bien redactada y comprensible.
- **Errores:** No se han detectado errores en la respuesta.

Caso 2: ¿A qué empresas se aplica la CS3D?

Respuesta generada:

“La Directiva de Diligencia Debida en Materia de Sostenibilidad Empresarial (CS3D) se aplica a todas aquellas empresas europeas que estén registradas en la UE y cuya actividad supere determinados umbrales de volumen de ventas o número de empleados. Esta directiva busca regular la diligencia debida que deben ejercitar las empresas para conocer y gestionar los impactos negativos que puedan generar en materia de sostenibilidad empresarial, incluyendo aspectos relativos a los derechos humanos y laborales.”

Análisis:

- **Corrección:** La respuesta es correcta en cuanto a contenido, la CS3D se aplica a empresas que superan ciertos umbrales y que operan dentro de la UE. Sin embargo, está cometiendo un error al no mencionar que no todas las empresas son europeas, también pueden estar sujetas a esta directiva empresas de otros países que tengan operaciones relevantes dentro del mercado europeo.
- **Compleitud:** La respuesta se puede considerar adecuada para el contexto conversacional. No especifica los umbrales concretos, pero esto es coherente con el enfoque de un asistente conversacional, donde se espera que el usuario pueda profundizar en detalles concretos mediante preguntas adicionales.
- **Claridad:** Respuesta clara y bien redactada, pero puede inducir a cierta confusión, dado que la expresión “*empresas europeas que estén registradas en la UE*” podría interpretarse como excluyente.
- **Errores:** No se han detectado errores factuales, a pesar del matiz descrito.

Caso 3: ¿Qué debe incluir un plan de acción conforme a la CS3D?

Respuesta generada:

“Un plan de acción conforme a la Ley CS3D debería incluir:

- *Una descripción del enfoque aplicado por la empresa a la diligencia debida, incluyendo un enfoque a largo plazo.*
- *La identificación de las palancas de descarbonización detectadas y las acciones clave previstas para alcanzar los objetivos de reducir las emisiones de carbono, incluyendo posibles cambios en la cartera de productos y servicios y la adopción de nuevas tecnologías.*
- *Explicación y cuantificación de las inversiones y la financiación necesarias para apoyar la ejecución del plan de transición para la mitigación del cambio climático.*
- *Descripción de cómo se evaluará la adecuación de los terceros comprobadores, siguiendo las directrices establecidas por la Comisión Europea y los Estados miembros.”*

Análisis:

- **Corrección:** El contenido de la respuesta es correcto. Los elementos mencionados están alineados con la CS3D, especialmente en lo relativo a sostenibilidad y cambio climático.
- **Compleitud:** La respuesta es incompleta. Se centra en gran medida en aspectos climáticos demasiado concretos, sin abordar otras áreas como la prevención y mitigación de impactos en derechos humanos, condiciones laborales, procesos de seguimientos, etc. Debe tenerse en cuenta que la pregunta formulada abarca un conjunto de aspectos demasiado amplio, y sería necesario ofrecer un contenido mucho más extenso.
- **Claridad:** Respuesta clara y bien estructurada en cuanto a la parte que cubre.
- **Errores:** No se han detectado errores.

Caso 4: ¿ Qué obligaciones de diligencia debida establece la CS3D en materia de derechos humanos?

Respuesta generada:

“La Directiva CS3D establece que las empresas deben ejercer la diligencia debida en materia de derechos humanos al identificar, prevenir y mitigar los efectos negativos de sus operaciones sobre los derechos humanos. Debe hacerlo de acuerdo con los Principios Rectores de las Naciones Unidas, los cuales requieren que las empresas eviten violar los derechos humanos y aborden los efectos negativos que han causado, contribuyeron o están relacionados con sus propias operaciones. También deben dar cuenta de cómo abordan estos efectos negativos. En caso de que los daños y perjuicios sean ocasionados únicamente por socios comerciales que formen parte de las cadenas de actividades de las empresas (relación directa), estas deben garantizar que las víctimas tienen derecho a la plena indemnización por los daños y perjuicios sufridos, de conformidad con el Derecho nacional y en concordancia con este principio común.”

Análisis:

- **Corrección:** La respuesta es correcta en cuanto a contenido. Se describe adecuadamente lo exigido por la CS3D, también es correcto que estas obligaciones se alinean con los Principios Rectores de la ONU, y que las empresas deben tomar medidas y ofrecer mecanismos de reparación cuando corresponda.
- **Compleitud:** En el contexto de un asistente conversacional, la respuesta es suficientemente completa como punto de partida para el usuario.
- **Claridad:** La respuesta es clara y comprensible, aunque algunas frases pueden resultar algo densas y podrían beneficiarse de una redacción más sencilla.
- **Errores:** No se han detectado errores.

5. MODELO DE LENGUAJE

En la siguiente sección se describe el modelo de lenguaje que ha sido utilizado para la generación de respuestas por parte del asistente legal, así como los ajustes realizados para su funcionamiento e integración con el sistema RAG del que se ha hablado en el capítulo anterior.

También se detalla el proceso de *fine-tuning* realizado sobre el modelo, con el fin de adaptar el modelo al lenguaje típico de documentos legales y a requisitos dentro de este marco regulatorio.

5.1. Ajustes y configuración del modelo

Como ya se ha mencionado en otros capítulos, se ha utilizado un modelo preentrenado de Hugging Face conocido como *Mistral-7B-Instruct-v0.3* [30]. Este modelo ya ha sido previamente ajustado para seguir las instrucciones que se le indiquen en lenguaje natural.

En los siguientes apartados se describe el proceso seguido para la carga del modelo y los ajustes realizados para adaptarlo a la funcionalidad del sistema.

5.1.1. Carga del modelo

Con el objetivo de reducir la carga computacional y hacer viable su ejecución en entornos con recursos limitados, como puede ser un ordenador portátil de uso personal, se ha aplicado una cuantización de 4 bits sobre el modelo. La cuantización es una técnica de optimización que consiste en reducir la precisión numérica con la que se van a representar los pesos de un modelo. En este contexto, cuando se habla de los pesos de un modelo se hace referencia a los valores numéricos que definen el conocimiento del modelo. Por ejemplo, cuando se entrena un LLM en este caso Mistral, para resolver una tarea como puede ser predecir la siguiente palabra, lo que hace es ajustar estos parámetros internos conocidos como pesos. El valor de estos pesos son los que determinan cómo va a responder el modelo ante una entrada.

De esta manera, el sistema carga el modelo Mistral 7B con una precisión de 4 bits en vez de los 16 bits de precisión que utiliza por defecto. Esto va a suponer un gran ahorro de memoria, tiempo y recursos en el sistema, pero también presenta ciertos inconvenientes. Con esta cuantización se va a producir una pequeña pérdida de precisión, pero esto queda compensado por el uso de un prompt bien estructurado que guía el comportamiento del modelo y el enfoque RAG que proporciona un contexto más controlado.

Además se ha utilizado la técnica *nf4*. A diferencia de la cuantización uniforme que divide el rango de valores en un rango equidistante, *nf4* emplea una distribución no lineal diseñada para asignar con una mayor precisión los valores cuantizados en los rangos donde realmente se concentran los pesos originales del modelo.

5.1.2. Tokenización y generación

Una vez se ha construido el prompt (véase la sección 4.2.5), se realiza la *tokenización* del mismo mediante el *tokenizer* correspondiente. La tokenización consiste en convertir un texto o una cadena de caracteres, en este caso el prompt, en una secuencia de tokens, es decir, una serie de números enteros que representan unidades mínimas de significado, ya sean palabras completas, fragmentos de palabras o símbolos.

Esta transformación es necesaria porque el modelo de lenguaje no opera directamente sobre la cadena de texto, sino sobre esas representaciones numéricas que ha aprendido a interpretar durante su entrenamiento.

Con el prompt ya tokenizado se procede a la generación de la respuesta. Al iniciar este proceso de generación se pueden configurar una serie de parámetros, que han sido ajustados para maximizar la coherencia, calidad y estilo de las respuestas:

- **max_new_tokens = 512**
Va a determinar el número máximo de tokens que el modelo puede generar como respuesta, es decir, su longitud en tokens. Se ha fijado en 512 para garantizar respuestas suficientemente desarrolladas, teniendo en cuenta la complejidad de explicaciones legales, y sin superar el límite de tokens del modelo.
- **do_sample = True**
Este otro parámetro indica que el modelo debe realizar muestreo aleatorio, es decir, va a elegir aleatoriamente entre los tokens más probables en función de su distribución de probabilidad en vez de elegir siempre el token más probable. De esta manera se evitan respuestas repetitivas.
- **temperature = 0.3**
Controla la aleatoriedad en la selección de tokens. Valores altos generan respuestas más creativas pero menos precisas, mientras que valores bajos van a priorizar a precisión. Se ha fijado en 0.3 para reducir la aleatoriedad y conseguir respuestas centradas en el contexto legal proporcionado.
- **top_p = 0.7**
Este parámetro define un umbral de probabilidad acumulada, de manera que el modelo solo elige aquellos tokens cuyo conjunto suma al menos el 70% de probabilidad. Este valor limita el rango de opciones a las más probables para favorecer la generación de respuestas más precisas y menos dispersas.
- **top_k = 15**
Este parámetro determina que el modelo solo considera los 15 tokens más probables, reduciendo la exploración de palabras inusuales y enfocando la generación en un vocabulario relevante y frecuente en el dominio legal.

- **repetition_penalty = 1.2**

Este parámetro penaliza la repetición de los mismos tokens. Se ha intentado encontrar un punto de equilibrio entre un valor demasiado grande que limite la fluidez y un valor demasiado pequeño que de lugar a respuestas redundantes.

- **eos_token_id = tokenizer_mistral.eos_token_id**

Indica al modelo cuándo debe detener la generación, utilizando para ellos el token de fin de secuencia, que en el caso de Mistral será <s/>.

Tras la generación, se eliminan del texto resultante los tokens especiales (< s >, [INST] y [/INST]) y se extrae únicamente la parte correspondiente a la respuesta generada por el LLM, basándose en la última ocurrencia del marcador “Asistente:”.

5.2. *Fine-tuning* del modelo

El proceso de fine-tuning consiste en ajustar un modelo de lenguaje que ya ha sido entrenado previamente a un dominio en específico o a un estilo concreto de respuestas, utilizando para ello un conjunto de ejemplos personalizados. En este sistema en concreto, el objetivo principal de este procedimiento es mejorar la adaptación del sistema a los temas legales que se tratan, concretamente la normativa CS3D, el reglamento EUDR y aquellas otras regulaciones relacionadas con el contexto que se está tratando.

5.2.1. Preparación del modelo base

Para llevar a cabo este proceso, se ha partido del modelo Mistral 7B Instruct en su última versión, al que como ya se ha mencionado previamente, se le ha aplicado una cuantización a 4 bits. Esta configuración no sólo se ha utilizado durante la inferencia, sino que también durante el entrenamiento, reduciendo el consumo de tiempo, memoria y recursos computacionales.

Una vez cargado el modelo base con la cuantización, se ha preparado para el entrenamiento con **LoRA** (*Low-Rank Adaptation*). Esta técnica permite añadir una serie de parámetros entrenables (matrices) sobre capas del mecanismo de atención, estos son:

- **q_proj** (*query projection*): Define las consultas que el modelo va a utilizar para decidir a qué otros tokens debe prestar atención. Representa lo que un token busca dentro del resto de la secuencia.
- **k_proj** (*key projection*): Representa el contenido semántico que puede ofrecer a otras consultas. Actúa como la clave que otros tokens consultan.
- **v_proj** (*value projection*): Contenido que se transfiere entre tokens cuando se decide que uno debe atender a otro. Es la información útil que pasa al siguiente paso.

- *o_proj (output projection)*: Se encarga de transformar la salida del mecanismo de atención en una representación vectorial adecuada que pueda ser utilizada por las siguientes capas del modelo.

Gracias a esta técnica los pesos originales del modelo quedan congelados durante el entrenamiento, y solo se modifican estos módulos añadidos que son mucho más pequeños.

Además de lo anterior, hay una serie de parámetros que se pueden configurar con el entrenamiento con LoRA, como es el caso de la dimensión interna de las matrices *r*, cuanto más pequeño sea se entrena un menor número de parámetros. En este caso se ha configurado este valor como 8 porque ofrece un buen equilibrio entre eficiencia, reduciendo el número de parámetros entrenables, y capacidad de adaptación sin comprometer el rendimiento del modelo.

También se ha fijado el parámetro *lora_alpha* ajustado a 16, lo que permite amplificar el efecto de los adaptadores LoRA sobre la salida del modelo, debido a que las matrices definidas son demasiado pequeñas y no tendrían impacto suficiente sobre los pesos originales del modelo. Por otro lado se ha aplicado un *lora_dropout* de 0.05, que desactiva aleatoriamente un 5% de los ajustes durante el fine-tuning, evitando el sobreajuste y ayudando al modelo a generalizar.

5.2.2. Preparación del conjunto de datos

Otro paso importante dentro del fine-tuning es realizar la selección de los datos que van a ser utilizados para entrenar el modelo. En concreto, el conjunto de datos utilizados contiene ejemplos en formato pregunta-respuesta en un archivo JSON.

Para cada entrada en dicho archivo se construye dinámicamente un prompt completo mediante el *pipeline RAG* definido previamente. Por tanto, se entrenará el modelo con los mismos prompts que se generarían en caso de que un usuario realizase esas consultas, y durante dicho entrenamiento el modelo aprende a predecir la respuesta que sigue al prompt.

Cabe destacar que, si se decidiera mejorar el sistema, una de las posibles mejoras sería entrenar el modelo con entradas del tipo conversacional, en lugar de interacciones aisladas del tipo pregunta-respuesta. Esto permitiría mejorar la continuidad y coherencia en respuestas más largas, aunque también implicaría un mayor volumen de datos, y por tanto, una carga computacional mayor.

El *dataset* utilizado para el fine-tuning se encuentra incluido en el **Anexo C** en el formato JSON.

5.2.3. Entrenamiento

Para el proceso del entrenamiento, los datos se han dividido en dos conjuntos, uno de entrenamiento y otro de validación. En concreto, se han seleccionado 3 entradas aleatorias para validación y 15 para entrenamiento, sobre un total de 18 ejemplo disponibles. Esta división permite al modelo aprender a partir de los datos del conjunto de entrenamiento y evaluar su rendimiento sobre el conjunto de test, que son datos con los que no ha entrenado y no conoce. Por tanto, durante este proceso de entrenamiento, el modelo irá ajustando sus parámetros utilizando únicamente el conjunto destinado para ello, y cada cierto número de pasos (*eval_steps*), se calcula su rendimiento sobre el conjunto de validación mediante una métrica de pérdida (*loss*), que es una medida numérica que cuantifica el error entre lo que el modelo ha generado y lo que debería haber generado (la respuesta del *dataset*).

Con esta técnica se pueden detectar signos de sobreajuste, y gracias a la técnica de *early_stopping* se puede detener el entrenamiento si la pérdida en el conjunto de validación deja de mejorar tras un número de iteraciones específico. Aunque el número total de ejemplos es bastante reducido debido a las restricciones computacionales del entorno en el que se está desarrollado el proyecto, esta estrategia permite obtener un ajuste razonable y controlado del modelo.

El entrenamiento ha requerido el ajuste de diversas configuraciones que ayudan a monitorizar el proceso completo. En particular, se ha activado el guardado periódico cada 10 pasos de entrenamiento, lo que permite almacenar versiones intermedias a lo largo del mismo. Para evitar un uso excesivo del almacenamiento, también se ha limitado el número de versiones almacenadas a 2, y al final del entrenamiento siempre se conservará el mejor modelo entrenado.

En paralelo, se ha definido una estrategia de *logging* que permite registrar métricas clave cada dos pasos. Esta información resulta útil para realizar un seguimiento de la pérdida entre los modelos generados.

En cuanto a los hiperparámetros del entrenamiento:

- **per_device_train_batch_size = 1**
Determina el número de ejemplos procesados en cada paso del entrenamiento. Se ha fijado a 1 debido a limitaciones de memoria en el entorno de ejecución.
- **gradient_accumulation_steps = 4**
Este hiperparámetro representa el número de pasos sobre los que se acumulan los gradientes antes de actualizar los pesos. Este valor simula un *batch* (paso de entrenamiento) de 4, estabilizando el entrenamiento sin aumentar el uso de memoria. Es decir, el sistema espera a tener 4 ejemplos procesados antes de actualizar los pesos.

- **adam_epsilon = 1e-8**
Valor utilizado para evitar divisiones por cero o inestabilidades numéricas durante cálculos internos del optimizador *AdamW*, este valor se suma al denominador de las operaciones. Se ha seleccionado el valor estándar y recomendado en la mayor parte de implementaciones.
- **weight_decay = 0.01**
Personalización aplicada a los pesos del modelo para reducir el sobreajuste. Trata de evitar que los valores de los pesos se descontrolen para conseguir una representación más generalizable.
- **learning_rate = 5e-5**
Representa la tasa inicial de aprendizaje, es decir, controla cuánto cambian los pesos en cada actualización. Se ha elegido un valor moderado que permite un ajuste progresivo sin cambios bruscos en el comportamiento del modelo.
- **lr_scheduler_type = "cosine"**
Estrategia que ajusta la tasa de aprendizaje durante el entrenamiento. Este tipo de técnica reduce gradualmente la tasa de aprendizaje favoreciendo una convergencia suave del modelo en las últimas fases.
- **num_train_epochs = 20**
Es el número máximo de recorridos completos sobre el conjunto de datos de entrenamiento. Aunque se ha seleccionado un número bastante alto, el uso de *early stopping* garantiza que el modelo no entrene más de lo necesario, deteniéndose cuando la mejora deje de ser significativa.

Los hiperparámetros descritos se han ido ajustando de forma iterativa, combinando pruebas preliminares y la observación directa del comportamiento del modelo a través de los logs de la pérdida y estabilidad del gradiente. Esta estrategia ha permitido refinar el rendimiento sin recurrir a una búsqueda exhaustiva, lo cual resultaría inviable dada la limitación de recursos computacionales.

Los resultados obtenidos en el entrenamiento que se pueden consultar en el **Anexo D** de este proyecto muestran una evolución progresiva y estable de la pérdida durante las primeras épocas. En concreto, se partió de una pérdida de entrenamiento de aproximadamente 2.36 en los primeros pasos, reduciendo de forma continua hasta alcanzar valores de 0.8 en la época 15. Del mismo modo, *eval_loss* pasó de 1.53 en la época 2.5 a 0.85 al finalizar la época número 15, lo que indica una mejora sostenida.

Además, el valor de la norma del gradiente también mostró una evolución decreciente y estable, pasando de 25.6 en los primeros pasos a valores comprendidos entre 1.0 y 1.5 en las últimas época, un rango óptimo en entrenamientos con LoRA y modelos cuantizados. Esto es un indicador de estabilidad y de que el modelo ha convergido de forma controlada.

5.2.4. Fusión del modelo

Se finaliza este proceso con la fusión del modelo entrenado con LoRA con el modelo base Mistral 7B Instruct. Al entrenar con esta técnica, el modelo base no se entrena directamente, y es por ello que es necesario fusionar los pesos adaptados con el modelo base, generando así un modelo único y listo para la inferencia.

Con esta fusión se puede utilizar el modelo directamente, sin necesidad de cargar los adaptadores de LoRA por separado, simplificando así el despliegue y reduciendo los requisitos del entorno de ejecución.

6. INTERFAZ DE USUARIO

En el siguiente capítulo se describe el proceso que se ha seguido en el desarrollo e implementación de la interfaz de usuario para el asistente legal, cuya funcionalidad es proporcionar a los usuarios finales un acceso fácil e intuitivo al sistema. Esta actúa como punto de entrada a las funcionalidades del asistente, permitiendo formular preguntas y recibir las respuestas entre otras acciones.

A lo largo de los siguientes apartados se analizan tanto los aspectos visuales y estructurales como las decisiones tomadas durante todo el desarrollo. También se expone el proceso de prototipado previo a la implementación.

6.1. Enfoque de diseño

El principal objetivo del diseño de la interfaz de usuario ha sido conseguir una experiencia sencilla, funcional, accesible e intuitiva, especialmente enfocada en usuarios no técnicos que necesiten utilizar la aplicación para consultar aspectos legales. Como ya se ha mencionado en capítulos anteriores, para la construcción de la interfaz se ha utilizado **Streamlit** [32] una herramienta que permite un desarrollo rápido de aplicaciones web a través del lenguaje de programación Python. Esto ha facilitado la integración directa de la interfaz con el modelo de lenguaje y el sistema RAG.

Dado que Streamlit presenta ciertas limitaciones, en cuanto a personalización visual y estructura, el diseño ha seguido una estética estandarizada y minimalista, priorizando siempre la claridad en los flujos de interacción. A pesar de ello, se han desarrollado prototipos visuales en **Figma** [33], permitiendo definir desde el inicio del proyecto una estructura clara de los componentes y funcionalidades del sistema.

Durante el proceso de diseño se han tenido en cuenta tanto los requisitos funcionales del sistema, como los no funcionales. En este sentido, la interfaz se ha diseñado de forma coherente con los objetivos y necesidades planteadas, ya que su estructura y comportamiento dependen directamente de las funcionalidades que se esperan del sistema inteligente.

6.2. Prototipo inicial

El objetivo principal de los prototipos iniciales era validar visualmente el funcionamiento del asistente antes de su implementación completa en Streamlit. Para esto, utilizando la herramienta Figma, se representó de forma estática la interfaz y se evaluaron aspectos claves como el diseño visual, la organización de los diferentes elementos que implementaban funcionalidades y la experiencia de usuario, tanto en modo claro como en modo oscuro. Este prototipo sirvió como guía de referencia para la posterior implementación.

A continuación se presentan los prototipos diseñados. Se ha creado una versión de la interfaz en el estado inicial (sin mensajes ni interacción) para cada uno de los modos que se han implementado. Se pueden visualizar en las siguientes figuras:




Fig. 6.1. Prototipo interfaz modo claro inicial




Fig. 6.2. Prototipo interfaz modo oscuro inicial

Por otro lado, se diseñaron otros dos prototipos que incluían interacciones, de manera que se agregaría el *scroll* en la parte del chat y los botones para valorar la respuesta generada por el asistente. A continuación se muestran las figuras con los prototipos mencionados.




Fig. 6.3. Prototipo interfaz con chat modo claro

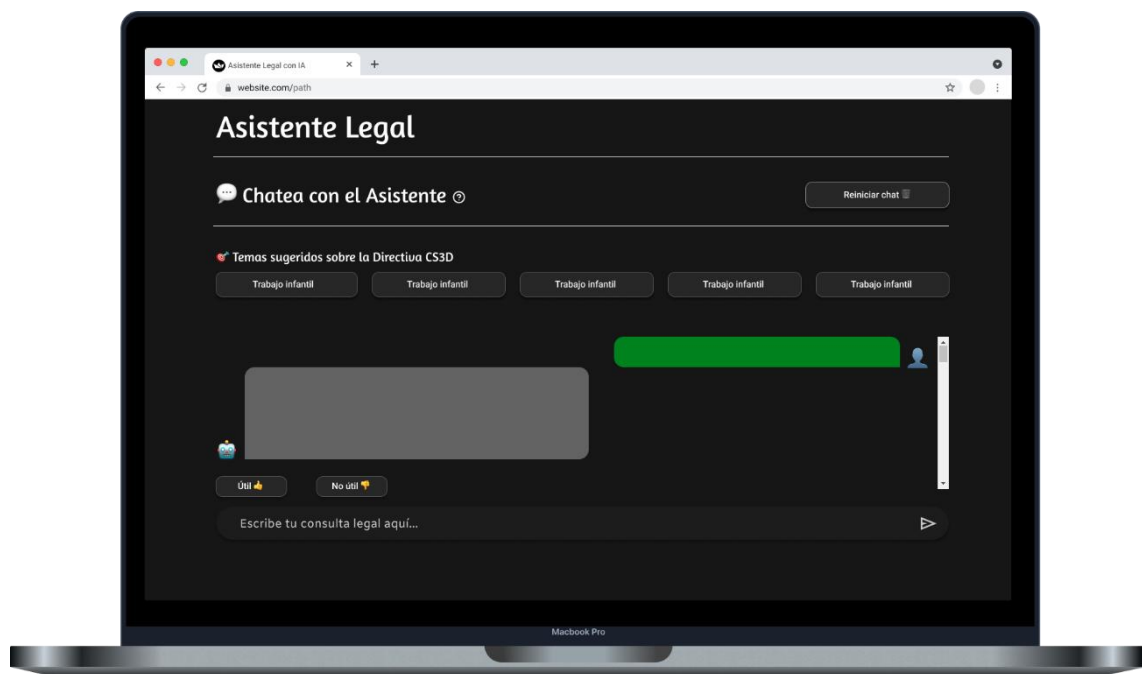


Fig. 6.4. Prototipo interfaz con chat modo oscuro

6.3. Estructura y componentes de la aplicación

La interfaz de usuario se ha diseñado siguiendo un esquema vertical y simplificado, de acorde con las restricciones de Streamlit y los flujos de interacción que se pueden esperar de un asistente conversacional, tratando de cumplir con los estándares seguidos en cualquier tipo de aplicación de mensajería. A continuación se describen los principales componentes que conforman la interfaz:

- **Entrada de texto (parte inferior de la pantalla):** Este área permite al usuario realizar sus consultas. El diseño busca emular el comportamiento natural de una conversación mostrando siempre la entrada para facilitar la interacción con el sistema.
- **Zona de conversación (área de mensajes con *scroll*):** En la parte central de la interfaz se encuentra el historial de conversación entre el usuario y asistente. Esta zona permite hacer scroll vertical para revisar respuestas anteriores. Los mensajes del usuario y del asistente se diferencian visualmente, siguiendo un patrón de burbujas.
- **Botón para reiniciar el chat:** Situado de forma visible en la parte superior de la interfaz, permite reiniciar la conversación y eliminar todos los mensajes anteriores.
- **Botones de sugerencias:** En la parte superior de la pantalla se han implementado una serie de botones que contienen sugerencias de temas relacionados con la normativa. Al seleccionar alguno de ellos, automáticamente se realiza en el chat una consulta relacionada con dicha temática.
- **Botones para la valoración de las respuestas generadas:** Debajo de la burbuja del mensaje de respuesta por parte del asistente, aparecen dos botones que sirven para valorar si la respuesta generada por el modelo es útil o no.

La interfaz ha sido diseñada con el objetivo de ser intuitiva, accesible y funcional. Cada componente ha sido pensado para guiar al usuario de forma natural durante la interacción, permitiéndole realizar consultas y seguir el hilo de la conversación sin complicaciones. Se ha buscado también una interfaz minimalista, con sólo lo necesario para realizar las principales acciones que ofrece el asistente, evitando que los usuarios se sientan sobrepasados por elementos innecesarios y facilitando al máximo la interacción. Con esto se pretende incentivar su uso habitual, haciendo que la herramienta resulte accesible, cómoda y rápida de utilizar.

6.4. Prueba de usabilidad

A pesar de que el público objetivo final del asistente legal que se está desarrollando está compuesto por trabajadores de pequeñas empresas que buscan facilitar el cumplimiento de las normativas, se ha considerado interesante y beneficioso realizar una pequeña prueba de usabilidad con usuarios externos al perfil objetivo, con el fin de obtener *feedback* específico sobre la interfaz de usuario y la experiencia de uso en general.

El objetivo principal, por tanto, será evaluar la usabilidad de la aplicación y la comprensión de la estructura de la interfaz desarrollada, identificando posibles mejoras en la navegación, diseño visual y presentación de las respuestas.

6.4.1. Metodología

Se ha realizado una prueba exploratoria no estructurada, sin un protocolo formal definido y orientada principalmente a recoger impresiones generales sobre la usabilidad de la interfaz y la experiencia del usuario. La prueba se ha centrado exclusivamente en aspectos de usabilidad, **sin evaluar en esta fase la validez o calidad de las respuestas.**

6.4.2. Participantes

En esta prueba han participado cinco usuarios, seleccionados de manera informal. Ninguno de ellos pertenece al público objetivo final de la aplicación. El perfil de los participantes es variado, incluyendo dos estudiantes de ingeniería, un estudiante de derecho y dos usuarios sin formación específica en el ámbito jurídico ni técnico.

Antes de la prueba, a todos los participantes se les proporcionó una breve explicación introductoria sobre el propósito de la aplicación y el contexto general de las normativas, para que pudieran formular consultas con una mínima comprensión.

6.4.3. Tareas planteadas

A cada uno de los participantes mencionados en el apartado anterior, se les propuso llevar a cabo una serie de tareas básicas:

1. Acceder a la aplicación y pasar a la interfaz principal aceptando el mensaje inicial sobre el uso de datos y condiciones del servicio.
2. Mantener una breve conversación con el asistente, intentando formular al menos dos mensajes consecutivos.
3. Utilizar la funcionalidad de borrar el chat.
4. Formular una pregunta usando los temas sugeridos en la interfaz.
5. Utilizar la funcionalidad de proporcionar feedback.

6.4.4. Resultados

Después de que los usuarios realizaran las tareas planteadas, se llevó a cabo una pequeña entrevista en la que se obtuvieron las siguientes conclusiones:

- La estructura conversacional de la interfaz desarrollada fue valorada de forma positiva por todos los participantes, quienes destacaron que el diseño les recordaba a aplicaciones de chat habituales. Esto facilitó la interacción con el asistente y contribuyó a una experiencia de usuario intuitiva desde el primer momento.
- Todos los usuarios lograron mantener al menos dos intercambios de mensajes con el asistente sin incidencias. Algunos indicaron que el poder interactuar de manera fluida les ayudaba a explorar mejor los temas.
- La función de “Reiniciar chat” fue utilizada correctamente por todos los usuarios. No se reportaron dificultades en su localización ni en su uso.
- La funcionalidad de sugerencia de temas fue empleada sin dificultad. Varios participantes comentaron que esta opción les resultaba especialmente útil dado que no tenían un conocimiento profundo de las normativas, sirviendo como punto de partida para sus consultas.
- La opción para proporcionar feedback (útil / no útil) fue utilizada en todas las interacciones. Los usuarios indicaron que su funcionamiento era claro y fácil de comprender.

6.4.5. Observaciones generales

Los comentarios generales recogidos durante la prueba incluyen las observaciones mencionadas a continuación:

- El tiempo de respuesta del asistente fue percibido como adecuado, sin generar esperas excesivas.
- En las respuestas más largas, se agradecía el uso de listas para facilitar la comprensión.
- Los participantes destacaron que, a pesar de no conocer las normativas, el propio diálogo con el asistente les permitió ir entendiendo mejor los temas tratados.
- Se propuso incluir un pequeño texto inicial que explique al usuario qué tipo de preguntas se pueden realizar o qué esperar del asistente.
- En general, la experiencia de uso de la interfaz fue valorada como satisfactoria, clara e intuitiva.

7. INFRAESTRUCTURA Y SERVICIOS CLOUD

A lo largo de la siguiente sección se describen los recursos y servicios cloud utilizados para la ejecución del asistente legal, incluyendo la infraestructura elegida, la configuración del entorno de ejecución, la organización del proyecto dentro de la plataforma y una serie de consideraciones de seguridad.

El asistente legal se ha desplegado y ejecutado en la nube utilizando para ello la plataforma RunPod [34], ya introducida previamente en la sección de herramientas del proyecto, y que permite lanzar entornos de desarrollo personalizados con acceso a GPU.

En un primer momento, el uso de la plataforma RunPod se planteó únicamente como una forma de hacer accesible el asistente legal desde cualquier dispositivo, permitiendo exponer la aplicación mediante una interfaz web sin depender del entorno local. Además, se buscaba mejorar ligeramente la velocidad de respuesta del modelo al ejecutarlo en una máquina con GPU. Sin embargo, durante el desarrollo del sistema se identificó que el uso de este entorno ofrecía también la posibilidad de realizar un proceso de fine-tuning más avanzado, gracias a unos recursos computacionales considerablemente superiores a los disponibles en el equipo personal. Esto permitió aprovechar RunPod no solo como entorno de despliegue, sino también como entorno de entrenamiento eficiente para ajustar el modelo de lenguaje a las necesidades específicas del asistente.

7.1. Configuración del *pod*

En **RunPod** los *pods* hacen referencia a las instancias virtuales de cómputo disponibles. Cada pod actúa como un contenedor aislado que tiene una serie de recursos como pueden ser CPU, GPU, memoria y almacenamiento. Estos permiten ejecutar *scripts* o aplicaciones de manera continua, y facilitan el despliegue de modelos de lenguaje de gran tamaño sin depender de recursos locales, proporcionando flexibilidad, escalabilidad y acceso directo a hardware especializado como unidades de procesamiento gráfico que aceleran este proceso.

Para el asistente legal, se ha desplegado una instancia en la modalidad *Community Cloud*, que permite ejecutar el sistema sobre recursos comunitarios GPU con un coste reducido. Aunque esta opción puede implicar una menor persistencia de los datos y pequeños riesgos relacionados con interrupciones, resulta adecuada para el desarrollo y prueba de proyectos personales como el presente sistema inteligente, que no requiere de una alta disponibilidad.

En cuanto a las características técnicas del pod seleccionado, este cuenta con una GPU NVIDIA RTX A4000, 16 núcleos virtuales de CPU y 54 GB de memoria RAM. La GPU se encarga del procesamiento paralelo requerido para la inferencia del modelo de lenguaje, lo que permite generar respuestas de forma eficiente y con tiempos de espera reducidos. Por otro lado, las 16 vCPU proporcionan suficiente capacidad para el resto de las tareas auxiliares, como gestionar el servidor, procesar las entradas y la ejecución del código de recuperación. La memoria RAM disponible permite cargar en memoria los componentes necesarios sin cuellos de botella, incluso al trabajar con LLMs.

Dentro de la configuración del *pod*, cabe destacar la imagen base utilizada, que es *pytorch:2.1.0-py3.10-cuda11.8.0-devel-ubuntu22.04*. Esta imagen incluye un entorno de desarrollo con Python 3.10, soporte para CUDA 11.8 (para la gestión de la GPU) y Pytorch 2.1.0 preinstalado.

Por último, se ha habilitado el puerto HTTP 5000 para exponer la aplicación desarrollada con Streamlit, lo que permite acceder a la interfaz del asistente legal desde el navegador mientras el pod esté en ejecución.

7.2. Estructura del proyecto

Dentro del entorno proporcionado por RunPod, el almacenamiento se organiza en dos niveles principales. Por un lado se encuentra la carpeta */workspace*, que se corresponde con la memoria persistente asignada al *pod*. Esto quiere decir que aunque se detenga el entorno o se reinicie, todo lo que se guarde en esa ruta se conservará. Esto lo convierte en el sitio idóneo para almacenar el código fuente, los modelos entrenados, conjuntos de datos o cualquier otro archivo que deba almacenarse de manera persistente. Por otro lado, el resto del sistema de archivos del contenedor es volátil, y por lo tanto se elimina automáticamente al detener el *pod*.

Para garantizar un entorno de ejecución de la aplicación limpio, controlado y reproducible, se ha creado un entorno virtual de Python específico para el asistente legal. Esta técnica es habitual en el desarrollo de aplicaciones en la nube, ya que permite aislar las dependencias necesarias del sistema y evitar posibles conflictos con otras versiones o paquetes instalados en la imagen base seleccionada para el *pod*. Además, esto facilita la portabilidad del proyecto y asegura que todas las librerías utilizadas sean compatibles.

Dado que el volumen de */workspace* es limitado (20GB) y está destinado a almacenar únicamente los elementos persistentes del proyecto, se ha optado por ubicar el entorno virtual de Python fuera de esta ruta, concretamente en *mnt/venv/*. Esta decisión ha permitido optimizar el uso del espacio disponible, evitando que las dependencias que pueden requerir varios gigabytes interfieran con el almacenamiento de otros elementos clave dentro del sistema como el código fuente o los modelos. De la misma manera, se mejora el rendimiento general del sistema al reducir la presión sobre el volumen persistente durante la ejecución.

7.3. Ejecución y puesta en marcha

Con el fin de facilitar la ejecución del sistema inteligente dentro del entorno de ejecución, se ha desarrollado un *script* de arranque denominado `start.sh`, que se encarga de preparar todo el entorno virtual en caso de que no se haya generado ya y lanzar la aplicación. Este enfoque evita tener que ejecutar de forma manual una serie de comandos cada vez que se quiera iniciar el *pod*, y garantiza la misma configuración en cada sesión. El *script* realiza de manera secuencial las siguientes acciones:

- **Creación y activación del entorno virtual:** Comprueba si ya existe el entorno virtual en la ruta indicada, y en caso de que no, lo genera.
- **Instalación de dependencias:** Realiza la instalación de todas las librerías y dependencias necesarias para el funcionamiento de la aplicación. Se desactiva la opción de almacenamiento en caché evitando un uso innecesario de memoria.
- **Lanzamiento del asistente legal:** Finalmente el *script* lanza la aplicación desarrollada en Streamlit en el puerto 5000, que es el que se había expuesto en la configuración del *pod*. Durante esta acción se deshabilita CORS para evitar restricciones de acceso al servidor, dado que la aplicación no se expone públicamente ni recibe peticiones de terceros. Además, la ejecución se realiza mediante *nohup* y con un `'&'` final, que permite mantener el proceso ejecutándose en segundo plano incluso si se cierra la terminal.

En caso de querer detener la aplicación, basta con identificar el proceso correspondiente y terminarlo manualmente mediante el comando *kill*.

```
#!/bin/bash

VENV_DIR="/mnt/venv"

echo "🔧 Creando entorno virtual en $VENV_DIR..."
python3 -m venv "$VENV_DIR"
source "$VENV_DIR/bin/activate"

echo "📦 Instalando dependencias del proyecto..."
pip install --no-cache-dir -r requirements.txt

echo "🚀 Lanzando el asistente legal en el puerto 5000..."

export STREAMLIT_BROWSER_GATHER_USAGE_STATS=false

nohup streamlit run src/main.py \
  --server.port 5000 \
  --server.address 0.0.0.0 \
  --server.enableCORS false \
  --server.headless true > streamlit.log 2>&1 &
```

Fig. 7.1. Script de arranque `start.sh`

7.4. Consideraciones de seguridad

Ya se ha mencionado que la infraestructura desplegada se ejecuta en un pod accesible a través de un servicio HTTP en el puerto 5000, utilizando un dominio gestionado por la plataforma RunPod.

Cabe destacar que actualmente el servicio se ejecuta en un entorno de desarrollo controlado, accesible solo por la desarrolladora del proyecto. Sin embargo, debido a que el tráfico HTTP no proporciona cifrado, es recomendable que en un entorno de producción se implemente HTTPS con el principal objetivo de proteger la confidencialidad de los datos intercambiados entre el usuario y el sistema. Adicionalmente, la plataforma de despliegue RunPod declara que cumple con el Reglamento General de Protección de Datos y otros estándares de seguridad, proporcionando un entorno que permite realizar una ejecución segura de los modelos de inteligencia artificial sin persistencia no autorizada de datos.

Además el sistema realiza llamadas a servicios externos, en este caso Pinecone para la recuperación semántica y Hugging Face para utilizar los modelos de vectorización y generación de las respuestas, utilizando para ello sus respectivas APIs. Estas interacciones requieren de un proceso de autenticación a través de claves, gestionadas mediante un archivo de configuración. A pesar de que este método resulta adecuado en un entorno de desarrollo como el de este proyecto, en un despliegue productivo sería preferible utilizar un gestor de secretos, una herramienta que sirve para guardar y proteger este tipo de información. De esta manera se garantizaría una mayor protección del contenido del archivo de configuración mencionado.

Por último, las interacciones de los usuarios se registran localmente en un archivo CSV, que actualmente no incorpora cifrado. Esta solución es suficiente en el contexto experimental y de desarrollo del proyecto, pero en caso de que se escale a un entorno productivo sería necesario cifrar estos datos y aplicar controles de acceso a los mismos, para garantizar su privacidad y seguridad.

8. MARCO REGULADOR

Dentro del desarrollo del asistente legal basado en inteligencia artificial no solo se deben tener en cuenta los aspectos más técnicos, sino que también se debe considerar el cumplimiento de una serie de normativas vigentes y los principios éticos que garanticen un uso responsable de la tecnología.

Es por ello a continuación se analizan las principales implicaciones legales y éticas asociadas a la solución propuesta, incluyendo el tratamiento de los datos introducidos por los usuarios, la creciente regulación sobre el uso de IA y las licencias software que condicionan el despliegue del sistema.

8.1. Protección de datos personales y derechos digitales

El asistente legal que se ha desarrollado en este proyecto, aunque no almacena datos personales identificativos como pueden ser nombres o direcciones, sí recoge las preguntas realizadas por los usuarios al asistente. Estas interacciones pueden contener de forma involuntaria información que identifique al usuario de forma directa o indirecta. Esto podría ocurrir en caso de que se introduzcan nombres, referencias a empresas, ubicaciones concretas u otro tipo de información.

Debido a lo anterior, el tratamiento de estos datos queda sujeto a la normativa vigente en materia de protección de datos personales, más en concreto, al Reglamento General de Protección de Datos [36] o por sus siglas RGPD de la Unión Europea, y a la Ley Orgánica 3/2018 de Protección de Datos Personales y garantía de los derechos digitales [37] (LOPDGDD). Entre los principios más relevantes establecidos por el RGPD y alineados con la ley española, destacan:

- **Licitud, lealtad y transparencia.** El tratamiento de los datos debe realizarse a partir de una base legal válida como el consentimiento, y además se debe informar a la persona afectada.
- **Minimización de datos.** Se tratarán únicamente los datos imprescindibles para la finalidad prevista.
- **Limitación del plazo de conservación.** Los datos no se deben almacenar más tiempo del que resulte estrictamente necesario.
- **Seguridad.** Deben aplicarse medidas técnicas y organizativas que aseguren la protección de los datos.

Como ya se ha mencionado, además del RGPD en España se aplica la LOPDGDD, una norma que complementa y desarrolla aún más el reglamento europeo, incluyendo puntos específicos sobre el tratamiento de datos en el ámbito académico y reforzando los derechos digitales de los usuarios. Por lo tanto, esta ley española reconoce el derecho de los ciudadanos a la protección de su intimidad en entornos digitales, así como a ser informados de forma clara y a otorgar un consentimiento para el tratamiento de sus datos personales.

Con el objetivo de garantizar el cumplimiento normativo expuesto, en el proyecto se han adoptado las siguientes medidas:

- Al iniciar el asistente se informa al usuario de que las interacciones pueden ser almacenadas con fines académicos y de mejora del sistema, y se le recomienda evitar introducir datos personales si no quiere que queden registrados.
- Se obtiene su consentimiento antes de almacenar las conversaciones estableciendo así una base legal válida para el tratamiento de datos personales según el artículo 6 del RGPD. En caso contrario, el usuario no podrá utilizar la herramienta.
- Los datos almacenados se conservan en un entorno seguro y no se comparten con terceros. Solo la desarrolladora del sistema tiene acceso a las conversaciones.
- Se aplica el principio de minimización de datos evitando el almacenamiento de información innecesaria, y se contempla la posibilidad de anonimizar los contenidos si se requiere su uso posterior.

Cumpliendo con los puntos anteriores, el desarrollo del asistente se alinea con los principios de protección de datos y con los derechos digitales de los usuarios.

8.2. Ética y regulación de la inteligencia artificial

En el desarrollo de sistemas de inteligencia artificial, especialmente en aquellos que interactúan con personas como es el caso del asistente propuesto en este proyecto, se deben tener en cuenta los principios éticos concretados por una Unión Europea para garantizar un uso responsable y controlado de la tecnología. Para cumplir con esto, se deben tener en cuenta los dos documentos descritos en los siguientes apartados.

8.2.1. Directrices éticas para una IA fiable

Este documento, publicado por un grupo de expertos de alto nivel sobre inteligencia artificial, pretende determinar un marco que ayude a conseguir que una IA sea fiable [38]. Para que esto ocurra, se deben dar los siguientes tres componentes:

- **IA lícita.** Debe garantizar el cumplimiento de todos los reglamentos y leyes aplicables, incluyendo legislación sobre protección de datos, normas sobre derechos fundamentales como la no discriminación o la igualdad, y otras regulaciones específicas del sector.
- **IA ética.** Este aspecto va más allá del cumplimiento legal, refiriéndose a que el sistema respeta los cuatro valores éticos fundamentales establecidos por la Comisión Europea [38].
 - Explicabilidad: Garantiza que el funcionamiento del sistema y sus decisiones puedan ser entendidos por los usuarios
 - Equidad: Implica que la IA no genere resultados discriminatorios, tratando a todas las personas de forma justa.
 - Prevención de daños: Exige que el sistema minimice posibles riesgos, errores y consecuencias negativas para los usuarios y la sociedad.
 - Respeto de la autonomía humana: Asegura que la IA complementa y no sustituye la capacidad de decisión de las personas, manteniéndolas siempre en el centro del control.
- **IA robusta.** Se refiere a un sistema técnicamente fiable, seguro y resiliente. Esto quiere decir que se comporta de forma predecible, no se puede manipular fácilmente y que es capaz de detectar errores y actuar ante fallos.

A parte de la definición de los fundamentos de una IA fiable, el documento también traduce estos principios en siete requisitos claves que se deben aplicar en todo el ciclo de vida de un sistema, incluyendo supervisión humana, privacidad y no discriminación. Finalmente, también propone una lista de evaluación preliminar que ayuda a implementar y verificar los requisitos anteriores en contextos reales.

8.2.2. Reglamento Europeo de IA - *AI Act*

El Reglamento Europeo de Inteligencia Artificial, también conocido como *AI Act* [39], establece un marco legal para el desarrollo, comercialización y uso de sistemas de inteligencia artificial en la UE, utilizando para ello un enfoque basado en el riesgo para clasificarlos.

Para ello tiene en cuenta el impacto que estas aplicaciones pueden tener en los derechos y la seguridad de las personas y establece así prohibiciones y requisitos específicos para ciertos usos de la IA. Se pueden clasificar superficialmente en:

- **Sistemas prohibidos:** Se prohíben prácticas de IA que se consideren inaceptables, como la manipulación o la explotación de vulnerabilidades de grupos entre otros.
- **Sistemas de alto riesgo:** Se consideran de alto riesgo aquellos sistemas de IA que se utilizan en áreas críticas como la educación, el empleo, la aplicación de la ley y la gestión de infraestructuras. Estos sistemas están sujetos a una serie de requisitos estrictos.
- **Otros sistemas:** Se establecen obligaciones más ligeras, principalmente relacionadas con la transparencia.

Dentro de este marco, un asistente legal como el que se ha desarrollado podría considerarse un sistema de riesgo limitado, al ofrecer orientación general sin llegar a sustituir a un profesional cualificado. Debido a esto, se le aplican obligaciones de transparencia relacionadas con la notificación a los usuarios de que están interactuando con un sistema de IA, y asegurando así una interacción informada y consciente.

8.2.3. Buenas prácticas aplicadas en este proyecto

Las decisiones técnicas que se han seguido a lo largo del desarrollo del asistente legal no se han tomado de manera aislada, sino que han estado guiadas por el marco regulador y ético que se ha expuesto en los anteriores apartados de este capítulo. En concreto se han adoptado una serie de buenas prácticas alineadas con:

Protección de datos personales y derechos digitales

- **Conservación responsable del historial:** El sistema guarda las interacciones pero informa al usuario y se le pide consentimiento previo. Además se aplican los principios de minimización de datos y seguridad, almacenando únicamente lo estrictamente necesario.

Ética y regulación de la inteligencia artificial

- **Prompting controlado:** Se utilizan instrucciones claras al modelo en cada consulta realizada para guiar su comportamiento, limitar la invención de contenidos y fomentar respuestas fiables.
- **Revisión humana:** Aunque el sistema no sustituye el asesoramiento profesional, se ha planteado la posibilidad de que las respuestas sean revisadas por personas cualificadas en futuras versiones, especialmente en entornos reales fuera del contexto académico.
- **Limitación del alcance legal del asistente:** Se evita que el asistente actúe como sustituto de un profesional jurídico, siendo su rol el ofrecer una orientación general.

8.3. Licencias Software

Como ya se ha mencionado, durante todo el desarrollo e implementación del sistema inteligente se han utilizado varias bibliotecas y modelos de código abierto cuyas licencias han sido respetadas en todo momento. Entre los principales paquetes destacan:

- *transformers*, *streamlit* o *sentence-transformers* entre otros, todos ellos distribuidos bajo la licencia **Apache 2.0**, que fue creada por *Apache Software Foundation* y es una de las licencias software más permisivas, dado que permite el uso, modificación y redistribución del código incluso en contextos comerciales, siempre y cuando se mantenga el aviso de *copyright* y los términos de la licencia original [40].
- El modelo generador utilizado Mistral 7B Instruct, así como el utilizado para crear los *embeddings* PlanTL-GOB-ES, se distribuyen también bajo la licencia de código abierto **Apache 2.0**, tal como se especifica en su página oficial de Hugging Face [30] [26].

Respecto al código desarrollado para la implementación del asistente, se ha optado por utilizar una licencia de software libre, concretamente se considera la licencia MIT o Apache 2.0 como opciones viables. Ambas licencias favorecen la transparencia, la reutilización del conocimiento y la colaboración con otros desarrolladores en el ámbito académico y profesional. En particular:

- La licencia **MIT** es sencilla, ampliamente aceptada y permite una gran flexibilidad en la reutilización de código [41].
- La licencia **Apache 2.0**, además de ofrecer libertades similares, incluye cláusulas sobre patentes, lo que puede ser beneficioso en entornos más formales o corporativos [40].

La elección de una licencia abierta responde al compromiso del proyecto con los principios de la inteligencia artificial ética y accesible, promoviendo un desarrollo abierto, transparente y colaborativo. Tras considerar las diferentes opciones se ha optado por la licencia **Apache 2.0**, que proporciona un equilibrio entre libertad de uso, modificación y distribución del software, junto con cierto grado de protección.

Por último, se han utilizado también servicios externos como Pinecone [29] y RunPod [34], que no son paquetes de software libre pero sí plataformas en la nube con condiciones de uso propias. Su uso se ha realizado conforme a sus términos de servicio, disponibles públicamente en sus páginas web. En el caso de Pinecone, se ha utilizado el plan gratuito, limitado en volumen y rendimiento, y no se han subido datos personales ni confidenciales al índice vectorial. Por otro lado, el uso de RunPod se ha limitado al entorno experimental del proyecto, respetando los términos establecidos por el proveedor y sin desplegar servicios públicos ni comerciales.

9. ENTORNO SOCIOECONÓMICO

En el siguiente capítulo se analiza el contexto en el que se desarrolla el proyecto, desde una perspectiva interna y externa, abordando su posible impacto social y económico, la planificación temporal de su desarrollo y por último, una estimación del presupuesto necesario para la implementación del asistente en un entorno real.

9.1. Impacto socioeconómico

Es bien sabido que la inteligencia artificial está generando un cambio significativo en el sector del derecho, especialmente en lo relativo a la automatización de tareas rutinarias de menor valor y más repetitivas, de tal forma que no sustituyen el papel de los profesionales de derecho pero sí les ayuda a aumentar su eficiencia al poder concentrarse en otras tareas que dependen más de su conocimiento y experiencia. Sin embargo, estas herramientas modifican sus funciones y competencias, tal como refleja el estudio de la Universitat de València [42], que concluye que la IA obligará a adquirir nuevas habilidades relacionadas con el uso de este tipo de tecnologías y el aprendizaje que antes se adquiría en la realización de las actividades repetitivas ahora desempeñadas por estas herramientas.

En este contexto, el desarrollo de asistentes legales o *chatbots* como el que se plantea en este proyecto se alinea con varias de las principales tendencias actuales en el sector legal, tal como se analiza en el estudio previamente mencionado [42], distinguiendo tres tipos de *chatbots*:

- **Chatbots sustitutivos del profesional:** Son sistemas que permiten al usuario realizar el proceso legal sin intervención humana directa. Utilizados en la redacción de documentos o asesoramiento sobre cuestiones simples.
- **Chatbots de asistencia profesional:** Estas herramientas asisten a los expertos en su trabajo cotidiano, aportando información, sugiriendo jurisprudencia y otros aspectos.
- **Chatbots para la experiencia del cliente:** Automatizan la primera interacción con el cliente, recopilando información básica, recomendando departamentos o concretando citas.

Por tanto, el asistente desarrollado pertenece a estas tendencias y se encuadra principalmente dentro del segundo grupo. Su función no es sustituir a los profesionales, sino facilitar el acceso a la información legal, sirviendo como una herramienta de apoyo.

Una vez se ha demostrado el interés existente en las nuevas propuestas tecnológicas relacionadas con el mundo legal, se afirma la posibilidad de incorporar nuevas iniciativas como la planteada dentro de este proyecto.

Este sistema en concreto aporta un valor añadido dentro del panorama actual, al estar dirigido a facilitar el acceso y la comprensión de la normativa europea. Esta orientación no responde únicamente a una necesidad creciente en sectores productivos que se enfrentan a nuevas regulaciones relacionadas con la sostenibilidad, sino que también representa una propuesta de valor concreta para pequeñas empresas o colectivos, que sin recursos jurídicos constantes requieren de esta orientación fiable. Es importante recalcar que en este contexto el asistente no sustituye al profesional, sino que actúa como una primera capa de apoyo e información, reduciendo la barrera de entrada al conocimiento legal.

A parte de lo anterior, también resulta relevante analizar la viabilidad del desarrollo del asistente desde un punto de vista económica:

- Bajo coste de implementación: Utiliza herramientas y biblioteca de código abierto, lo que reduce los gastos iniciales.
- Escalabilidad: Existe la posibilidad de adaptarlo a diferentes ámbitos legales y áreas del derecho con ajustes mínimos.
- Modelo de negocio flexible: Se podrían ofrecer servicios gratuitos con funciones básicas, y servicios de pago con características más avanzadas.

Por último, resulta también relevante tener en cuenta el impacto ambiental asociado al uso de servicios *cloud*, como la infraestructura de despliegue que utiliza el asistente legal. La ejecución del sistema en la nube supone un consumo energético, cuya huella de carbono depende de las políticas de sostenibilidad seguidas por los proveedores *cloud*, en este caso RunPod. Dado que en este proyecto se utiliza la modalidad *Community Cloud*, la procedencia de la energía consumida por el pod es desconocida y heterogénea, ya que estos recursos son aportados por terceros. No obstante, dado el carácter experimental y la escala limitada del sistema en esta fase de prototipo, se considera un impacto ambiental reducido. En futuros despliegues a mayor escala, sería necesario evaluar opciones con mayores garantías en términos de sostenibilidad

En este contexto también cabe destacar el índice creado en Pinecone para la recuperación semántica. Dicho índice se aloja en la infraestructura *cloud* de AWS, que sí mantiene un compromiso corporativo para alcanzar un uso del 100% de energía renovable en todos sus centros de datos. Según la información publicada por *Amazon Web Services* en su página de sostenibilidad [43], la compañía mantiene este compromiso, aunque no proporcione un desglose detallado de la energía utilizada por región, resulta una buena aproximación para minimizar el impacto ambiental asociado al uso de sus servicios.

9.2. Planificación

A la hora de realizar la planificación del proyecto y estimar el tiempo necesario para el desarrollo del mismo, se deben considerar diversos factores. En primer lugar, es necesario determinar cuáles serán las actividades principales dentro de este proceso:

1. Estudio preliminar y definición del enfoque

Investigación sobre el uso de *chatbots* en el sector legal, análisis de las técnicas existentes más adecuadas para la elaboración del proyecto y revisión de las principales normativas relacionadas con la iniciativa Deforestación Cero, así como el principal marco regulador a tener en cuenta durante el desarrollo.

2. Procesamiento de documentos y generación de embeddings

Creación de la base de conocimientos del asistente legal a través de la extracción y limpieza de los textos normativos, generación de los embeddings y almacenamiento en la base vectorial de los mismos.

3. Diseño e implementación del sistema RAG

Desarrollo del sistema que integra la recuperación semántica con la generación de las respuestas.

4. Experimentación con el modelo generador base Mistral 7B Instruct

Evaluación inicial del comportamiento del modelo con diferentes parámetros de inferencia y técnicas de *prompting*.

5. Fine-tuning de Mistral 7B Instruct

Generación del conjunto de datos que se va a utilizar para el entrenamiento del modelo, así como el proceso de fine-tuning.

6. Desarrollo de la interfaz de usuario

Diseño e implementación de la interfaz del asistente, integración con el backend e inclusión de todas las funcionalidades requeridas.

7. Despliegue e infraestructura *cloud*

Configuración del entorno de ejecución en la nube.

8. Redacción de la memoria y documentación del proyecto

Elaboración del documento que incluye los diferentes aspectos del proyecto, desde el estudio preliminar hasta el diseño, desarrollo e implementación, incluyendo tablas de requisitos, casos de uso y otros componentes de diseño.

El desarrollo del proyecto se inició a mediados de enero de 2025, con la fase del estudio preliminar. A lo largo de los meses posteriores se sucedieron las fases de diseño e implementación. Se ha dado por finalizado a principios de mayo, lo que supone una duración total de unos 100 días. Se estima que el tiempo total de trabajo ha sido de entre 360 y 440 horas, lo que equivale a unas 90 a 110 jornadas de cuatro horas.

TABLA 9.1. PLANIFICACIÓN

Tarea	Inicio	Fin	Duración (d)	Duración (h)
Estudio inicial	16/01/2025	25/01/2025	9	36
Procesamiento	25/01/2025	02/02/2025	8	32
Sistema RAG	02/02/2025	17/02/2025	15	60
Ajuste Mistral	17/02/2025	07/03/2025	18	72
Fine-tuning	07/03/2025	21/03/2025	14	56
Interfaz	21/03/2025	28/03/2025	7	28
Despliegue	28/03/2025	31/03/2025	3	12
Documentación	31/03/2025	29/04/2025	29	116
Total			103	412

A partir de la estimación realizada en la anterior tabla, se ha desarrollado el siguiente diagrama de Gantt que muestra la distribución del tiempo.




Fig. 9.1. Diagrama Gantt del proyecto

9.3. Presupuesto

Un proyecto como el que se ha desarrollado en este trabajo implica una serie de recursos humanos, materiales y tecnológicos, cuyo coste estimado se detallará en esta sección. A pesar de que se trata de un proyecto académico, es importante valorar la viabilidad de su desarrollo y ejecución desde un punto de vista económico, con el objetivo de dimensionar el esfuerzo que se ha invertido en el proyecto y para facilitar una posible implementación en un contexto profesional. Esta estimación considera el uso de herramientas de software, equipos, y el tiempo dedicado por los miembros involucrados.

El primer coste a tener en cuenta es el de la plantilla, que hace referencia al tiempo invertido por cada uno de los miembros del personal en el desarrollo del proyecto. Para realizar esta estimación se deben definir también los roles de los integrantes del equipo, así como su salario bruto. Para una estimación realista de los sueldos se han utilizado los datos de Glassdoor [44].

TABLA 9.2. COSTE DE LA PLANTILLA

Rol	Estimación (%)	Horas	Sueldo por hora (€)	Coste
Jefe de Proyecto	15 %	62	24,67 €	1.529,54 €
Experto en IA	30 %	124	22,7 €	2.814,80 €
Analista	20 %	82	19,32 €	1.584,24 €
Desarrollador de software	35 %	144	18,75 €	2.700,00 €
Total	100%	412	-	8.628,58 €

También se deben tener en cuenta los costes asociados con los recursos tecnológicos utilizados, tanto físicos como digitales. Para cada herramienta o dispositivo, se ha tenido en cuenta únicamente la parte proporcional correspondiente al tiempo de uso. Esto queda reflejado mediante el cálculo de su coste amortizado, es decir, el valor aproximado correspondiente al tiempo de uso que ha tenido cada recurso dentro del proyecto.

TABLA 9.3. COSTE RECURSOS TECNOLÓGICOS

Descripción	Precio	Horas de uso	Vida útil	Coste amortizado
Ordenador personal	1200 €	380	10.000 h	45,60 €
Microsoft Office	10 €/mes	116	-	7,25 €.
RunPod (GPU RTX A4000)	0,15 €/h	960	-	144 €
Total				196,85 €

Finalmente, se presenta la tabla que recoge el coste total estimado del proyecto, incluyendo en ella los costes de personal y recursos calculados previamente. Además se ha considerado un porcentaje del 15% para costes indirectos, es decir, una serie de gastos que quizás no se perciben de forma directa pero que se deben tener en cuenta en el desarrollo del proyecto, como puede ser electricidad, Internet o material de oficina. También se ha contemplado un fondo de prevención del 10% que está destinado a cubrir posibles imprevistos dentro del presupuesto planteado inicialmente. No se ha añadido ningún margen de beneficio, dado que se trata de un proyecto académico sin fines comerciales.

TABLA 9.4. COSTE TOTAL DEL PROYECTO

Concepto	Precio
Coste de plantilla	8.628,58 €
Coste de recursos tecnológicos	196,85 €
Total costes directos	8.825,43 €
Costes indirectos (7%)	617,78 €
Margen de beneficios (0%)	0 €
Fondo de prevención (10%)	882,4 €
Total del proyecto	10.325,61 €

10. CONCLUSIONES

Para finalizar con el documento, en este capítulo se presentan las conclusiones del trabajo realizado, así como algunas posibles líneas futuras que se podrían contemplar para realizar una mejora de los resultados obtenidos en el proyecto desarrollado.

10.1. Conclusiones generales

El desarrollo del asistente legal surgió ante un problema real y concreto: la dificultad que encuentran muchas pequeñas y medianas empresas para comprender y adaptarse a normativas que pueden resultar complejas, como es el caso de los reglamentos relacionados con las iniciativas europeas de Deforestación Cero. Esta barrera de entendimiento presente en sectores con menos recursos o que no disponen de la formación jurídica necesaria, puede frenar el cumplimiento de prácticas sostenibles o incluso poner en riesgo el acceso de estas empresas al mercado europeo.

Con el objetivo principal de dar respuesta a esta necesidad, se diseñó y desarrolló un sistema inteligente basado en LLMs capaz de ofrecer explicaciones simplificadas y adaptadas al contexto de cada consulta realizada por el usuario. Para esto, se planteó un enfoque técnico apoyado en una arquitectura RAG.

Durante todo el desarrollo del proyecto se ha llevado a cabo un proceso iterativo de planificación, prueba y ajuste en el que se han abordado distintos retos, desde el procesamiento y estructuración documentos legales, hasta la implementación de un sistema de recuperación semántica y el *fine-tuning* del modelo generador, todo esto teniendo en cuenta las limitaciones computacionales de las que se partía inicialmente.

A pesar de ello, se han alcanzado los principales objetivos definidos, desarrollando un prototipo robusto y funcional capaz de:

- Recuperar la información relevante de documentos legales en relación a las consultas realizadas.
- Generar respuestas coherentes, claras y adaptadas a un lenguaje no técnico, para facilitar el entendimiento de las normativas.
- Funcionar de manera eficiente en entornos con recursos computacionales limitados.
- Presentar una interfaz que prioriza la accesibilidad y la facilidad de uso.

También se ha realizado un análisis detallado del entorno socioeconómico del proyecto, en el que se han estimado los costes de desarrollo y despliegue del sistema, junto con una planificación temporal. Este análisis ha permitido concluir que no solo es un proyecto viable, sino también económicamente sostenible, especialmente considerando el uso de hardware accesible, así como herramientas y modelos de código abierto.

Cabe destacar que el sistema cumple con todos los requisitos establecidos en las fases iniciales de diseño del trabajo, incluyendo todas las funcionalidades descritas, así como las restricciones impuestas en términos de eficiencia y buenos resultados.

Este trabajo realza el potencial que tiene la inteligencia artificial cuando se utiliza de una forma ética, responsable, y sobre todo, centrada en el usuario. No se trata solo de lo que la tecnología puede hacer, sino de **para quién y para qué se hace**. En este caso la IA **no busca sustituir sino acompañar, no impone sino que ayuda a entender**.

Desde la perspectiva de la ingeniería, este proyecto refuerza una idea fundamental, **ser ingeniero no es únicamente construir soluciones eficientes y que funcionen, sino diseñar soluciones con un propósito**, con capacidad de generar un impacto social.

En resumen, este proyecto no solo ha permitido explorar la aplicación de tecnologías avanzadas de inteligencia artificial en el ámbito legal, sino que también ha demostrado su viabilidad como solución para reducir la brecha entre las nuevas normativas y quienes deben cumplirlas, facilitando este cumplimiento desde un enfoque comprensible y accesible.

10.2. Futuras líneas de trabajo

A lo largo del desarrollo del sistema, se han identificado posibles mejoras o extensiones que por cuestión de tiempo y alcance no han podido ser abordadas. Sin embargo, presentan grandes oportunidades que permitirían enriquecer el sistema y aumentar su utilidad en entornos reales.

A continuación, se describen varias líneas de trabajo que permitirían continuar evolucionando el asistente legal, tanto desde el punto de vista técnico como funcional:

- **Ampliación del corpus legal:** Incluir más documentos legales relacionados con las iniciativas de Deforestación Cero, así como otros marcos normativos sociales específicos de cada país, como pueden ser declaraciones de derechos, condiciones laborales, etc.
- **Evaluación con usuarios reales:** Realizar pruebas con empresas para analizar el uso del asistente en situaciones reales, recoger *feedback* de los usuarios y detectar mejoras tanto en el contenido de las respuestas como en la interfaz y la interacción.

- **Optimización de la recuperación de información:** Explorar nuevas técnicas con el fin de mejorar los fragmentos recuperados por el sistema RAG, ya que se ha observado una correlación directa entre la calidad de la recuperación y las respuestas generadas. Esto podría incluir el ajuste de parámetros del índice, el enriquecimiento del corpus con metadatos, o el uso de técnicas avanzadas para reordenar los fragmentos obtenidos.
- **Entrenamiento con conversaciones completas:** Explorar un entrenamiento más avanzado del modelo, utilizando para ello diálogos completos en vez de pares asilados de pregunta-respuesta. Permitiría al modelo mejorar la capacidad de mantener el contexto y ofrecer una experiencia conversacional más fluida y natural.
- **Mejora del entrenamiento del modelo sin restricciones de rendimiento:** Realizar un fine-tuning completo del modelo sin aplicar técnicas de cuantización ni adaptación eficiente (como LoRA), utilizando un hardware más potente. Con esto se conseguiría un entrenamiento con mayor precisión, ajustando los pesos del modelo en profundidad.
- **Análisis de documentos legales:** Incorporar una funcionalidad que permita al usuario subir documentos propios (como contratos o políticas internas de la empresa) y realizar un análisis simplificado, advertencias sobre incumplimientos o sugerencias de mejoras basadas en las normativas.
- **Seguridad del despliegue y gestión avanzada de la infraestructura:** Actualmente el prototipo se ejecuta en un entorno de desarrollo controlado, con ciertas limitaciones en cuanto a la gestión de credenciales y protección de datos en tránsito y reposo. Sería recomendable utilizar prácticas avanzadas como el uso de HTTPS, la integración de un gestor de secretos para el almacenamiento seguro de credenciales, y la aplicación de cifrado a los datos almacenados en el registro de las interacciones.

11.BIBLIOGRAFÍA

- [1] Parlamento Europeo y Consejo. “Propuesta de DIRECTIVA DEL PARLAMENTO EUROPEO Y DEL CONSEJO sobre diligencia debida de las empresas en materia de sostenibilidad y por la que se modifica la Directiva (UE) 2019/1937.” EUR-Lex. [En línea]. Disponible en: <https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX:52022PC0071>. [Acceso: 27 de abril 2025].
- [2] International Cocoa Organization, “Production of cocoa beans by region and country, cocoa year 2024/25,” *ICCO Quarterly Bulletin of Cocoa Statistics*, vol. LI, nº 1, p. 1, febrero 2025. [En línea]. Disponible en: https://www.icco.org/wp-content/uploads/Production_QBCS-LI-No.-1.pdf. [Acceso: 27 de abril 2025].
- [3] Parlamento Europeo y Consejo. “Reglamento (UE) 2023/1115 del Parlamento Europeo y del Consejo, de 31 de mayo de 2023, relativo a la comercialización en el mercado de la Unión y a la exportación desde la Unión de determinadas materias primas y productos asociados a la deforestación y la degradación forestal, y por el que se deroga el Reglamento (UE) n.º 995/2010.” EUR-Lex. [En línea]. Disponible en: <https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX%3A32023R1115>. [Acceso: 2025 abril 27].
- [4] DoNotPay. “DoNotPay Official Website.” DoNotPay. [En línea]. Disponible en: <https://donotpay.com/>. [Acceso: 29 abril 2025].
- [5] LawDroid. “LawDroid Official Website.” LawDroid. [En línea]. Disponible en: <https://lawdroid.com/>. [Acceso: 29 abril 2025].
- [6] Observatorio de Responsabilidad Social Corporativa, “La Directiva de Diligencia Debida Empresarial en la Unión Europea: un paso relevante hacia la sostenibilidad,” *Observatorio de Responsabilidad Social Corporativa*, 2 abril 2024. [En línea]. Disponible en: <https://observatoriorsc.org/directiva-diligencia-debida-ue-paso-relevante-hacia-sostenibilidad/>. [Acceso: 1 mayo 2025].
- [7] Comisión Europea. “Explicación de la debida diligencia.” Comisión Europea. [En línea]. Disponible en: https://single-market-economy.ec.europa.eu/sectors/raw-materials/due-diligence-ready/due-diligence-explained_es. [Acceso: 1 mayo 2025].

- [8] J. Magro González, “Directiva CS3D: 6 pasos para adoptar la diligencia debida,” *KPMG Tendencias*, 24 mayo 2024. [En línea]. Disponible en: <https://www.tendencias.kpmg.es/2024/05/cs3d-6-pasos-adoptar-diligencia-debida/>. [Acceso: 1 mayo 2025].
- [9] KPMG Tendencias, “Claves del reglamento EUDR contra la Deforestación,” *KPMG Tendencias*, 7 abril 2025. [En línea]. Disponible en: <https://www.tendencias.kpmg.es/2025/04/reglamento-eudr-deforestacion-claves-requerimientos/>. [Acceso: 1 mayo 2025].
- [10] Prewave. “Prewave Official Website.” Prewave. [En línea]. Disponible en: <https://www.prewave.com/>. [Acceso: 3 mayo 2025].
- [11] Anytime AI. “Anytime AI Official Website.” Anytime AI. [En línea]. Disponible en: <https://www.anytimeai.ai/>. [Acceso: 3 mayo 2025].
- [12] John Snow Labs. “Legal NLP – Natural Language Processing for Legal Documents.” John Snow Labs. [En línea]. Disponible en: <https://www.johnsnowlabs.com/legal-nlp/>. [Acceso: 3 mayo 2025].
- [13] J. Lai, W. Gan, J. Wu, Z. Qi, and P. S. Yu, “Large Language Models in Law: A Survey,” 2023, *arXiv:2312.03718*. [En línea]. Disponible en: <https://doi.org/10.48550/arXiv.2312.03718>. [Acceso: 4 mayo 2025].
- [14] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, et al., “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” 2021, *arXiv:2005.11401*. [En línea]. Disponible en: <https://doi.org/10.48550/arXiv.2005.11401>. [Acceso: 4 mayo 2025].
- [15] Z. Guo, L. Xia, Y. Yu, T. Ao, and C. Huang, “LightRAG: Simple and Fast Retrieval-Augmented Generation,” 2025, *arXiv:2410.05779*. [En línea]. Disponible en: <https://doi.org/10.48550/arXiv.2410.05779>. [Acceso: 4 mayo 2025].
- [16] Hugging Face. “Hugging Face Official Website.” Hugging Face. [En línea]. Disponible en: <https://huggingface.co/>. [Acceso: 6 mayo 2025].
- [17] TensorFlow. “TensorFlow Hub.” TensorFlow. [En línea]. Disponible en: <https://www.tensorflow.org/hub>. [Acceso: 6 mayo 2025].
- [18] PyTorch. “PyTorch Hub.” PyTorch. [En línea]. Disponible en: <https://pytorch.org/hub/>. [Acceso: 6 mayo 2025].
- [19] ONNX. “ONNX Model Zoo.” ONNX. [En línea]. Disponible en: <https://github.com/onnx/models>. [Acceso: 6 mayo 2025].

- [20] Google. “Google Trends.” Google. [En línea]. Disponible en: <https://trends.google.com/>. [Acceso: 10 mayo 2025].
- [21] Sentence Transformers. *paraphrase-multilingual-MiniLM-L12-v2*. 2 junio 2021. Hugging Face. [En línea]. Disponible en: <https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2>. [Acceso: 10 mayo 2025].
- [22] N. Reimers y I. Gurevych, "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," presentada en Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP 2019), Hong Kong, noviembre 2019. [En línea]. Disponible en: <https://aclanthology.org/D19-1410/>. [Acceso: 10 mayo 2025].
- [23] Sentence Transformers. *distiluse-base-multilingual-cased*. 22 junio 2021. Hugging Face. [En línea]. Disponible en: <https://huggingface.co/sentence-transformers/distiluse-base-multilingual-cased-v1>. [Acceso: 10 mayo 2025].
- [24] DCC UChile. *bert-base-spanish-wwm-uncased*. 23 diciembre 2019. Hugging Face. [En línea]. Disponible en: <https://huggingface.co/dccuchile/bert-base-spanish-wwm-uncased>. [Acceso: 10 mayo 2025].
- [25] J. Cañete, G. Chaperon, R. Fuentes, J.-H. Ho, H. Kang, y J. Pérez, "Spanish Pre-Trained BERT Model and Evaluation Data," presentada en Proceedings of the 2nd Workshop on Machine Learning for the Developing World (PML4DC) at ICLR 2020, Addis Ababa, Etiopía, 2020. [En línea]. Disponible en: <https://users.dcc.uchile.cl/~jperez/papers/pml4dc2020.pdf>. [Acceso: 10 mayo 2025].
- [26] Plan de Tecnologías del Lenguaje - Gobierno de España. *roberta-large-bne*. 19 octubre 2021. Hugging Face [En línea]. Disponible en: <https://huggingface.co/PlanTL-GOB-ES/roberta-large-bne>. [Acceso: 10 mayo 2025].
- [27] A. Gutiérrez-Fandiño, J. Armengol-Estapé, M. Pàmies, J. Llop-Palao, J. Silveira-Ocampo, C. Pio-Carrino, et al., “MarIA: Spanish Language Models,” *Procesamiento del Lenguaje Natural*, vol. 68, pp. 39–60, marzo de 2022. [En línea]. Disponible en: <http://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6405>. [Acceso: 10 mayo 2025].
- [28] Scikit-learn. “Scikit-learn.” Scikit-learn. [En línea]. Disponible en: <https://scikit-learn.org/>. [Acceso: 10 mayo 2025].

- [29] Pinecone. "Pinecone Official Website." Pinecone. [En línea]. Disponible en: <https://www.pinecone.io/>. [Acceso: 12 mayo 2025].
- [30] Mistral AI. *Mistral-7B-Instruct-v0.3*. 22 mayo 2024. Hugging Face. [En línea]. Disponible en: <https://huggingface.co/mistralai/Mistral-7B-Instruct-v0.3>. [Acceso: 12 mayo 2025].
- [31] A. Q. Jiang, A. Sablayrolles, A. Mensch, C. Bamford, D. S. Chaplot, D. de las Casas, et al., "Mistral 7B," 2023, *arXiv:2310.06825*. [En línea]. Disponible en: <https://doi.org/10.48550/arXiv.2310.06825>. [Acceso: 12 mayo 2025].
- [32] Streamlit. "Streamlit Official Website." Streamlit. [En línea]. Disponible en: <https://streamlit.io/>. [Acceso: 12 mayo 2025].
- [33] Figma. "Figma Oficial Website." Figma. [En línea]. Disponible en: <https://www.figma.com/es-es/>. [Acceso: 12 mayo 2025].
- [34] RunPod. "RunPod Official Website". RunPod. [En línea]. Disponible en: <https://www.runpod.io/>. [Acceso: 13 mayo 2025].
- [35] *IEEE Recommended Practice for Software Requirements Specifications*, IEEE Std 830-1998, 20 octubre 1998. [En línea]. Disponible en: <https://doi.org/10.1109/IEEESTD.1998.88286>. [Acceso: 15 mayo 2025].
- [36] Parlamento Europeo y Consejo. "REGLAMENTO (UE) 2016/679 DEL PARLAMENTO EUROPEO Y DEL CONSEJO de 27 de abril de 2016 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos y por el que se deroga la Directiva 95/46/CE (Reglamento general de protección de datos)." EUR-Lex. [En línea]. Disponible en: <https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX:32016R0679>. [Acceso: 27 mayo 2025].
- [37] Jefatura del Estado. "Ley Orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales." BOE. Es. [En línea]. Disponible en: <https://www.boe.es/eli/es/lo/2018/12/05/3>. [Acceso: 27 mayo 2025].
- [38] Grupo de Expertos de Alto Nivel sobre Inteligencia Artificial, "Directrices éticas para una IA fiable," Comisión Europea, Bélgica, Informe, 2019. [En línea]. Disponible en: <https://digital-strategy.ec.europa.eu/es/library/ethics-guidelines-trustworthy-ai>.

- [39] Parlamento Europeo y Consejo. “REGLAMENTO (UE) 2024/1689 DEL PARLAMENTO EUROPEO Y DEL CONSEJO de 13 de junio de 2024 por el que se establecen normas armonizadas en materia de inteligencia artificial y por el que se modifican los Reglamentos (CE) n.o 300/2008, (UE) n.o 167/2013, (UE) n.o 168/2013, (UE) 2018/858, (UE) 2018/1139 y (UE) 2019/2144 y las Directivas 2014/90/UE, (UE) 2016/797 y (UE) 2020/1828 (Reglamento de Inteligencia Artificial).” EUR-Lex. [En línea]. Disponible en: <https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=CELEX%3A32024R1689>. [Acceso: 29 mayo 2025].
- [40] The Apache Software Foundation, “Apache License, Version 2.0”. [En línea]. Disponible en: <https://www.apache.org/licenses/LICENSE-2.0>. [Acceso: 29 mayo 2025].
- [41] Open Source Initiative, “The MIT License”. [En línea]. Disponible en: <https://opensource.org/license/MIT>. [Acceso: 29 mayo 2025].
- [42] J. M. Peiró, A. Todolí, J. M. Sánchez, P. López, y D. Crespo, “Motores de cambio y consecuencias,” en *Diagnóstico y estrategia sobre el futuro de las profesiones de la Facultat de Dret: Retos tecnológicos, demográficos y sociales*, Valencia: Publicacions de la Universitat de València, 2025, pp. 31–84.
- [43] Amazon. "AWS Cloud Sustainability." Amazon. [En línea]. Disponible en: <https://sustainability.aboutamazon.com/products-services/aws-cloud>. [Acceso: 30 mayo 2025].
- [44] Glassdoor. “Sueldos de la empresa.” Glassdoor. [En línea]. Available: <https://www.glassdoor.es/Sueldos/index.htm>. [Último acceso: 31 mayo 2025].

ANEXO

A. Especificación de requisitos completa

TABLA A.1. REQUISITO FUNCIONAL RF-01

Identificador	RF-01		
Nombre	Resolución de consultas sobre Deforestación Cero		
Fuente	Cliente		
Prioridad	Alta	Estabilidad	Alta
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe interpretar y responder preguntas legales formuladas en lenguaje natural sobre las normativas relacionadas con la iniciativa de <i>Deforestación Cero</i> (CS3D y EUDR).		

TABLA A.2. REQUISITO FUNCIONAL RF-02

Identificador	RF-02		
Nombre	Recuperación contexto legal mediante RAG		
Fuente	Experto en IA		
Prioridad	Alta	Estabilidad	Media
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe utilizar la estrategia RAG para recuperar los fragmentos más importantes de la documentación legal para que sirvan como base para la generación de respuestas.		

TABLA A.3. REQUISITO FUNCIONAL RF-03

Identificador	RF-03		
Nombre	Registro historial conversacional		
Fuente	Analista		
Prioridad	Media	Estabilidad	Media
Necesidad	Media	Verificabilidad	Alta
Descripción	El sistema debe guardar las tres últimas interacciones entre el usuario y el asistente.		

TABLA A.4. REQUISITO FUNCIONAL RF-04

Identificador	RF-04		
Nombre	Construcción del prompt		
Fuente	Analista		
Prioridad	Alta	Estabilidad	Alta
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe construir el prompt incluyendo instrucciones, fragmentos legales importantes y el historial conversacional almacenado.		

TABLA A.5. REQUISITO FUNCIONAL RF-05

Identificador	RF-05		
Nombre	Generación de respuesta legal con modelo LLM		
Fuente	Experto en IA		
Prioridad	Alta	Estabilidad	Media
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe generar una respuesta utilizando un LLM previamente ajustado al dominio legal relevante para las normativas consideradas.		

TABLA A.6. REQUISITO FUNCIONAL RF-06

Identificador	RF-06		
Nombre	Disponibilidad de base documental legal		
Fuente	Analista		
Prioridad	Alta	Estabilidad	Alta
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe disponer de una base documental legal que contenga textos relevantes sobre las normativas.		

TABLA A.7. REQUISITO FUNCIONAL RF-07

Identificador	RF-07		
Nombre	Entrada de consultas desde la interfaz web		
Fuente	Cliente		
Prioridad	Alta	Estabilidad	Alta
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe tener un campo de entrada en la interfaz que permita al usuario ingresar consultas.		

TABLA A.8. REQUISITO FUNCIONAL RF-08

Identificador	RF-08		
Nombre	Visualización inmediata de respuestas		
Fuente	Analista		
Prioridad	Media	Estabilidad	Alta
Necesidad	Media	Verificabilidad	Alta
Descripción	El sistema debe mostrar la respuesta generada en pantalla inmediatamente después de que finalice el procesamiento de la consulta.		

TABLA A.9. REQUISITO FUNCIONAL RF-09

Identificador	RF-09		
Nombre	Feedback sobre utilidad de respuestas		
Fuente	Analista		
Prioridad	Media	Estabilidad	Media
Necesidad	Media	Verificabilidad	Alta
Descripción	El sistema debe permitir al usuario indicar si una respuesta ha sido útil o no, mediante botones de “útil” y “no útil”.		

TABLA A.10. REQUISITO FUNCIONAL RF-10

Identificador	RF-10		
Nombre	Registro de interacciones en archivo CSV		
Fuente	Analista		
Prioridad	Alta	Estabilidad	Alta
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe registrar en un archivo CSV cada interacción del usuario, incluyendo la consulta realizada, la respuesta generada y el feedback recibido.		

TABLA A.11. REQUISITO FUNCIONAL RF-11

Identificador	RF-11		
Nombre	Retroalimentación visual durante el procesamiento		
Fuente	Analista		
Prioridad	Media	Estabilidad	Media
Necesidad	Media	Verificabilidad	Alta
Descripción	El sistema debe proporcionar retroalimentación visual durante el procesamiento de una consulta, con el fin de informar al usuario de que su petición está siendo atendida.		

TABLA A.12. REQUISITO FUNCIONAL RF-12

Identificador	RF-12		
Nombre	Botones de consulta rápida		
Fuente	Analista		
Prioridad	Baja	Estabilidad	Media
Necesidad	Baja	Verificabilidad	Alta
Descripción	El sistema debe ofrecer botones con temas predefinidos que, al pulsarse, generen automáticamente una consulta sobre ese tema.		

TABLA A.13. REQUISITO FUNCIONAL RF-13

Identificador	RF-13		
Nombre	Reinicio del historial de chat		
Fuente	Cliente		
Prioridad	Baja	Estabilidad	Media
Necesidad	Baja	Verificabilidad	Alta
Descripción	El sistema debe permitir al usuario eliminar el historial actual del chat mediante un botón, iniciando así una nueva conversación desde cero.		

TABLA A.14. REQUISITO FUNCIONAL RF-14

Identificador	RF-14		
Nombre	Inclusión de documentación legal CS3D		
Fuente	Cliente		
Prioridad	Alta	Estabilidad	Alta
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe contener documentación legal relevante relacionada con la CS3D con el fin de fundamentar las respuestas generadas.		

TABLA A.15. REQUISITO FUNCIONAL RF-15

Identificador	RF-15		
Nombre	Autenticación mediante claves de entorno		
Fuente	Analista		
Prioridad	Media	Estabilidad	Baja
Necesidad	Media	Verificabilidad	Alta
Descripción	El sistema debe cargar las claves necesarias desde un archivo y autenticar al usuario en Hugging Face y Pinecone de forma transparente para el usuario.		

TABLA A.16. REQUISITO FUNCIONAL RF-16

Identificador	RF-16		
Nombre	Extracción de contenido desde PDF		
Fuente	Analista		
Prioridad	Alta	Estabilidad	Alta
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe extraer el contenido de los documentos legales en formato PDF para su posterior procesamiento.		

TABLA A.17. REQUISITO FUNCIONAL RF-17

Identificador	RF-17		
Nombre	División del texto en fragmentos		
Fuente	Analista		
Prioridad	Alta	Estabilidad	Alta
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe dividir el texto en fragmentos de longitud configurable, evitando cortar ideas o frases a la mitad.		

TABLA A.18. REQUISITO NO FUNCIONAL RNF-01

Identificador	RNF-01		
Nombre	Tiempo de respuesta		
Fuente	Analista		
Prioridad	Media	Estabilidad	Alta
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe generar y mostrar la respuesta en un máximo de 11 segundos tras el envío de la consulta por parte del usuario.		

TABLA A.19. REQUISITO NO FUNCIONAL RNF-02

Identificador	RNF-02		
Nombre	Tiempo de carga del sistema		
Fuente	Analista		
Prioridad	Media	Estabilidad	Alta
Necesidad	Media	Verificabilidad	Alta
Descripción	El sistema debe estar completamente cargado y listo para recibir una consulta en menos de 10 segundos tras su despliegue o reinicio, para no afectar la experiencia de usuario.		

TABLA A.20. REQUISITO NO FUNCIONAL RNF-03

Identificador	RNF-03		
Nombre	Interfaz con formato de chat		
Fuente	Cliente		
Prioridad	Alta	Estabilidad	Media
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe presentar la interacción entre usuario y asistente en un formato conversacional tipo chat, con las consultas y respuestas mostradas de forma secuencial.		

TABLA A.21. REQUISITO NO FUNCIONAL RNF-04

Identificador	RNF-04		
Nombre	Sistema accesible desde cualquier dispositivo		
Fuente	Analista		
Prioridad	Alta	Estabilidad	Media
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe ejecutarse en una infraestructura en la nube que permita su uso desde cualquier ordenador, independientemente de sus especificaciones técnicas.		

TABLA A.22. REQUISITO NO FUNCIONAL RNF-05

Identificador	RNF-05		
Nombre	Facilidad de uso		
Fuente	Cliente		
Prioridad	Alta	Estabilidad	Alta
Necesidad	Alta	Verificabilidad	Media
Descripción	La interfaz debe ser clara, sencilla y comprensible para usuarios sin conocimientos técnicos ni jurídicos.		

TABLA A.23. REQUISITO NO FUNCIONAL RNF-06

Identificador	RNF-06		
Nombre	Persistencia del registro de interacciones		
Fuente	Analista		
Prioridad	Alta	Estabilidad	Alta
Necesidad	Alta	Verificabilidad	Alta
Descripción	El sistema debe almacenar de forma persistente las interacciones en un archivo CSV para su posterior análisis.		

TABLA A.24. REQUISITO NO FUNCIONAL RNF-07

Identificador	RNF-07		
Nombre	Rendimiento mínimo del modelo		
Fuente	Experto en IA		
Prioridad	Alta	Estabilidad	Baja
Necesidad	Alta	Verificabilidad	Alta
Descripción	El modelo LLM utilizado debe alcanzar un valor de pérdida (<i>loss</i>) inferior a 1.0 sobre el conjunto de validación al finalizar el entrenamiento, asegurando un rendimiento adecuado en la generación de respuestas legales.		

TABLA A.25. REQUISITO NO FUNCIONAL RNF-08

Identificador	RNF-08		
Nombre	Arquitectura desacoplada		
Fuente	Analista		
Prioridad	Media	Estabilidad	Alta
Necesidad	Media	Verificabilidad	Alta
Descripción	El sistema debe estar organizado en dos módulos principales (<i>frontend</i> y <i>backend</i>), permitiendo su mantenimiento y despliegue por separado.		

TABLA A.26. REQUISITO NO FUNCIONAL RNF-09

Identificador	RNF-09		
Nombre	Compatibilidad con navegadores modernos		
Fuente	Cliente		
Prioridad	Media	Estabilidad	Alta
Necesidad	Media	Verificabilidad	Alta
Descripción	La aplicación debe ser compatible con los navegadores web más utilizados (como Chrome, Firefox o Edge) sin requerir configuraciones adicionales.		

TABLA A.27. REQUISITO NO FUNCIONAL RNF-10

Identificador	RNF-10		
Nombre	Soporte modo claro y oscuro		
Fuente	Cliente		
Prioridad	Baja	Estabilidad	Alta
Necesidad	Baja	Verificabilidad	Alta
Descripción	El sistema debe permitir alternar entre modo claro y modo oscuro en la interfaz web, adaptándose a las preferencias visuales del usuario.		

B. Especificación de casos de uso completa

TABLA B.1. CASO DE USO CU-01

Identificador	CU-01	Nombre	Realizar una consulta
Actor	Usuario	Fuente	RF-01, RF-07, RF-11
Precondiciones	El sistema debe estar cargado, accesible desde la interfaz y con el modelo LLM disponible.		
Postcondiciones	La consulta se ha enviado correctamente y el sistema ha iniciado su procesamiento.		
Descripción	El usuario introduce una pregunta en lenguaje natural a través de la interfaz web.		

TABLA B.2. CASO DE USO CU-02

Identificador	CU-02	Nombre	Recuperar contexto legal
Actor	Sistema	Fuente	RF-02, RF-06, RF-14, RF-04
Precondiciones	El sistema ha recibido una consulta válida por parte del usuario.		
Postcondiciones	Se han identificado y seleccionado los fragmentos legales relevantes que servirán como contexto en el prompt.		
Descripción	El sistema utiliza una arquitectura basada en RAG para localizar y recuperar los fragmentos relacionados con la ley de la base de datos.		

TABLA B.28. CASO DE USO CU-03

Identificador	CU-03	Nombre	Generar respuesta con LLM
Actor	Sistema	Fuente	RF-03, RF-04, RF-05
Precondiciones	La consulta del usuario, el contexto y las instrucciones han sido recibidas correctamente a través del prompt.		
Postcondiciones	Se ha generado una respuesta coherente basada en el contexto proporcionado.		
Descripción	El sistema utiliza un modelo LLM para elaborar una respuesta a partir del prompt correspondiente que contiene la consulta del usuario, las instrucciones y el contexto recopilado.		

TABLA B.4. CASO DE USO CU-04

Identificador	CU-04	Nombre	Mostrar la respuesta
Actor	Sistema	Fuente	RF-08, RF-11
Precondiciones	Respuesta generada correctamente por el modelo.		
Postcondiciones	Respuesta visible en la interfaz de usuario.		
Descripción	El sistema presenta la respuesta generada de forma inmediata en la interfaz.		

TABLA B.5. CASO DE USO CU-05

Identificador	CU-05	Nombre	Valorar respuesta
Actor	Usuario / Sistema	Fuente	RF-09, RF-10
Precondiciones	El usuario ha recibido y leído la respuesta a la consulta legal.		
Postcondiciones	El sistema registra el <i>feedback</i> sobre la utilidad de la respuesta en un archivo CSV.		
Descripción	El usuario indica si la respuesta le ha resultado útil a través de los botones proporcionados para ello, y el sistema almacena dicha valoración junto con los datos de la interacción en un archivo CSV.		

TABLA B.6. CASO DE USO CU-06

Identificador	CU-06	Nombre	Consultar mediante sugerencias
Actor	Usuario	Fuente	RF-12
Precondiciones	El sistema debe estar cargado, accesible desde la interfaz y con el modelo disponible. Debe tener cargados los botones de sugerencias.		
Postcondiciones	El sistema lanza una consulta basada en el botón seleccionado.		
Descripción	El usuario selecciona uno de los botones temáticos disponibles para realizar una consulta rápida, sin necesidad de escribirla manualmente.		

TABLA B.7. CASO DE USO CU-07

Identificador	CU-07	Nombre	Reiniciar chat
Actor	Usuario	Fuente	RF-13
Precondiciones	Existe una conversación visible en la interfaz.		
Postcondiciones	El historial de chat ha sido borrado y se ha iniciado una nueva conversación.		
Descripción	El usuario pulsa el botón para eliminar el chat actual con el sistema y comenzar una nueva conversación desde cero.		

TABLA B.8. CASO DE USO CU-08

Identificador	CU-08	Nombre	Carga del sistema
Actor	Sistema	Fuente	RF-15, RF-07
Precondiciones	Sistema iniciado y con el archivo de entorno y claves necesarias para la autenticación.		
Postcondiciones	El sistema ha cargado las claves y ha autenticado el acceso a los servicios externos (Hugging Face, Pinecone), mostrando la interfaz para permitir su uso.		
Descripción	Al iniciarse, el sistema carga las claves desde el archivo y se autentica de forma transparente para el usuario en los servicios requeridos. Posteriormente, muestra la interfaz del asistente.		

TABLA B.9. CASO DE USO CU-09

Identificador	CU-09	Nombre	Carga de documentos
Actor	Administrador / Sistema	Fuente	RF-06, RF-14, RF-16, RF-17
Precondiciones	Se han cargado nuevos documentos legales en formato PDF.		
Postcondiciones	El contenido se extrae y se divide en fragmentos con una longitud determinada para su posterior uso.		
Descripción	Un administrador o desarrollador carga documentos legales en PDF. El sistema extrae el contenido y lo divide en fragmentos, para facilitar su uso en la recuperación de contexto.		

C. Dataset para *fine-tuning*

```
[
  {
    "input": "Soy productor de cacao en Ecuador. ¿Debo preocuparme por las condiciones laborales de mis trabajadores para cumplir con la CS3D?",
    "output": "Sí. Aunque no estas directamente regulado por la CS3D, si exportas a la UE, tus clientes pueden exigir que cumplas con estándares internacionales de derechos laborales. La CS3D obliga a las empresas europeas a verificar que sus proveedores respeten los derechos humanos, incluyendo condiciones laborales adecuadas. Te recomendaría revisar si tu finca cumple con las normativas laborales de la OIT, como la prohibición de trabajo infantil y la igualdad de condiciones laborales para todos."
  },
  {
    "input": "En mi finca en Ecuador, hemos escuchado que algunos de nuestros trabajadores son menores de edad. ¿Cómo puede esto afectarme si vendo a empresas en la UE?",
    "output": "La CS3D obliga a las empresas de la UE a asegurarse de que sus proveedores respeten los derechos laborales, incluido el trabajo infantil. Si alguna empresa europea detecta que tu finca emplea trabajo infantil, podría terminar el contrato contigo y enfrentarse a sanciones. Para evitar estos problemas, es importante asegurarte de que todos los trabajadores en tu finca sean adultos y que no haya explotación infantil."
  },
  {
    "input": "¿Qué puedo presentar para demostrar que en mi finca no hay corrupción ni malos manejos?",
    "output": "Lo ideal es tener una política interna clara contra la corrupción, y si tienes alguna auditoría o control interno, también ayuda."
  },
  {
    "input": "En mi finca en Ecuador trabajamos con comunidades indígenas para cultivar café. ¿Cómo afecta la CS3D a la relación con estos trabajadores",
    "output": "La CS3D también cubre el respeto a los derechos de las comunidades vulnerables, incluidas las comunidades indígenas, teniendo en cuenta la Declaración de las Naciones Unidas sobre los Derechos de los Pueblos Indígenas. Es importante que asegures que las condiciones de trabajo respeten sus derechos culturales, sociales y económicos. Deberías trabajar con ellos de forma equitativa, asegurándote de que reciban un trato justo, salarios adecuados y tengan acceso a servicios básicos. Si una empresa de la UE compra tus productos, te puede exigir que implementes políticas que respeten estos derechos para poder seguir colaborando (Fuente: CS3D - Normativa Europea - Introducción)"
  },
]
```

```

{
  "input": "Soy productor de cacao y tengo trabajadores temporales. ¿Qué debo hacer para evitar que mi empresa sea vista como responsable de explotación laboral?",
  "output": "Para evitar que tu empresa sea vista como responsable de explotación laboral, debes asegurarte de que los trabajadores temporales sean incluidos en el cálculo del número de empleados, de forma proporcional al tiempo que trabajen. Además, asegúrate de cumplir con las normativas laborales locales e internacionales, garantizando condiciones laborales justas. Los trabajadores temporales deben ser tratados conforme a los derechos laborales establecidos para evitar cualquier percepción de explotación (Fuente: CS3D - Normativa Europea - Introducción)"
},
{
  "input": "Tengo trabajadores migrantes de Venezuela en mi finca. ¿Cómo debo tratarlos para cumplir con la CS3D?",
  "output": "La CS3D también requiere que las empresas respeten los derechos de los trabajadores migrantes, garantizando su acceso a condiciones laborales justas, sin discriminación. Debes asegurarte de que los trabajadores migrantes reciban el mismo trato que los empleados locales en cuanto a salarios, beneficios y condiciones de trabajo. Es recomendable ofrecerles apoyo para regularizar su estatus migratorio si es necesario, y darles acceso a servicios como salud y educación (Fuente: CS3D - Normativa Europea - Introducción)"
},
{
  "input": "Si uno de mis proveedores en Ecuador viola derechos laborales, ¿la CS3D me puede hacer responsable?",
  "output": "Sí. La CS3D exige que las empresas en la UE verifiquen que sus proveedores respetan los derechos humanos y laborales. Si uno de tus proveedores en Ecuador tiene problemas en este sentido, y exportas a la UE, tu empresa puede verse afectada. Las empresas de la UE pueden suspender sus relaciones comerciales si descubren violaciones. Es importante que monitorees regularmente a tus proveedores y garantices que cumplen con los estándares internacionales."
},
{
  "input": "Hola!",
  "output": "¡Hola! ¿Cómo puedo ayudarte hoy? Si tienes dudas sobre la Ley CS3D o temas relacionados con los derechos laborales, estaré encantado de ayudarte."
},
{
  "input": "¿Qué es la Ley CS3D?",
  "output": "La Ley CS3D es una legislación europea que obliga a las grandes empresas a verificar que sus proveedores respeten los derechos humanos, incluyendo condiciones laborales justas. Si eres proveedor de alguna empresa en la UE, puede que también te afecte. ¿Te gustaría saber más?"
}

```

```

},
{
  "input": "¿Mi empresa necesita cumplir con la CS3D?",
  "output": "Para saber si tu empresa debe cumplir con la CS3D, necesitamos revisar ciertos detalles, como su tamaño, el sector en el que opera y si trabaja con empresas de la UE. ¿Podrías darme más información sobre tu empresa?"
},
{
  "input": "¿Tengo que seguir la CS3D si mi empresa es pequeña?",
  "output": "La Ley CS3D está principalmente dirigida a grandes empresas, pero si tu empresa es pequeña, la ley podría aplicar en función de tus actividades. ¿Cuántos empleados tiene tu empresa y cuál es su volumen de facturación anual? Esto me ayudará a darte una respuesta más precisa."
},
{
  "input": "¿Cómo aseguro que haya igualdad entre hombres y mujeres en mi finca?",
  "output": "Asegúrate de que los contratos no hagan distinciones por género y aplica las mismas condiciones laborales a todos."
},
{
  "input": "Soy productor de cacao en Ecuador. ¿Qué debo hacer para evitar que mi empresa emplee a niños de manera ilegal?",
  "output": "Para evitar emplear a niños ilegalmente, asegúrate de cumplir con las normativas internacionales sobre trabajo infantil. Según la Convención sobre los Derechos del Niño y la OIT, está prohibido el trabajo infantil que afecte la educación, salud o desarrollo, y no se permite el empleo de menores de 15 años, salvo en excepciones locales. Verifica que todos tus empleados cumplan con la edad mínima legal y que las condiciones laborales sean adecuadas (Fuente: CS3D - Normativa Europea - ANEXO)."
},
{
  "input": "Soy productor de cacao en Ecuador, ¿cómo puedo asegurarme de que mi cadena de suministro cumpla con los estándares de la CS3D y evite problemas de explotación laboral?",
  "output": "Para asegurar que tu cadena de suministro cumpla con los estándares de la CS3D, es fundamental implementar sistemas de trazabilidad que permitan verificar el origen de tus productos y las condiciones laborales de los trabajadores en cada etapa. Debes mantener registros claros de tus proveedores y de las condiciones laborales en su campo, incluyendo auditorías periódicas. Además, es importante establecer acuerdos con tus proveedores que incluyan compromisos claros sobre el respeto a los derechos laborales y el cumplimiento de la normativa local e internacional. Asegúrate de que tu empresa esté preparada para proporcionar evidencia clara de su compromiso con la transparencia y el respeto a los derechos humanos."
}

```

```

    },
    {
      "input": "¿Quién revisa que las instalaciones de mi parcela sean seguras?",
      "output": "Normalmente el Ministerio de Trabajo hace inspecciones, y tener esos informes te puede servir como evidencia."
    },
    {
      "input": "¿Qué documento muestra que en mi finca no hay esclavitud ni trabajo forzoso?",
      "output": "Una política interna que lo prohíba y contratos firmados libremente con los trabajadores serían una buena prueba."
    },
    {
      "input": "¿Qué documentos necesito para cumplir con las reglas de seguridad en mi plantación?",
      "output": "Una certificación del Ministerio de Trabajo o pruebas de inspecciones pasadas ayudarán a demostrarlo."
    },
    {
      "input": "¿Cómo pruebo que tengo derecho a usar la tierra donde tengo mi plantación?",
      "output": "Puedes presentar el título de propiedad o un contrato de arriendo firmado y legalizado."
    }
  ]

```

D. Resultados *fine-tuning*

{'loss': 2.3657, 'grad_norm': 25.612300872802734, 'learning_rate': 4.996573836886435e-05, 'epoch': 0.27}
{'loss': 2.0153, 'grad_norm': 12.744002342224121, 'learning_rate': 4.9863047384206835e-05, 'epoch': 0.53}
{'loss': 1.6629, 'grad_norm': 2.0732595920562744, 'learning_rate': 4.9453690018345144e-05, 'epoch': 1.0}
{'loss': 1.6146, 'grad_norm': 1.2246085405349731, 'learning_rate': 4.877641290737884e-05, 'epoch': 1.53}
{'loss': 1.5702, 'grad_norm': 2.602419853210449, 'learning_rate': 4.783863644106502e-05, 'epoch': 2.0}
{'loss': 1.4979, 'grad_norm': 1.7059471607208252, 'learning_rate': 4.665063509461097e-05, 'epoch': 2.53}
{'eval_loss': 1.531161904335022, 'eval_runtime': 113.9125, 'eval_samples_per_second': 0.026, 'eval_steps_per_second': 0.009, 'epoch': 2.53}
{'loss': 1.409, 'grad_norm': 1.3603127002716064, 'learning_rate': 4.522542485937369e-05, 'epoch': 3.0}
{'loss': 1.3297, 'grad_norm': 1.057112693786621, 'learning_rate': 4.357862063693486e-05, 'epoch': 3.53}
{'loss': 1.3667, 'grad_norm': 1.0006740093231201, 'learning_rate': 4.172826515897146e-05, 'epoch': 4.0}
{'loss': 1.2473, 'grad_norm': 1.098539113998413, 'learning_rate': 3.969463130731183e-05, 'epoch': 4.53}
{'loss': 1.2539, 'grad_norm': 1.0845366716384888, 'learning_rate': 3.7500000000000003e-05, 'epoch': 5.0}
{'eval_loss': 1.2804114818572998, 'eval_runtime': 117.3444, 'eval_samples_per_second': 0.026, 'eval_steps_per_second': 0.009, 'epoch': 5.0}
{'loss': 1.1731, 'grad_norm': 1.1978927850723267, 'learning_rate': 3.516841607689501e-05, 'epoch': 5.53}
{'loss': 1.1445, 'grad_norm': 1.1801848411560059, 'learning_rate': 3.272542485937369e-05, 'epoch': 6.0}
{'loss': 1.0503, 'grad_norm': 1.1394774913787842, 'learning_rate': 3.0197792270443982e-05, 'epoch': 6.53}
{'loss': 1.0824, 'grad_norm': 1.6617164611816406, 'learning_rate': 2.761321158169134e-05, 'epoch': 7.0}
{'loss': 0.9731, 'grad_norm': 1.5344549417495728, 'learning_rate': 2.5e-05, 'epoch': 7.53}
{'eval_loss': 1.0669505596160889, 'eval_runtime': 117.4368, 'eval_samples_per_second': 0.026, 'eval_steps_per_second': 0.009, 'epoch': 7.53}
{'loss': 0.9931, 'grad_norm': 1.5534216165542603, 'learning_rate': 2.238678841830867e-05, 'epoch': 8.0}
{'loss': 0.9355, 'grad_norm': 1.315373182296753, 'learning_rate': 1.980220772955602e-05, 'epoch': 8.53}


```

{'loss': 0.8754, 'grad_norm': 1.4858345985412598, 'learning_rate':
1.7274575140626318e-05, 'epoch': 9.0}
{'loss': 0.8759, 'grad_norm': 1.3349635601043701, 'learning_rate':
1.4831583923104997e-05, 'epoch': 9.53}
{'loss': 0.8153, 'grad_norm': 1.5008388757705688, 'learning_rate':
1.2500000000000006e-05, 'epoch': 10.0}
{'eval_loss': 0.9238970875740051, 'eval_runtime': 117.4887,
'eval_samples_per_second': 0.026, 'eval_steps_per_second': 0.009, 'epoch': 10.0}
{'loss': 0.8173, 'grad_norm': 1.4158514738082886, 'learning_rate':
1.0305368692688174e-05, 'epoch': 10.53}
{'loss': 0.7805, 'grad_norm': 1.4837455749511719, 'learning_rate':
8.271734841028553e-06, 'epoch': 11.0}
{'loss': 0.7712, 'grad_norm': 1.298365592956543, 'learning_rate': 6.421379363065142e-
06, 'epoch': 11.53}
{'loss': 0.7774, 'grad_norm': 1.322670578956604, 'learning_rate':
4.7745751406263165e-06, 'epoch': 12.0}
{'loss': 0.769, 'grad_norm': 1.3376953601837158, 'learning_rate':
3.3493649053890326e-06, 'epoch': 12.53}
{'eval_loss': 0.8644374012947083, 'eval_runtime': 117.041, 'eval_samples_per_second':
0.026, 'eval_steps_per_second': 0.009, 'epoch': 12.53}
{'loss': 0.7312, 'grad_norm': 1.4853293895721436, 'learning_rate':
2.1613635589349756e-06, 'epoch': 13.0}
{'loss': 0.7284, 'grad_norm': 1.3825472593307495, 'learning_rate':
1.2235870926211619e-06, 'epoch': 13.53}
{'loss': 0.7714, 'grad_norm': 1.443272352218628, 'learning_rate': 5.463099816548579e-
07, 'epoch': 14.0}
{'loss': 0.7179, 'grad_norm': 1.3563944101333618, 'learning_rate':
1.3695261579316777e-07, 'epoch': 14.53}
{'loss': 0.7643, 'grad_norm': 1.4420806169509888, 'learning_rate': 0.0, 'epoch': 15.0}
{'eval_loss': 0.8547428250312805, 'eval_runtime': 116.9167,
'eval_samples_per_second': 0.026, 'eval_steps_per_second': 0.009, 'epoch': 15.0}
{'train_runtime': 28827.0335, 'train_samples_per_second': 0.01,
'train_steps_per_second': 0.002, 'train_loss': 1.0896591822306314, 'epoch': 15.0}

```

E. Fragmentos recuperados en la evaluación

Consulta 1: ¿Qué es la directiva CS3D?

Fragmento 1 (Fuente: CS3D - Normativa Europea - Introducción):

Las garantías contractuales deben estar concebidas para garantizar que la empresa y los socios comerciales compartan adecuadamente las responsabilidades. Las garantías contractuales deben ir acompañadas de medidas adecuadas para comprobar su cumplimiento. Sin embargo, la empresa solo debe estar obligada a intentar recabar las garantías contractuales, ya que ELI: <http://data.europa.eu/eli/dir/2024/1760/oj> 11/58 ES DO L de 5.7.2024 su obtención puede depender de las circunstancias.

Fragmento 2 (Fuente: CS3D - Normativa Europea - Artículo 12):

Reparación de efectos adversos reales. Los Estados miembros velarán por que una empresa repare un efecto adverso real que haya causado por sí misma o conjuntamente. Cuando el efecto adverso real haya sido causado únicamente por un socio comercial de la empresa, esta podrá repararlo voluntariamente. Asimismo, la empresa podrá recurrir a su capacidad de influir en el socio comercial que esté causando el efecto adverso para repararlo.

Fragmento 3 (Fuente: CS3D - Normativa Europea - Artículo 7):

La política de diligencia debida contemplada en el apartado 1 se elaborará previa consulta a los empleados de la empresa y sus representantes y constará de todos los elementos siguientes: una descripción del enfoque aplicado por la empresa —incluso a largo plazo— a la diligencia debida.

Consulta 2: ¿A qué empresas se aplica la CS3D?

Fragmento 1 (Fuente: CS3D - Normativa Europea - Introducción):

Las garantías contractuales deben estar concebidas para garantizar que la empresa y los socios comerciales compartan adecuadamente las responsabilidades.

Fragmento 2 (Fuente: CS3D - Normativa Europea - Introducción):

El documento de trabajo de los servicios de la Comisión que acompaña a la Comunicación de la Comisión, de 17 de septiembre de 2020, titulada «Intensificar la ambición climática de Europa para 2030».

Fragmento 3 (Fuente: CS3D - Normativa Europea - Introducción):

El plan debe abordar, en su caso, la exposición de la empresa a actividades relacionadas con el carbón, el petróleo y el gas.

Consulta 3: ¿Qué debe incluir un plan de acción conforme a la CS3D?

Fragmento 1 (Fuente: CS3D - Normativa Europea - Artículo 7):

La política de diligencia debida contemplada en el apartado 1 se elaborará previa consulta a los empleados de la empresa y sus representantes y constará de todos los elementos siguientes: una descripción del enfoque aplicado por la empresa—incluso a largo plazo— a la diligencia debida.

Fragmento 2 (Fuente: CS3D - Normativa Europea - Introducción):

Las garantías contractuales deben estar concebidas para garantizar que la empresa y los socios comerciales compartan adecuadamente las responsabilidades.

Fragmento 3 (Fuente: CS3D - Normativa Europea - Artículo 22):

Descripción de las palancas de descarbonización detectadas y de las acciones clave previstas para alcanzar los objetivos mencionados en la letra a), incluidos cambios en la cartera de productos y de servicios y la adopción de nuevas tecnologías; explicación y cuantificación de las inversiones y financiación para apoyar la ejecución del plan de transición.

Consulta 4: ¿Qué obligaciones de diligencia debida establece la CS3D en materia de derechos humanos?

Fragmento 1 (Fuente: CS3D - Normativa Europea - Introducción):

El concepto de diligencia debida en materia de derechos humanos se especificó y desarrolló más a fondo en las Líneas Directrices para Empresas Multinacionales de la OCDE.

Fragmento 2 (Fuente: CS3D - Normativa Europea - Introducción):

Las empresas deben tener esto en cuenta a la hora de integrar la diligencia debida en sus políticas y sistemas de gestión de riesgos para garantizar que los códigos de conducta y los procesos establecidos se adapten a las zonas de conflicto y de alto riesgo.

Fragmento 3 (Fuente: CS3D - Normativa Europea - Introducción):

Las víctimas deben tener derecho a la plena indemnización por los daños y perjuicios sufridos, de conformidad con el Derecho nacional y en consonancia con este principio común.

F. Declaración de IA



DECLARACIÓN DE USO DE IA GENERATIVA EN EL TRABAJO DE FIN DE GRADO

He usado IA Generativa en este trabajo

Marca lo que corresponda:

SI	NO
----	----

Si has marcado SI, completa las siguientes 3 partes de este documento:

Parte 1: reflexión sobre comportamiento ético y responsable

Ten presente que el uso de IA Generativa conlleva unos riesgos y puede generar una serie de consecuencias que afecten a la integridad moral de tu actuación con ella. Por eso, te pedimos que contestes con honestidad a las siguientes preguntas (*Marca lo que corresponda*):

Pregunta		
1. En mi interacción con herramientas de IA Generativa he remitido datos de carácter sensible con la debida autorización de los interesados.		
SÍ, he usado estos datos con autorización	NO, he usado estos datos sin autorización	NO, no he usado datos de carácter sensible
2. En mi interacción con herramientas de IA Generativa he remitido materiales protegidos por derechos de autor con la debida autorización de los interesados.		
SÍ, he usado estos materiales con autorización	NO, he usado estos materiales sin autorización	NO, no he usado materiales protegidos

3. En mi interacción con herramientas de IA Generativa he remitido datos de carácter personal con la debida autorización de los interesados.		
SÍ, he usado estos datos con autorización	NO, he usado estos datos sin autorización	NO, no he usado datos de carácter personal
4. Mi utilización de la herramienta de IA Generativa ha respetado sus términos de uso , así como los principios éticos esenciales, no orientándola de manera maliciosa a obtener un resultado inapropiado para el trabajo presentado, es decir, que produzca una impresión o conocimiento contrario a la realidad de los resultados obtenidos, que suplante mi propio trabajo o que pueda resultar en un perjuicio para las personas.		
SI		NO

Si **NO** has contado con la autorización de los interesados en alguna de las preguntas 1, 2 ó 3, explica brevemente el motivo (*por ejemplo, “los materiales estaban protegidos pero permitían su uso para este fin” o “los términos de uso, que se pueden encontrar en esta dirección (...), impiden el uso que he hecho, pero era imprescindible dada la naturaleza del trabajo”*).

No aplicable (no he usado datos personales, sensibles ni materiales protegidos).

Parte 2: declaración de uso técnico

Utiliza el siguiente modelo de declaración tantas veces como sea necesario, a fin de reflejar todos los tipos de iteración que has tenido con herramientas de IA Generativa. Incluye un ejemplo por cada tipo de uso realizado donde se indique: *[Añade un ejemplo]*.

Declaro haber hecho uso del sistema de IA Generativa ChatGPT para:

Documentación y redacción:

- *Soporte a la reflexión en relación con el desarrollo del trabajo: proceso iterativo de análisis de alternativas y enfoques utilizando la IA*

He utilizado la IA como apoyo para identificar alternativas de modelos adecuados para la vectorización y para la generación en el contexto de mi proyecto. A partir de las sugerencias obtenidas, he profundizado posteriormente en la documentación de cada modelo y en su idoneidad para el caso de uso concreto.

- *Revisión o reescritura de párrafos redactados previamente*

He solicitado la reformulación de algunas frases o párrafos que estaban mal redactados o poco claros, para mejorar la redacción manteniendo las ideas originales, así como para suavizar el tono de explicaciones que resultaban demasiado técnicas.

- *Búsqueda de información o respuesta a preguntas concretas*

He solicitado información sobre los parámetros que se pueden ajustar en los modelos utilizados y componentes como *LoRAConfig*, *Trainer* y otros elementos del *pipeline* de ajuste, con el fin de entender mejor las opciones disponibles y su impacto en el comportamiento del modelo.

- *Búsqueda de bibliografía*

He solicitado ejemplos de papers que utilizasen RAG en asistentes legales para contrastar enfoques posibles en mi desarrollo, así como ejemplos de herramientas que aplicasen técnicas similares. La IA me ha servido como apoyo en la búsqueda inicial de literatura relacionada, que posteriormente he leído y evaluado de manera crítica antes de decidir su inclusión en el trabajo.

Desarrollar contenido específico

Se ha hecho uso de IA Generativa como herramienta de soporte para el desarrollo del contenido específico del TFG, incluyendo:

- *Asistencia en el desarrollo de líneas de código (programación)*

He pedido explicaciones sobre código Python de la parte de fine-tuning, relacionado con el uso de Trainer y LoRAConfig para entender mejor el flujo de entrenamiento.

También he consultado ejemplos de cómo manejar el uso de Streamlit o Pinecone.

- *Inspiración de ideas en el proceso creativo*

He solicitado ideas para posibles ejemplos de uso del asistente legal que sirvieran como ejemplo en la memoria y en el dataset del entrenamiento, en el contexto de empresas y cumplimiento de normativas como CS3D y EUDR.

Parte 3: reflexión sobre utilidad

Por favor, aporta una valoración personal (formato libre) sobre las fortalezas y debilidades que has identificado en el uso de herramientas de IA Generativa en el desarrollo de tu trabajo. Menciona si te ha servido en el proceso de aprendizaje, o en el desarrollo o en la extracción de conclusiones de tu trabajo.

El uso de herramientas de IA Generativa ha resultado útil como apoyo para obtener una primera aproximación en la búsqueda de bibliografía relevante, especialmente en las fases iniciales del trabajo, cuando no siempre es evidente por dónde comenzar a explorar el estado del arte. Este uso me ha permitido ahorrar tiempo en la identificación de fuentes útiles, que posteriormente he analizado y valorado de forma crítica.

La IA también me ha ayudado a entender mejor el impacto de distintos parámetros en el ajuste del modelo y en la generación de respuestas, facilitando la comprensión teórica de su funcionamiento. Este apoyo ha contribuido a mi aprendizaje en el uso de los modelos, aunque la configuración final y el ajuste de los mismos han requerido siempre un trabajo manual y un análisis propio.

Como debilidad, he observado que las sugerencias bibliográficas no siempre son precisas, ni puede sustituir el juicio experto necesario para ajustar modelos en tareas específicas. Ha sido, una herramienta complementaria que ha enriquecido el proceso de aprendizaje, sin reemplazar el trabajo personal en el desarrollo del TFG.